



C++哈氏教程

第二版

cppHusky

序

本书为 *cppHusky* 的二〇二四年礼。

cppHusky

目录

序	i
泛讲篇	3
第一章 初识 C++	3
1.1 开始一个 C++ 程序	3
1.2 数据与信息	6
1.3 数据的定义和使用	8
1.4 运算符与类型	11
1.5 <code>sizeof</code> 与内存空间	13
1.6 类与对象	16
第二章 数据的基本操作	19
2.1 赋值语句与常量	19
2.2 基本数据类型	22
2.3 运算符	27
2.4 类型转换	32
第三章 程序的流程控制	37
3.1 简介：结构、流程与次序	37
3.2 选择结构	45
3.3 循环结构	51
3.4 作用域初步	60
3.5 实操：简易计算器的设计	61
第四章 函数初步	65
4.1 函数的概念	65
4.2 函数的定义和使用	67
4.3 函数重载	73
4.4 默认参数的设置	76
4.5 函数递归	78
4.6 函数模版简介	80
第五章 复合类型及其使用	83
5.1 指针	83
5.2 “常量指针” 与 “指向常量的指针”	92

5.3 (左值) 引用与引用参数传递	94
5.4 一维数组	98
5.5 字符串	107
5.6 指针与数组的复合类型	112
5.7 动态内存分配	120
第六章 自定义类型及其使用	125
6.1 枚举常量	125
精讲篇	129
附录 A C++ 运算符基本属性	129
附录 B ASCII 码表 (0 到 127)	131
附录 C 相关数学知识	133
C.1 进制与进制转换	133
跋	135

泛讲篇

第一章 初识 C++

在本章，我们将会了解一些 C++ 中最基本的知识，最常见的概念，和最简单的语法，并付诸代码来实现。

我们不要求读者搞懂每句代码的含义——那是不必要的。我们在本章中会给出一个基本的代码模版，读者只需修改其中的一小部分即可。毕竟，学习都是从模仿开始的，C++ 也不例外。

有一点值得注意。我们需要有一个编译器，来把我们的代码 (.cpp 文件或者别的什么) 变成可以执行和看到效果的程序（Windows 中的.exe 文件、Linux 或 MacOS 上的可执行文件，或者别的什么），以便检查它能否实现我们想要的功能，并在日后使用这个程序。

根据自己计算机的系统，你可以选择[Embarcadero Dev-C++ \(Windows\)](#), [Microsoft Visual C++ \(Windows\)](#), [Apple Xcode \(MacOS\)](#), [Open Watcom C++ \(Windows/Linux/DOS\)](#), [Code::Blocks \(跨系统\)](#), [MonoDevelop \(跨系统\)](#)。这些都是集成开发环境¹，你只需要在下载后做很简单的配置，就可以开始写代码了。

另外还有一些代码编辑器，比如[Visual Studio Code \(Windows/Linux/MacOS\)](#), [Sublime Text \(Windows/Linux/MacOS\)](#), [Vim \(跨系统\)](#)，你需要做额外的配置（比如安装插件），把它们变得如同集成开发环境一样。

另有一些在线的代码编译工具，让你可以无需安装软件，只要在浏览器上提供代码，就能远程编译并告诉你运行结果。比如[Coliru](#)和[Wandbox](#)。不过相比于本地编译运行，这种方式的交互效果就相当差劲了，仅适合一些无输入或只有简单输入的程序。这些在线编译方式对于本章涉及的程序来说当然够用，但不要太过依赖。

1.1 开始一个 C++ 程序

各种编程语言的教程都喜欢用“输出 Hello World!”作为第一个编程示例，本书也不例外。

在 C++ 中，我们可以用如下的代码来输出“Hello World!”：

代码 1.1: Hello_World.cpp

```
// 这是一个简单的C++程序，用于输出Hello World
#include <iostream> // 标准输入输出头文件
using namespace std; // 使用 std 命名空间
int main() { // 主函数，程序执行始于
    cout << "HelloWorld!"; // 输出Hello World
    return 0;
}
```

如果你使用的是集成开发环境，那么只需要用一两个选项或快捷键就可以完成编译、运行步骤，并看到程序的运行结果了。这个快捷键因软件而异，不过总得说来，可以概括成三个过程：

¹集成开发环境（Integrated Development Environment, IDE），是一种辅助进行软件开发的应用。在开发工具内部就可以编写源代码，并编译打包成为可用的程序。IDE 需要的配置较少，对新手比较友好，上手容易。

1. 编译 (Compile): 编译器将你写在文件中的源代码²编译成目标代码³。
2. 链接 (Link): 将目标代码与其它代码链接。C++ 标准库提供了非常丰富的功能，而链接器负责将我们的源代码与这些功能对应的库，以及其它必需文件结合起来，形成可执行文件。
3. 运行 (Run): 可执行文件在运行时，可以进行计算、存取和用户交互等各种行为。程序可以长期处于运行状态，也可以在某个指令后结束运行。

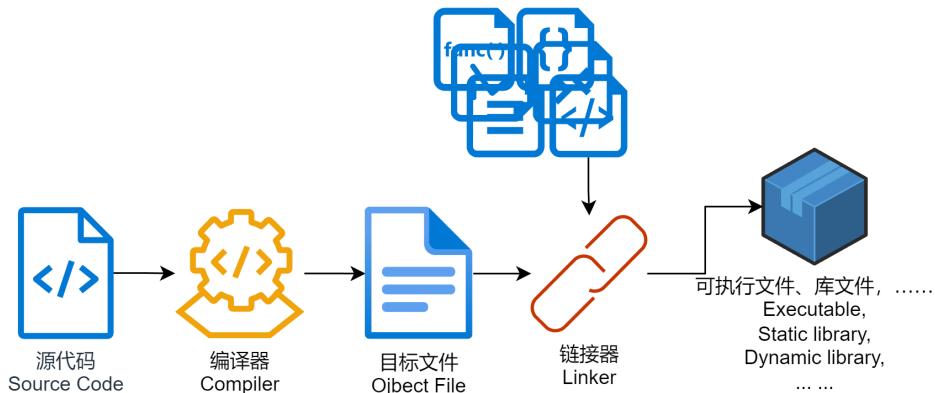


图 1.1: 从源代码到可执行文件

实际上的过程会更复杂，比如在编译之前还会进行预处理（Preprocess）。但是我们现在还不需要操心这么多，因为在按下“编译”键之后，预处理和编译都会进行，所以不妨把它统称为一个过程。

编译器的选择

C++ 的编译器（Compiler）非常丰富。[List of C++ Compilers-Wikipedia](#) 条目为我们提供了一个不完全的 C++ 编译器列表。

一般我们选择使用 Clang、GCC 或 Visual C++ (MSVC)，它们都是跨系统的编译器，对语言标准的支持比较好⁴，许多 IDE (如 Dev_C++, Code::Blocks, Visual C++ 等) 也都默认提供这些编译器之一。另外，Coliru 和 Wandbox 等在线编译器也都支持使用 Clang 和 GCC。

同种的编译器也会有版本上的差异。很多古老的版本 (如 GCC 4.9.4) 并不支持新近的语法 (如 C++17⁵)。新版本的编译器往往有很多好用的特性，比如对代码有更好的优化。⁶

语言标准的选择

不同的 C++ 标准 (Standard) 对语法的支持不同。比如说，在 C++11 以后的标准中下，可以使用 `auto` 来自动确定我们要定义的变量类型。这是一种很方便的语法，但 C++11 以前的版本就不支持使用。

C++ 语言标准的更新总会带来很多新的功能，也会对以往标准中的缺陷和漏洞加以弥补，所以越新的标准往往就越强大、易用。另一方面，新标准通常都能兼容旧标准⁷，所以你也无需担心为了适应新标准而放弃很多旧知识，或者换用新标准后很多代码编译失败了。

²源代码 (Source Code)，是一系列人类可读的计算机语言指令，在 C++ 中一般指.cpp 文件中的代码。

³目标代码 (Object Code)，是源代码经编译器或汇编器处理后产生的代码，对人类来说可读性很差。机器不能直接执行源代码，只能执行目标代码。

⁴Clang 和 GCC 支持 C++17 以前标准和 C++20 的大部分标准，而 MSVC 支持 C++20 的全部标准和 C++23 的部分标准。

⁵C++17 是 C++ 委员会制定的一个语言标准，其最终版发布于 2017 年 12 月。这也是本书采用的主要语言标准。

⁶另请注意，最好选择稳定版本的编译器，而非试验性的测试版，以免出现问题带来的麻烦。

⁷只是通常如此。有很多反例，比如 C++17 标准移除了古已有之的 `std::auto_ptr`。

可惜并非所有编译器都能支持 C++ 新标准的特性。因此，在编写本书时，考虑到许多编译器对语言标准支持的情况，本书选择使用 C++17 标准。今后若无特殊说明，默认本书所有知识和代码遵循 C++17 标准。

Windows 下运行的可能问题

在 Windows 系统中，很多 IDE 允许你在一个辅助窗口中运行程序（我本人比较习惯这种方式）。有些 IDE 在程序执行完毕后，会保留辅助窗口，等待用户“按任意键继续”，于是我们有足够的时间看到程序运行的结果；还有一些 IDE 在程序结束时会立刻关闭辅助窗口，我们就来不及看程序运行的结果。

为了解决这个问题，我们可能需要对代码做一些修改：

```
//... 前面的代码不变
cin.get(); // 可能需要添加的语句
cin.get(); // 甚至可能需要再加这句
return 0;
}
```

`cin.get()` 的作用是读取下一个键盘输入，所以如果你不按下键盘上的 Enter 键，程序就会一直等待下去。（只有按下 Enter，输入内容才能发送给程序，我们后面会慢慢道来）

至于用两个 `cin.get()`，这是为了应对可能的 '`\n`' 遗留被第一个 `cin.get()` 吞没。我们现在尚无必要在乎这些细枝末节，只需要知道：如果窗口没有保持打开，就加一个 `cin.get()`；如果还不行，就加两个 `cin.get()`。⁸

回到 Hello World

现在让我们回来看 Hello World 代码。这个代码可以在任何操作系统上，用任何编译器和任何语言标准来编译。程序的输出就是一个单词 `Hello World!`。

```
// 这是一个简单的C++程序，用于输出Hello World
```

程序的第一行是一个注释（Comment）。注释以两个双斜线开头，其后直到行末的内容均会被编译器忽略，所以你写什么都可以。注释是为了给人类阅读的，以便我们理解程序和代码的含义。

```
#include <iostream> // 标准输入输出头文件
```

程序的第二行是一个文件包含（File Inclusion）。通过这个语句，预处理器会对代码作预处理⁹，将本句命令替换成 `iostream` 库中的代码。

```
using namespace std; // 使用 std 命名空间
```

程序的第三行是一个命名空间（Namespace）使用。C++ 中，`cout` 被定义¹⁰在 `std` 命名空间中，我们要通过 `std::cout` 这样的语法才可以使用它。而有了 `using namespace std;` 之后，我们就可以直接使用 `cout`。

关于文件包含和命名空间的概念，我们会在第七章进行讲解。目前我们无需过分纠结。

```
int main(){// 主函数，程序执行始于此
    // 函数体代码
}
```

⁸值得留意的是，用 `cin.get()` 来阻断程序进度只是一种临时的解决方案，目的在于便于我们进行学习和演示。而在实际的开发中，人们通常不会在程序中添加这种代码。

⁹如前所述，源代码在编译之前需要经过预处理，例如文件包含和宏。预处理结束后，编译才会开始。

¹⁰定义（Definition），是为程序中的一个实体（如变量、函数、类等）分配内存并提供其具体的实现或值的过程。在以 C++ 为代表的静态语言中，一个实体必须定义才能使用。

程序的第四行是主函数（Main Function）的定义。主函数是程序的入口，它必须唯一。程序从主函数开始按顺序执行各句代码，除非遇到了条件或循环结构。关于函数，我们会在第四章讲解；关于结构，我们会在第三章讲解。

```
cout << "HelloWorld!"; // 输出 Hello World
```

程序的第五行是输出（Output）语句。这一句对我们来说更重要，因为我们接下来要模仿的代码主要是基于修改输出内容来实现的。

<< 左侧的 cout 是在标准库 iostream 中定义的 std 空间的对象，控制标准输出。我们无需对它作修改；<< 右侧的 "HelloWorld!" 则是我们要输出的内容。外套双引号表示它是一个字符串，我们会在第五章讲解字符串。

如果我们想要输出一个数字，我们只需要修改 << 右侧的内容即可，比如

```
cout << 3.14159; // 输出圆周率小数点后五位
```

第三节我们就会开始介绍如何使用 cout 来输出数据。

1.2 数据与信息

我们日日夜夜都在与数据打交道。

早上醒来，看一眼天气预报，发现今天的最低气温是-5°C，比昨天低了好多，看来要加衣服了；匆忙赶到教室，看了一眼时间，发现刚好是 7:59，庆幸自己没有迟到；中午去超市购物，发现面包促销，全场打 8 折，就买了好多回去；睡前称一下体重，发现比上个月瘦了 2 斤，心中暗暗窃喜。像这样，温度、时间、价格、体重等等，都是具象的数据（Data）。

我们还可能遇到抽象的数据。学生的学号、员工的工号、公民身份证号，这些都是“编号”，它们比那些一眼就明白含义的数据要抽象，如果不加解释，我们就很难看懂，只会觉得那是一串无规律的数字。

有些数据的形式不太常规，比如一个人的姓名，它看上去又像数据，又不像数据——我们怎么能把汉字当成数字一样的东西呢？要解决这个困惑，我们可以给所有汉字进行编码（Encoding）。比如说，“赵钱孙李”分别定为“1, 2, 3, 4”，那么我们就可以把“赵”记为“1”，把“孙”记为“3”。像这样把所有汉字都编成表，接下来我们就可以用这张表来把汉字翻译成数字了。

表 1.1: 一个简单的汉字-数字编码表

汉字	编码	汉字	编码	汉字	编码	汉字	编码
赵	1	钱	2	孙	3	李	4
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
何	21	吕	22	施	23	张	24
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
一	569	二	570	三	571	四	572
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

于是我们根据这个表，可以查出“张三”对应“24-571”，而“李四”对应“4-572”。这就是一个简单的编码过程。

同样的道理，我们如果拿到了“24-571”，就可以根据这张表查出“张三”；拿到了“4-572”，就可以根据这张表查出“李四”。这就是一个简单的解码（Decoding）过程。

地址也是数据，我们可以对地址进行编码。例如，中国邮政使用六位数字组成的邮政编码来划分邮件投递区域，比如说北京市是“10××××”，上海市是“20××××”。这样就可以用数据来指代我们想要表达的信息了。

还有更抽象的数据。一本电子书，一部电影，一款电子游戏，也是数据¹¹。在计算机中，它们都有相应的文件扩展名，像是.epub, .mp4, .exe之类。这些文件都以某种编码方式储存在计算机里，扩展名不同，说明它们的编码方式不同。如果要了解这些文件中的信息，就需要用正确的打开方式（比如下载支持.epub格式的电子书阅读器）才能对内容进行解码。

C++ 中的基本数据

说了这么多，让我们回来看看 C++ 中的数据吧。C++ 的数据可以分为两大类：**基本类型 (Fundamental type)** 和**复合类型 (Compound type)**。本章删繁就简，只介绍三种基本的数据类型：整数、浮点数（小数），字符。

整数类型 (Integer type)

顾名思义，整型就是专为表示整数而设计的类型。它不能表示小数。

C++ 为我们提供了很多内置的整数类型，我们可以直接使用。不同类型的区别主要在于以下两点：其一，有些可以表示负数，而有些不允许表示负数；其二，有些表示的数据范围较宽（我们可以把这个范围理解成“容量”），有些则较窄¹²。我们目前无需追究其中的细节，我会在第二章和后面的精讲篇中详细讨论这个问题。

浮点类型 (Floating-point type)

浮点类型有点像“科学记数法”，一个浮点数既有表示分数的部分 (Fraction)，又有表示幂次的部分 (Exponent bias)。它既可以表示小数，也可以表示整数，并且数据范围非常宽¹³。

C++ 同样提供了内置的浮点类型。不同类型的区别主要在于以下两点：其一，它们能表示的有效位数各不相同；其二，它们的幂指数范围有宽有窄。

字符类型 (Character type)

严格说来，字符型是一种特殊的整型。不同之处在于，字符数据不是用来“计算”而是用来“编码”的。

以最原始而最通用的 ASCII 码¹⁴为例，它有若干控制字符和可显示字符，每个字符都有一个编码，如图 1.1 所示。读者无需记忆本图，只需知道它是一套编码系统即可。通过 ASCII，每个拉丁字母都能编码成一个整数，比如字符'0' 对应着编码 48，字符'A' 对应着编码 65，字符'a' 对应着编码 97。

这套字符编码只适用于现代拉丁字母。如果要表示其它语言（比如中文）的字符，就需要用更复杂的编码规则。我们会在精讲篇中细细道来。

¹¹广义地讲，实体书、绘画、雕塑等等也是数据。但这些已经远远超出了我们的讨论范围。

¹²容量是与内存空间有关的。如果某个类型占用的字节数为 2，那么它只能表示 $256^2 = 65536$ 个不同的整数。因此它无法表示十万以上的数据，我们需要用更宽的类型来表示。

¹³值得注意的是，浮点类型的数据都有精度限制，不能准确表示有效数字过多的数据。正因如此，浮点类型不适合用来表示和计算特别大的整数；这时应当使用整型。

¹⁴美国信息标准交换代码 (American Standard Code for Information Interchange, ASCII)，是一套基于拉丁字母的编码系统，主要用于显示现代英语。

b ₇	b ₆	b ₅	b ₄	b ₃	b ₂	b ₁	Column →	0	0	0	0	1	0	1	0	1	1	1
B	i	t	s				Row ↓	0	1	2	3	4	5	6	7			
0	0	0	0	0	0	0	NUL	DLE	SP	0	@	P	`	p				
0	0	0	0	1	1	1	SOH	DC1	!	1	A	Q	a	q				
0	0	1	0	2	2	2	STX	DC2	"	2	B	R	b	r				
0	0	1	1	3	3	3	ETX	DC3	#	3	C	S	c	s				
0	1	0	0	4	4	4	EOT	DC4	\$	4	D	T	d	t				
0	1	0	1	5	5	5	ENQ	NAK	%	5	E	U	e	u				
0	1	1	0	6	6	6	ACK	SYN	&	6	F	V	f	v				
0	1	1	1	7	7	7	BEL	ETB	'	7	G	W	g	w				
1	0	0	0	8	8	8	BS	CAN	(8	H	X	h	x				
1	0	0	1	9	9	9	HT	EM)	9	I	Y	i	y				
1	0	1	0	10	10	10	LF	SUB	*	:	J	Z	j	z				
1	0	1	1	11	11	11	VT	ESC	+	;	K	[k	{				
1	1	0	0	12	12	12	FF	FS	,	<	L	\	l	l				
1	1	0	1	13	13	13	CR	GS	—	=	M]	m	}				
1	1	1	0	14	14	14	SO	RS	.	>	N	^	n	~				
1	1	1	1	15	15	15	SI	US	/	?	O	—	o	DEL				

图 1.2: 一个 ASCII 码表

图片来源：维基共享资源

1.3 数据的定义和使用

前一节我们介绍了三种数据类型：整型、浮点型和字符型。这一节让我们回到代码中来，看看如何定义一个数据，又如何使用它。

C++ 中有一些关键字，用特定的关键字就可以定义特定类型的数据，比如

```
#include <iostream>
using namespace std;
int main(){
    int i = -1; // 定义一个 int 整型数据，并初始化为 -1
    double d = 3.14159; // 定义一个 double 浮点型数据，并初始化为 3.14159
    char c = '0'; // 定义一个 char 字符型数据，并初始化为 '0'，其 ASCII 码为 48
    return 0;
}
```

这三个语句的结构非常相似，我们可以把它们归纳成一个统一的形式：

```
<类型关键字> <名字> = <值>;
```

接下来我们分别介绍这三个部分。

类型关键字（Keyword）

C++ 为不同类型提供了丰富的关键字。

对于整型来说，**int** 是最基本的关键字。我们可以通过增加前缀的方式来将 **int** 型改为其它整型。

- 改变符号性：我们可以增加 **signed**（有符号）前缀，允许它表示负数；或者增加 **unsigned**（无符号）前缀，禁止它表示负数。如果不加前缀，将默认允许表示负数。因此，如果没有禁止负数的需要，无需加前缀 **unsigned**。

- 改变“容量”：我们可以增加 `short`, `long` 或者 `long long` 前缀来改变它的容量。简便起见，如果有这三个前缀之一，可以直接省略 `int`。因此，我们可以直接用 `long long` 这样的关键字而不必用 `long long int`。

无论改变符号性还是改变容量，其目的都在于让我们的数据合乎需求。如果我们要统计某物的数量，那么这个数字肯定是非负的，于是我们可以用 `unsigned` 来限制它的取值范围；如果某物的数量可能很多，`int` 类型的容量存不下，那么我们就要考虑使用 `long long` 了。

对于浮点型来说，`double` 是最常用的关键字。另有 `float` 和 `long double`，它们的有效位数和容量也不同。简单来说，`float` 的有效位数和容量最少，`double` 居中，`long double` 最多。浮点型数据无法改变符号性，它们必须允许负数的表示。

对于字符型来说，`char` 是最常用的关键字¹⁵，它能表示 ASCII 的所有字符，但对非拉丁字母（比如中日韩文字及变体）无能为力。为了表示非拉丁字母，我们可以使用 `wchar_t` 类型。

其实我们在实际编程时最常使用的关键字是 `int`, `double`, `char`。而其它的关键字，如 `unsigned` 或 `long double` 往往是我们有特殊需求时才会去考虑使用的。简便起见，我们在这一章只使用这三种基本类型。它们足够应付我们的需要了。

标识符（名字）(Identifier)

在定义数据时，我们需要给它一个名字，以便日后使用。这个名字就是一种标识符。

在 C++ 中，标识符指代的概念甚广，包含一切关键字，以及我们定义的所有名字。在遵守下述要求的前提下，我们可以起各种千奇百怪的名字：

1. 一个标识符只能由英文字母 A-Z 和 a-z、数字 0-9 以及下划线 `_` 构成。¹⁶
2. 标识符的首字母不能是数字，但可以是字母和下划线。¹⁷
3. 标识符对大小写敏感。这意味着，即便两个标识符只有大小写上的区别，它们也是不相同的。
4. C++ 中的关键字均被保护¹⁸，你不能定义一个与关键字相同的名字。
5. 标识符的长度可能受到系统或开发环境的限制，不能太长。¹⁹

比如我在上述代码中起了三个名字：`i`, `d`, `c`，这些名字都是允许的。

不只是数据名。以后我们可能需要起函数名、结构名和类名，这些命名方式全部应该按照这样的标准来起名。举几个例子：“`lhs`”, “`it_1`” 和 “`__max`” 都是可以使用的名字，而 “`12a`”, “张三” 和 “`new`” 都是不能使用的名字（`new` 是 C++ 中的关键字）。

初始化 (Initialization)

一个数据存储一个值。整型数据存储整数值，浮点型数据存储小数值，字符型数据存储字符值（对于 `char` 型来说，它存储的值可以用对应的 ASCII 码值来表示。）如果你不为它指定一个值的话，它就会存储一个不确定的值²⁰。使用“不确定的值”是危险的，我们要尽量避免。

初始化是一种“在定义的同时就给定值”的方法。在本例中，我们使用=加一个值的形式来实现初始化。

¹⁵C++ 还规定了两个类型：`signed char` 和 `unsigned char`。请注意，它们和 `char` 是三种互不相同的类型。这一点与 `int` 等于 `signed int` 的情况截然不同。读者尚无必要纠结其中细节，精讲篇会予以介绍。

¹⁶这是不完全的，实际上还可以用其它具有 XID_Continue 属性的字符。本书无意在这个问题上走得太远，也不打算使用这种字符来作为标识符。感兴趣的读者可以参阅[Properties for Lexical Classes for Identifiers-Unicode Technical Reports](#) 获取更多信息。

¹⁷有一类特殊的反例，参见[用户定义字面量-cppreference](#)。这种情况不在我们的讨论范围之内。

¹⁸许多代码编辑器会对关键字做特殊着色处理。本书将关键字一律以蓝色加粗来标明（偶有不宜着色者除外）。

¹⁹C++ 标准并未对标识符的长度作明确规定，实际编程中也几乎不会有长度超限的情况，所以本条不那么重要。

²⁰严格说来，只有局部变量才会如此。全局变量如果不加指定，将会自动初始化为零。

```
unsigned long long ull = 4294967296;
// 定义一个 unsigned long long 整型数据，并初始化为 4294967296
long double ld = 3.141592653590;
// 定义一个 long double 浮点型数据，并初始化为 3.141592653590
```

以上初始化语法也叫作直接初始化（**Direct Initialization**）。

初始化的语法不只这一种。在 C++11 以后的语言标准中，我更推荐使用统一初始化（**Uniform Initialization**）的方法：

```
<类型关键字> <名字> = {值}; // 统一初始化语法
<类型关键字> <名字> {值}; // 另一种统一初始化语法
```

统一初始化的语法更强大，在进行初始化时会进行检测，避免范围缩限等问题。

举个例子，某台电脑的 **short** 型变量只能容纳-32768 到 32767（包含两端）之间的整数²¹。那么这样的代码是可以通过编译并且运行的：

```
short s1 = 40000; // 定义 s1 并直接初始化为 40000
cout << s1; // 输出 s1 的值
```

这个输出的结果可能是 -25536。同时，有些编译器还可能给出如下警告信息：

```
warning: overflow in conversion from ‘int’ to ‘short int’ changes value
from ‘40000’ to ‘-25536’ [-Woverflow]
```

在这里，给一个不能容纳 40000 的数据存 40000 的数值本来就是违规操作。警告信息（Warning）虽然只是一个提醒，但仍然不会阻止你运行这个程序并得到错误结果，更遑论一些老旧编译器甚至不会给你警告信息。统一初始化则不然，它会直接以报告错误（Error）的方式阻止你运行程序，你必须改正这个违规操作才行。

```
short s2 = {40000}; // 定义 s2 并统一初始化为 40000，这种方法是禁止的。
```

统一初始化还有许多其它的优点，这也是我推荐使用统一初始化的理由。

实操：让编译器充当计算器

有了数据之后，我们可以拿它们来做一些简单的计算了。我们希望定义一些数据，让它们进行简单的四则运算。我们在开始动工之前，需要粗略规划一下我们要做的事情。我们的大致步骤是：

1. 定义几个数据，并初始化。考虑到我们可能会计算小数，我们应该用浮点型的 **double** 类型。
2. 把我们想算的式子写到代码的输出语句中。比如说，我想计算 $(a+b*c)/d$ ，那么我应该把 `cout <<` 后面改成我想输出的这个式子。
3. 编译、运行，看下输出的结果。

现在我们完成第一步，定义数据。从我们的式子中可以看出，这里需要 4 个浮点型变量，那么我就定义 4 个浮点型变量。同时我还需要给出 4 个初始值。

```
double a = {1.5};
double b = {0.3};
double c {0.5}; // 这也是一种统一初始化语法，省略了 =
double d {4.5};
```

²¹这个范围可能因电脑而异，如果读者要自己尝试，应以自己电脑的实际情况为准。

其实 C++ 还支持另一种简便的语法。如果要定义的量是同类型的，那么我们可以用单个类型关键字，将变量名隔开来定义。

```
double a {1.5}, b {0.3}, c {0.5}, d {4.5}; // 定义并初始化
```

注意，句末用的是分号，而句中用的是逗号。这样就不用写 4 次 `double` 了，省时省力。

接下来是第二步，我们改一下输出代码，让它输出我们需要的内容。

```
cout << (a + b * c) / d; // 输出 (a+b*c)/d 的值
```

这段代码不能单独存在，现在让我们“借鉴”一下 `Hello_World.cpp` 的代码，把它改成这样：

代码 1.2: `calc.cpp`

```
// 这是一个简单的C++程序，用于简易的数值计算
#include <iostream> // 标准输入输出头文件
using namespace std; // 使用 std 命名空间
int main(){ // 主函数，程序执行始于此
    double a {1.5}, b {0.3}, c {0.5}, d {4.5}; // 定义并初始化
    cout << (a + b * c) / d; // 输出 (a+b*c)/d 的值
    return 0;
}
```

最后的输出结果是一个近似值 `0.366667`，与实际计算器算出的结果相近。

你还可以修改代码中的初始值，或者是把输出的式子改成别的式子，观察一下结果。

1.4 运算符与类型

在上一节的末尾，我们实现了一个简单的基于浮点数的计算器。这一节我想走得更远，增加一些数据类型和新的运算，看看会不会有什么新变化。

整数的模运算

模运算 (Modulo)，俗称取余，简记为 `mod`，就是求两个数相除得到的余数。例如， $5 \div 2 = 2 \dots 1$ ，这里的余数就是 1，所以 $5 \bmod 2 = 1$ ；再例如， $9 \div 3 = 3 \dots 0$ ，这里的余数就是 0，所以 $9 \bmod 3 = 0$ 。

一般意义上讲，只有整数才有带余除法，所以我们在计算时应该使用整型，比如 `int`。如果要计算某两个数 `a` 与 `b` 的模值，我们可以用如下的代码来实现：

```
int a {1584}, b {7}; // 定义 a, b 并初始化
cout << a % b; // 求 a mod b 的值
```

这里使用的百分号（%）可能会让人费解。其实在 C++ 中，% 并不是百分号，而是取模运算符，含义是左边整数除以右边整数得到的余数（模值）。在各类编程语言中，这种“记号含义与传统含义不同”的现象比比皆是，以下是 C++ 当中的部分例子（读者无需现在就掌握，但日后要留心）：

- `^` 不是幂指数的含义，而是位异或运算。²²
- `<<` 和 `>>` 既不是书名号，也不是数学意义上的“远小于”和“远大于”，而是移位运算符。
- `[]` 和 `{}` 不是数学上的“中括号”和“大括号”，它们分别有另外的含义。数学意义上的括号统一使用 `()` 嵌套来实现。
- `=` 是赋值运算符，而传统意义上相等性的判断应当用 `==`。

²²关于位异或和移位运算符，参见附录 C.2 布尔代数基础。

-

要计算 `1584%7` 的值，也可以跳过定义数据这一步，直接在输出语句中使用字面量²³完成。

```
cout << 1584 % 7; // 直接求 1584 mod 7, 不必定义a和b
```

这种写法更加简便、直观，不需要定义数据。但也请注意，它无法支持程序层面的交互（如，用户输入两个数并计算。我们总不能要求用户来亲自修改代码。关于程序输入，我们会在第二章介绍）。

字面量的类型

C++ 会自动识别字面量的类型，比如前面介绍过的这个例子（编译器的报错信息以注释形式附于其后）：

```
short s2 = {40000};  
//error: narrowing conversion of '40000' from 'int'  
//to 'short int' [-Wnarrowing]
```

编译器的报错信息是很重要的，它能把出错的关键信息告诉我们，帮助我们有针对性地查找和解决问题。这个报错信息是“40000 在从 `int` 到 `short int` 的过程中发生了收缩转换”，意思就是“原本 40000 是 `int` 类型的，完全装得下；但是你要往 `short` 里面塞，那就装不下了”。

于是从报错信息中我们能看出，40000 这个值被编译器识别成 `int` 型。

再来个类似的例子：

```
int i {2147483648};  
//error: narrowing conversion of '2147483648' from 'long long int'  
//to 'int' [-Wnarrowing]
```

这个报错信息是“2147483648 在从 `long long int`²⁴ 到 `int` 的过程中发生了收缩转换”，意思就是“原本的 `long long` 类型完全装得下，但是 `int` 类型装不下”。换言之，字面量 2147483648 被编译器识别成了 `long long` 型。

总得说来，如无前缀或后缀²⁵，代码中的浮点字面量统一识别成 `double` 型。代码中的整数字面量会按照 `int`, `long`, `long long` 的顺序，找到能容纳它的类型，作为这个字面量的类型；而字符串面量会把 ASCII 字符统一识别成 `char` 型²⁶。

字面量的实际知识远比我们介绍的要多。如果读者有意进一步了解相关知识，可以查阅[字面量-表达式-cppreference](#)。

1 和 1.0 的区别是什么？

我们在写代码时常常会遇到 `1.0` 这样的写法。你可能会好奇，为什么不写成 `1` 呢？究其原因，在于 `1.0` 是一个浮点字面量，而 `1` 则是一个整数字面量。它们的类型并不相同，一个是 `double`，另一个则是 `int`。

C++ 中还有更简洁的语法，就是用 `1.` 和 `.1` 来取代 `1.0` 和 `0.1` 这样的浮点字面量。比如说

```
cout << 1. / .1; // 等价于 cout << 1.0 / 0.1;
```

²³字面量 (Literal)，是一个值在代码中不具名的文本表示。比如 `1584`，它没有“名字”，在代码中被写出来就是 `1584`，它的值也是 `1584`。与之相对的是具名数据，它们经过定义，就有了名字。

²⁴这点可能因电脑的环境而异，比如有些电脑的 `long` 类型就可以容纳这个数，那么报错信息应当是 `long int`；而另一些则不能容纳这个数，报错信息应当是 `long long int`。

²⁵字面量可加前缀或后缀来指定优先使用的类型，第二章会对此进行介绍。

²⁶关于宽字符，我们会在精讲篇中再谈。

整数除法问题

让我们来看一下这段代码：

```
cout << 8 / 3; // 计算 8/3 的值
```

猜一下它的运行结果。如果你手头有编译条件，可以跑一下代码看看（记得加上那一堆必需代码）。

如果你猜的结果是 2.66667 或者是类似的近似结果，那么恭喜你，这是初学者常犯的错误！

整数除法与浮点数除法有所不同。如果两数不能整除，那么结果就会被“截尾”²⁷。如果要避免截尾，获得较精确的数据，应该使用符点型来操作。

```
cout << 8. / 3.; // 计算 8.0/3.0 的值
```

那如果我要计算两个具名整型数据的除法呢？比如在 a 和 b 都是整型的情况下计算 a/b？这时我们可以使用第二章中将会介绍的类型转换的方法。

这里有一种比较简单的类型转换方法：

```
cout << 1. * a / b; // 计算 a/b 的浮点数结果
```

但是请注意，下面的写法是不行的：

```
cout << a / b * 1.; // 计算 a/b 的浮点数结果，但事与愿违
```

关于第一种方法为什么可行，第二种为什么不可行，我们会在第二章中探讨。

总而言之，类型不同，可能会让结果出现一些意想不到的差异。因此类型是很重要的数据特征，日后编程时我们需要多加留意。

1.5 `sizeof` 与内存空间

我们在之前总是反复提及，整型与整型之间是不同的，浮点型与浮点型之间也是不同的。对于整型来说，有符号与无符号是一个区别，而“容量”是另一个区别。如何理解这里的“容量”呢？这就需要我们深入到“内存”中去，一探究竟。

什么是内存？

张三正在用电脑打单机游戏，这时突然停电了。好不容易等到来电，张三心急如焚地打开电脑，刚准备继续玩，突然发现自己忘了存档，当前游戏进度还是昨天的进度。这让他非常不爽。

那么问题来了，明明确程序中都有我们当前游戏的进度，为什么我们还要通过“存档”来把这些内容保存下来呢？这就涉及到内存和外存的区别了。

非易失型存储器 (Non-Volatile Memory, NVM)，俗称外存，这种存储器内的信息不会随着电脑关机、供电中断等因素而丢失。但是，外存信息的访问速度慢，可能导致程序运行卡顿。张三的游戏存档就储存在外存当中。

易失型存储器 (Volatile Memory, VM)，俗称内存，这种存储器内的信息会随着电脑关机、供电中断等因素消失。不过，内存信息的访问速度更快，程序运行更加流畅，所以计算机程序主要都是在内存当中运行的，偶尔才会与外存进行数据交换。在张三打游戏的过程中，游戏数据就存储于内存当中，只有通过存档才能把信息保存至外存。

正因如此，张三今天的游戏数据（储存于内存）丢失了，但昨天的存档（储存于外存）依然健在。

同样，我们写出来的程序在运行时也会在内存当中运转。我们定义的数据，也都保存在内存当中。

²⁷ 截尾 (Truncation)，广义上指对小数点后数字个数的限制。在这里指的是直接截掉小数点后的部分，比如 1.618 → 1 和 -2.718 → -2。这种方法与四舍五入和单纯上/下取整都不同，可以把它理解成“对正数向下取整，对负数向上取整”。

内存如何存储数据？

存储器的内部结构很像是一大群排列紧密、有序的房屋，彼此都是相同的模样。每个房屋有 8 个同款的房间，每个房间都存储着 0 或 1，看上去单调而乏味，了无新意。但就是这种看似无趣的 0 和 1 的排列组合，却构成了我们眼里丰富多彩的信息。一部时长一百分钟的高清电影，大小 7.07GB，换算过来是 76 亿个这样的房屋，由 607 亿个这样的 0 和 1 的排列组合而成。²⁸

前文提到，我们可以用编码的方式来将多样的信息转换成 10 种阿拉伯数字的排列组合，又可以通过解码的方式将这些数据转换回去。而在存储器中，多样的信息都会被编码成 0 和 1 的排列组合。我们把每一位这样的 0 或 1 称为一个比特（Binary digit, bit）。

比特，如同生命中的细胞，化学中的原子，建成大厦的砖块和社会中的每个人，是构成信息最基本、最微小的单元。无数细胞构成了绚丽多彩的生命，无数原子构成了气象万千的世界，而无数比特则构成了我们眼中目不暇接的信息。

不过，存储器中是不允许“单细胞生物”或者“单原子分子”存在的。在存储器中，每 8 个比特构成一个字节（Byte）²⁹。字节是度量信息的单位，也是可寻址³⁰的最小单元。

回到我们刚才的比喻。存储器的内部结构是排列有序的房屋。每个房屋代表一个字节，它是相对独立的最小可寻址单元。而每个房屋有 8 个房间，各自存储一比特的信息。图 1.3 可以帮助我们更直观地理解这种关系。

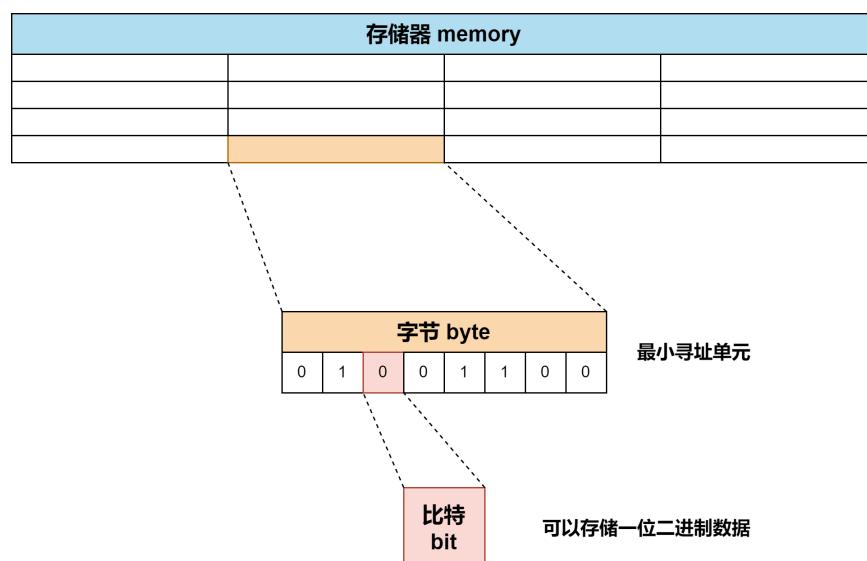


图 1.3: 存储器、字节与比特

信息与容量

香农³¹是最早把“比特”的概念引入到信息技术中的人。在论文³²的第一页，他就提出：N 个比特可以表示 2^N 种状态。³³

²⁸严格说来，这部电影存储于外存。但内存与外存都有这样的特征，所以借来阐述并不为过。

²⁹历史上，每个字节包含多少个比特没有特定标准，因而在一定时期是混乱的。如今的标准规定每个字节包含八个比特，但可能有极少数例外。

³⁰关于内存地址，我们会在第五章讲解。

³¹克劳德·艾尔伍德·香农（Claude Elwood Shannon），美国数学家、电子工程师、计算机科学家和密码学家，被誉为“信息论之父”。

³²A Mathematical Theory of Communication, 于 1948 年发表于《贝尔实验室技术期刊》。这篇论文奠定了现代信息论的基础，被《科学美国人》誉为“信息时代的《大宪章》”。

³³原文：A device with two stable positions, such as a relay or a flip-flop circuit, can store one bit of information. N such devices can store N bits, since the total number of possible states is 2^N and $\log_2 2^N = N$.

我们可以把一个数据的值看作一个状态（State）。当这个数据是 20 的时候，它的状态就是 20；当这个数据的值是 13 的时候，它的状态就发生了改变，变为 13。可以试想，如果我们有 1 个字节的数据，那么这 8 个比特一共可以表示的状态数量就是 $2^8 = 256$ 个。换言之，它只能表示最多 256 种状态，也就只能编码 256 种信息。

C/C++ 中的 `char` 数据占用的内存空间是一个字节，所以它能表示 256 种信息。而 ASCII 码只有 128 种信息，所以用一个 `char` 足够表示一个 ASCII 字符。假如我们定义了一个 `char` 数据并初始化为 '`A`'，那么它在内存中的 8 个比特就有了某个特定的排布方式（假设排布方式是 `0100 0001`）。下一次，我给它另一个值，比如 '`Z`'。改变了它的值，也就改变了它的状态，于是这 8 个比特的排布方式也就改变了（假设排布方式改为了 `0101 1010`）。但是无论怎么修改它的值，这 8 个比特的信息永远都在 256 种可能性中打转，绝对不会出现第 257 种排布方式。于是我们可以说，它的“容量”就是 256。

在大多数电脑上，`int` 类型的数据占用的内存空间是 4 字节³⁴，也即 32 比特，所以它能表示 $2^{32} = 4'294'967'296$ 种状态。所有这些状态被用来给数字编码。对于 `int` 类型来说，它可以表示从 $-2^{147'483'648}$ 到 $2^{147'483'647}$ 的全部整数（含两端）；而 `unsigned` 类型可以表示从 0 到 $4'294'967'295$ 的全部整数（含两端）。于是我们可以说，它的“容量”就是 $4'294'967'296$ 。

值得注意的是，虽然 `signed int`（亦即 `int`）和 `unsigned int`（亦即 `unsigned`）占用的内存空间大小相等，但它们能表示的数据范围是不相同的！这是一个“我们能够编码多少数据”和“我们编码了什么数据”的问题。对于 `int` 和 `unsigned` 来说，它们都只能编码 $4'294'967'296$ 个数据，但因为它们编码的数据不尽相同，于是它们能表示的数据范围也就有所差异（但数据宽围的“宽度”是相等的）。我们会在精讲篇中更细致地谈论这个问题。

那么如果你想要表示比 $4'294'967'295$ 还要大的数字呢？我们就要选择能容纳它的类型，比如 `long`³⁵ 或者 `long long`，甚至是 `unsigned long long`。总得说来，占据内存空间越多的类型，它能表示的数据范围也就越宽。

`sizeof` 运算符

在不同的电脑上，同一数据类型可能占据的字节数并不相同，这就给我们造成了困扰。如何知道自己电脑上每个类型占据多少内存空间呢？我们可以用 `sizeof` 运算符来搞定这个问题。

`sizeof` 是一个单目运算符³⁶，可以接收一个类型或数据信息，并求出其内存占用。它的语法是

```
sizeof (<类型或数据>); // 对类型求 size 必须套括号
sizeof <数据>; // 如果只对单个数据求 size，可以不套括号
```

这只是单纯的求值。如果要输出我们求出来的值，我们就需要在前面加上 `cout <<`。

```
cout << sizeof (char); // 求 char 类型的内存占用
```

这样它就会输出 `char` 类型的内存空间大小。这个值在任何电脑上都是 1。

我们还可以让它求出某个数据的内存空间占用，比如

```
cout << sizeof 2.71828; // 求双精度浮点数 2.71828 的内存占用
```

在 Coliru 上，它的输出结果是 8。

还可以输出我们定义的数据的内存空间大小，比如

```
unsigned long long ull = {10}; // 定义一个 unsigned long long 数据并初始化为 10
cout << sizeof (ull); // 求 ull 的内存占用，可以不加括号
```

在 Coliru 上，它的输出结果是 8。

³⁴C++ 标准规定，`int` 类型的最低内存占用为 2 字节（16 比特），但现在的大多数电脑都使用 4 字节。

³⁵在很多电脑上，`long` 类型和 `int` 类型一样占据 4 字节空间，这时就不能用 `long`。

³⁶有关运算符的问题，我们将在第二章讲解。

编译时行为与运行时行为

`sizeof`也是一个运算符。不过它与我们之前见到的加减乘除和模运算不同，它不是在程序运行时进行计算的，而是早在编译时就已经计算好了的。

我们在第 1 节中讲过，从写完代码到运行程序可以粗略分为三个过程：编译、链接和运行。有些值在编译的时候就能确定下来，比如 `sizeof (a)`，无论它在内存中处于什么位置，也无论它的值是多少，它占据的内存空间的大小永远相同。（还记得吗，无论数据怎么变化，本质上只是若干个比特的排布方式发生了改变，但这个数据仍然占据同样尺寸的内存空间）

所以 `sizeof` 在编译时就已经计算出来了，运行时就无需再浪费时间去计算 `sizeof`；而四则运算和取模，它们必须要在运行时才能确定结果，所以编译时不会进行计算。

C++11 标准引入了 `constexpr` 语法，它扩展了编译时行为的范围。比如说

```
int a = {3}, b = {5};
int c = {a+b}; //a+b在运行时计算
```

假如使用 `constexpr` 呢？

```
constexpr int a {3}, b {5};
constexpr int c {a+b}; //a和b都是constexpr，所以a+b将在编译时计算
```

这说明，`constexpr` 改变了编译器处理数据的方式，使得一些数据可以在编译时就被计算出来。

本章只对编译时行为、运行时行为和 `constexpr` 作简要介绍，在精讲篇中我们还会深入讲解。

1.6 类与对象

C++ 语言脱胎于 C 语言。斯特劳斯特鲁普³⁷最初选择了 C 语言，首先在 C 的基础上发展出了 C with Classes。后来 C++ 不断扩容并增加新功能，直至 C++98 标准发布，C++ 语言的基本功能已经成形。之后的 C++11 又是一个划时代的更新，不过这些就离我现在想要谈的事情比较远了。

迈耶斯³⁸在他的著作《Effective C++》中，将 C++ 语言视为四种“子语言”的统合体³⁹：

- **C**: 这是脱胎于 C 语言的部分，它继承和发展了 C 语言中的部分功能。所以当有人问起“如果没学过 C 语言，是不是要先学 C 再学 C++”的时候，我们的回答都是“不必如此”！在 C++ 的起步阶段中你学习的内容已经基本涵盖 C 语言了。
- **面向对象的 C**: 这里有了比 C 语言中 `struct` 丰富得多的功能，它也是 C with Classes 最初区别于 C 的特征。
- **泛型 C**: 这里提供了泛型编程和元编程的支持，使 C++ 成为一门更为强大的语言。它们是 C++ 与 C with Classes 的重要区别之一。
- **标准模版库 (STL)**: STL 由斯捷潘诺夫⁴⁰设计实现。相比于单纯的泛型编程，它有一套相对独立的逻辑。STL 更多地支持对“现成”数据结构和算法的使用，其优点是方便、高效、简洁。

这些内容都会在本书的泛讲篇或精讲篇有所涉及。但本书并非进阶教程，读者若有意深入挖掘，还应选择合适的进阶教材阅读。

³⁷比雅尼·斯特劳斯特鲁普 (Bjarne Stroustrup)，丹麦计算机科学家。他发明并发展了 C++ 语言，以其对 C++ 语言的卓著贡献而享誉世界。如果读者有意了解关于他和 C++ 的更多信息，可以访问[Stroustrup 的个人主页](#)。

³⁸斯科特·道格拉斯·迈耶斯 (Scott Douglas Meyers)，美国作家、软件顾问和 C++ 语言程序设计专家，以其所著 *Effective C++* 系列书而闻名。

³⁹这只是迈耶斯的观点，笔者认为其合理而采纳至此。不同的专家可能对此有不同的理解。

⁴⁰亚历山大·亚历山德罗维奇·斯捷潘诺夫 (Alexander Alexandrovich Stepanov)，俄罗斯裔美国计算机科学家，以其提倡泛型编程与设计实现了 C++ 语言中的标准模版库而闻名。

从 C++ 的发展史来看，面向对象编程（Object-oriented programming, OOP）是 C++ 相对于 C 跨出的第一步。面向对象的概念广泛用于 C++ 的语法中，以至于我们往往习焉不察。

我本来不打算在第一章就介绍面向对象的概念，但我很快就发现那很难。如果不了解什么是面向对象，也不清楚相关的基本概念，后面几章的知识依然都能学（别忘了，C 语言可没有面向对象，那些 C 有关的语法也都不依托这方面的知识）；然而，这会在“C”部分与“面向对象的 C”部分的过渡处造成很大的障碍（尤其对于初学者来说）。正如迈耶斯所说，它们几乎是两个子语言，为此你需要一定的适应期，并且回顾很多以往的知识，才能真正理解它。

出于上述考虑，我决定在第一章就介绍面向对象，并且在后面的章节中也会时常提起它（甚至把它和一部分 C 内容串讲）。我希望通过这种方式，读者能够真正把“一门语言”学成“一门语言”，而不是“四门语言”——如果可以的话，这也是我对本书的一点期许。

什么是类？什么是对象？

类与对象是一对概念，不得不并举。

类（Class）是一个抽象的概念，它规定它的所有对象都有一些属性和功能。而对象（Object）⁴¹则是一个个具体的实现。举例来说，“哈士奇”是一个抽象的概念（类），它规定了其对象的一些属性，比如“身高”、“体重”，还有其对象的一些功能，比如“拆家”。而“我家的哈士奇”和“张三家的哈士奇”是两个实体（对象），它们衍生自“哈士奇”这个概念。

同一个类的不同对象都有这些属性，但属性的具体值是因对象而异的。我家的哈士奇的体重是 27 公斤，而张三家哈士奇的体重是 20 公斤。属性不同，会导致它们在运行一些功能时有不同的表现。比如，有个沙发的承重是 25 公斤，那么我家哈士奇拆沙发的效率当然就要好于张三家的哈士奇。

我们经常容易把类与对象的关系和另外两组关系搞混。所以不妨让我们来做一下辨析：

- “狗”与“哈士奇”的关系不是类与对象关系。它们两个都是抽象的概念，只不过“哈士奇”在“狗”的基础上进一步细化了属性和功能。比如说，“拆家”不是所有狗的特征，它不是“狗”的功能；而“哈士奇”在“狗”这个概念的基础上增加了“拆家”的功能。然而说到底，“哈士奇”依然是一个概念，而非实体。⁴²
- “猫”与“我家哈士奇”的关系不是类与对象关系。“猫”的确是一个类，“我家哈士奇”也的确是一个对象，但它们完全八竿子打不着。我家哈士奇根本就不是猫。
- “张三”与“张三的心脏”的关系不是类与对象关系。“张三”确实是由各个器官构成的，然而张三是一个实体，它们之间的关系应当是整体与部分，而不是类与对象。
- “人”与“张三的心脏”的关系也不是类与对象关系。我们不能说“张三的心脏”就是一个人。
- “人”与“张三”的关系是类与对象关系。张三是一个人。

可以看出，类与对象的关系可以用“a 是一个 A”的语句来检验和阐述，比如：秦始皇是一个皇帝；上海是一座城市；银河系是一个“有生命存在的星系”。

C++ 中的类与对象

面向对象的概念并非 C++ 独有；不过本书只介绍 C++ 中的面向对象。

在 C++ 中，类型（Type）和类（Class）很多时候是等价概念。⁴³假设我定义了一个 int 型数据 i，那么它们两者之间的关系是不是类与对象呢？

⁴¹“对象”这个译名容易引起困惑；相比之下，英文原名 object 和台湾译名“物件”就显得易懂些。

⁴²在第九章中我们会讲到，这是两个类的继承关系。

⁴³在泛型编程中，我们一般将其视为等价概念，使用 typename 和 class 关键字的效果是相同的。不过，在另一些语境下，class 是比 type 更为广泛的概念。

我们可以用“a 是一个 A”的语句来检验这个关系。就像我们反复强调的那样，i 是一个 int 型的数据，于是“i 是一个 int”的判断成立，它们是类与对象的关系。

我们可以在同一个类之下定义很多对象。

```
double a {1.1}, b {2.2}, c {3.3}; // 在 double 类之下定义三个对象 a,b,c
```

这里的 **double** 就是一个抽象的概念，而 a, b, c 就是这一概念下创造出来的实体。

C++ 中还有一个更好的例子，就是我们一直在用但是还没有讲的 cout。这是一个 ostream 类的外部对象⁴⁴。ostream 类重载了 << 运算符⁴⁵，使得我们可以方便地输出很多基本类型的对象的值。

ostream 只是一个类，它提供了诸多输出方面的功能支持，但是倘若没有一个实体，这些功能都是空中楼阁，无从实现。为此，C++ 在 std 命名空间中定义了 cout 作为标准输出对象，所以我们才可以使用这个对象来实现基本类型值的输出。

```
namespace std{
    extern std::ostream cout;
}
```

这个对象定义在头文件 iostream 中，所以我们必须要在每个完整的程序代码之前加上

```
#include <iostream> // 包含头文件 iostream
```

方可使用它。

C++ 还定义了标准输入 cin，也在头文件 iostream 当中。我们会在下一节中使用它。

⁴⁴关于外部对象等概念，我们将在第七章中介绍。

⁴⁵关于运算符重载，我们将在第八章中介绍。

第二章 数据的基本操作

在第一章，我们通过一些简单的代码，对 C++ 语言有了最基本的认识。我们还了解了数据、信息、内存和面向对象的相关常识。在后面的章节中，我们将更多关注于具体的知识。

本章我们先来介绍数据。按照分类标准的不同，我们可以把 C++ 语言中的数据分成不同的类别：

- 如果按照数据的类型来分类，数据可以分为整型数据、浮点型数据等等。
- 如果按照是否具名来分类，数据可以分为不具名量¹ 和变量。前者没有名字，后者有名字。
- 如果按照是否可以改变来分类，数据可以分为常量和可变量。前者不可改变，后者可以改变。
- 如果按照是否可取地址来分类，数据可以分为左值和右值。²
-

光是分类还不够。我们还要学会如何更好地使用数据。在第一章中我们通过简单的代码实现了计算器的功能，但如果我们仅仅止步于此，那还远远没有达到 C++ 能够支持的水平。在这一章我们会学习更多有关运算符的知识，以此扩展代码的可能性。

数据类型的差异可能会为我们造成一些困扰。在实际编程时，我们可能需要在不同数据类型之间作转换。本章我们也会谈及数据类型转换的基础语法。

C++ 的世界非常丰富，但一切都要从数据开始。

2.1 赋值语句与常量

在此之前我们定义了许多数据，但是只进行了初始化，并未在定义之后修改过它们的值。实际上我们之前定义过的那些数据（它们也被称为变量（Variable））都可以通过赋值、输入、运算等方式来修改其值。这里先来讲一下赋值语句，然后是常量；输入和运算将在之后讲解。

基本赋值语句

最基本的赋值语句的结构是这样的：

```
<变量名> = <值>; //用字面量为其赋值  
<变量名> = <表达式>; //用其它数据或表达式为其赋值
```

如果你愿意，也可以将初始化看作一个赋值过程³：但我绝不会这样讲。

在基本赋值语句中出现的 = 叫做赋值运算符（Assignment operator），它的含义是：将右边的数的值赋给左边，从而改变左边的值。

¹我们先前提及的“字面量”正是不具名量的一种。

²有关左值和右值的问题，我们在精讲篇中讲解。

³对于内置类型，我们看不出细节来；但对于自定义类型来说，初始化和赋值是不同的。初始化时会调用构造函数，而赋值时会调用赋值运算符。我们在第八章中会细讲。

赋值运算符的用途很广泛，C++ 中的许多数值改变都要通过赋值来实现。以下是一些常见的例子：

```
int n = {3}; // 定义n并初始化为3
n = n * n; // 这是在做什么？
cout << n; // 输出会是什么样的？
```

初学者可能会对 $n = n \times n$ 这样的表达感到困惑。但是不要忘记，这里是编程，而不是数学！

$n=n*n$ 这个语句可以由赋值运算符分为两部分，左边是 n ，右边是 $n*n$ 。按照赋值运算符的含义，它的功能是将右边的数的值 ($n*n$) 赋给左边，从而改变左边数 (n) 的值。也就是说，它的含义是在把 n^2 的值赋给 n ，于是输出就变成了 9。

赋值运算符和数学上的等号⁴不同的地方还在于，它是不满足交换律的。比如说， $a=b$ 的含义是把 b 的值赋给 a ，而 $b=a$ 的含义是把 a 的值赋给 b 。再比如，如果我们把刚才的代码改成这样，它是不能通过编译的：

```
int n = {3}; // 定义n并初始化为3
n * n = n;
//error: lvalue required as left operand of assignment
cout << n;
```

我已将编译器的报错信息以注释的方式添加到代码中。它的意思是：赋值运算符的左操作数需要是一个左值。我们不需要管什么是“左值”，我们只需要知道，编译器并不允许我们把 n 的值赋给 $n*n$ 。

常量

任何一个变量（广义地讲，对象）在被定义之后都可以修改，这固然很方便，但也可能会遭遇一些问题。

圆周率的近似值是 3.14，我们希望定义一个变量 Pi ，它不会被我们自己，或是别的人随便改动；围棋棋盘上有 $19*19$ 个可放子的交叉点，这是恒定不变的，我们也希望不会有人乱改。

但是传统意义上的变量无法禁止修改。C 语言使用宏⁵来定义一个标识符，并通过预处理将其转换为字面量（字面量无法被修改）来实现禁止修改的效果。而在 C++ 中，我们有更好的方法：使用 **const** 限定符，将变量限定为常量（Constant）。⁶

定义一个常量的语法是

```
const <类型> <名字> = <初始化>; //const可以在类型关键字前
<类型> const <名字> = <初始化>; //const在类型关键字后，效果相同
```

这两种方式均正确，读者可以选择自己喜欢的方式来定义。

我们可以定义一个 **double** 型的常量 Pi 来表示圆周率的近似值，再定义一个 **int** 型的常量 Grid 来表示围棋棋盘的边长。那么我们可以这样写：

```
const double Pi = {3.14}; // 定义一个double常量Pi
const int Grid {19}; // 定义一个int常量Grid
```

如果你试图在之后的代码中修改常量，那么编译器将报告这样的错误：

```
Pi = 3.1; //试图修改常量Pi的值
//error: assignment of read-only variable 'Pi'
```

⁴数学上的等号在 C++ 中可以用相等性运算符 $==$ 来表示。我们会在后面讲解。

⁵宏（Macro），是一种批量转换特定内容的方法。它的功能很像我们常用的“查找替换”。

⁶广义上讲，“常量”是“变量”的一部分。根据[Variable-Wikipedia](#)的阐释，凡在内存中占据存储空间的具名量都是变量。这点似与数学上的“变量”概念不同。本书于处理常量变量之关系处也很为难，故约定：**在需要分清常量和变量的场合下，将它们视为不重合的概念；而在一般场合下，统称其为变量**。当然，若以“对象”统称之，便没有歧义了。

这说明 `Pi` 是一个只读的数据，我们不能对它赋值来进行修改。

在 C++ 中，常量是一种一经定义就无法修改的量。这意味着，我们只能在定义它的同时就给它初始化，而不能把定义和初始化的步骤分开。⁷ 变量则不同，我们可以不进行初始化，或者是在定义之后进行赋值。

```
int i; // 定义变量但不初始化，此时i的值未定
i = 2; // 赋值，这样i的值就确定下来了
const int i_c; // 定义常量但不初始化
//error: uninitialized 'const i_c' [-fpermissive]
```

这个报错信息的含义是：`i_c` 作为一个常量，没有被初始化。所以这是不允许的。

常量与字面量的区别

说到这里，你也许会感到困惑：如果我们用 `const` 常量就是为了防止数据被修改的话，那为什么不全部使用字面量呢？这里就来介绍一下常量相比于字面量的优点。

首先，常量可以用标识符来阐述其含义。比如用 `Grid`，这就比单纯放一个字面量 19 要容易理解得多，也便于后期我们回顾代码。

而且，常量容易统一修改。这里的“修改”不是上文中提到的那种赋值式的修改，而是直接修改定义语句中用来初始化的值。

我们在一开始设计围棋程序的时候可能没有想到，围棋棋盘的大小还可以有 13×13 和 9×9 两种简化版。如果咄咄逼人的甲方要求你改成 13 或者 9 的边长，而你又在你的上千行代码中写下了数百个 19，你可能会崩溃的。

而如果我们都用常量呢？我们可以不用写数百个 19，而是把它们都用 `Grid` 代替。这样一来，如果甲方要求你改变棋盘的大小，你就可以通过改变初始化值的方式来解决问题了。

```
const int Grid {13}; // 现在把19改成13
```

这样就很省事了。

常量还有一个优点，它可以使用变量来初始化。比如说，我现在换了个思路，不想再修改源代码了。我通过一个中间变量来接收输入，然后把这个输入的值作为棋盘大小，用来给常量初始化。这个过程对于初学者来说可能有点复杂，我把代码列在这里：

```
int g; // 定义一个临时变量g。因为通过输入来赋值，我们不必初始化
cin >> g; // 通过输入来改变g。输入多少，g就变为多少
const int Grid = {g}; // 用g的值来为Grid初始化，g的值取决于输入
```

这是一个相当有创造性的做法！在这里，`Grid` 不是预先决定的常量，而是可以通过变量来控制的常量。它仍然符合一经定义就无法修改的限制，同时又有了一定的灵活性。这种做法在将来的函数参数传递中非常常用，后面我们还会继续这个话题。

枚举常量简介

枚举 (Enumeration) 在 C++ 中的使用不像常量那么频繁，但它也很好用。在有些场合中，定义整型常量比较麻烦，而定义枚举很简单，这时我们可以用枚举来简化我们的代码。在另一些场合中，我们可以用枚举来方便地为一些标识符制定常量编码，并限制可能的取值范围。

具名的枚举可以视作一个自定义类型，而常量只能依托于已有的类型（无论是内置类型还是自定义类型），比如 `int`, `double` 之类。

定义一个枚举要用到 `enum` 关键字。定义枚举的最简单语法是：

⁷某种意义上，这也体现出初始化与赋值的区别。

```
enum { <标识符1>, <标识符2>, <标识符3>, ... }; //无枚举名
enum <枚举名> { <标识符1>, <标识符2>, ... }; //有枚举名
```

无枚举名的语法一般不用于自定义类型，而是纯粹当作整型常量。我们可以指定不同的标识符的值。

```
enum { MiniGrid = 9, SmallGrid = 13, NormalGrid = 19 };
//定义无枚举名的枚举，相当于整型常量
```

这样我们就可以像常量一样使用它们了。

有枚举名的语法当然也可以当作整型常量来看待，不过它支持的功能就更丰富了。

```
enum Color { Red, Blue, Green}; //定义有枚举名的枚举
Color sky_color = {Blue}; //定义Color类数据sky_color，其值为Blue
Color grass_color = {Green}; //定义Color类数据grass_color，其值为Green
```

这里的 `sky_color` 和 `grass_color` 就相当于 `Color` 类型的两个数据，或者也可以说是 `Color` 类的两个对象。

这里只对 `enum` 作简单介绍，而不要求读者掌握。我们会在第六章讲解关于枚举的更多细节。

2.2 基本数据类型

整型

在第一章我们已经谈过，整型就是只能表示整数的数据类型。

常用的整型变量一般有 `short`, `int`, `long`, `long long` 及其相应的 `unsigned` 版本⁸。某一类型在不同电脑上占用的内存空间大小可能是不同的，而内存空间的多少又和数据表示范围紧密相关，所以我们不妨把类型和数据范围分开讨论。

2字节的数据类型可以表示 $(2^8)^2 = 65'536$ 种状态，也就是可以存储 65'536 种值。有符号类型编码了 0~32'767 和 -32'768~-1 的数字（换言之，从 -32'768 到 32'767）；而无符号类型就不需要编码负数了，节省出来的容量可以编码更多正数，所以无符号类型编码了 0~65'535 的数字。

4字节的数据类型可以表示 $(2^8)^4 = 4'294'967'296$ 种状态，可以存储 4'294'967'296 种值。有符号类型编码了 -2'147'483'648~2'147'483'647 的数字；无符号类型编码了 0~4'294'967'295 的数字。

8字节的类型可以表示 $(2^8)^8 \approx 1.84 \times 10^{19}$ 种状态。有符号类型编码了 -2⁶³~2⁶³-1 的数字；无符号类型编码了 0~2⁶⁴-1 的数字。

于是乎，我们只需要通过 `sizeof` 算出它的内存空间大小，再根据它是有符号类型还是无符号类型，就可以判断出它的数据范围是什么了。

C++ 还有另一种更简便的方法，那就是直接使用 `limits` 头文件中定义的 `numeric_limits` 来输出某一类型的数据上下限。`numeric_limits` 给出的结果正是本电脑的类型数据范围。

以下是实现这个功能的完整示例代码：

代码 2.1: Integer_Limits.cpp

```
// 这是一个简单的C++程序，用于输出一些整型数值的上/下限值
#include <iostream> // 标准输入输出头文件
#include <limits> // 标准算术类型属性头文件，numeric_limits 定义于此
using namespace std; // 使用 std 命名空间
int main(){ // 主函数，程序执行始于此
```

⁸`long long` 及 `unsigned long long` 在 C++11 标准以后可用。本书默认使用 C++17 标准，故不再反复提及此问题。

```

cout << numeric_limits<short>::lowest(); // 输出 short 类型的下限值
cout << endl; // 输出换行，下同
cout << numeric_limits<short>::max(); // 输出 short 类型的上限值
cout << endl;
cout << numeric_limits<unsigned>::lowest(); // 输出 unsigned 类型的下限值
cout << endl;
cout << numeric_limits<unsigned>::max(); // 输出 unsigned 类型的上限值
return 0;
}

```

在 Coliru 上，该程序代码的运行结果如下：

```

-32768
32767
0
4294967295

```

这里需要介绍几点：

首先，`numeric_limits` 是一个类模版⁹，它要接收一个“类”作为模版参数。比如说，在这个例子中，我们分别使用了 `short` 和 `unsigned` 作为模版参数，然后用 `lowest()` 和 `max()` 成员函数¹⁰ 来求出我们想要知道的值。如果你愿意，也可以把这段代码中的类型改成其它任何一个基本数据类型，然后观察输出，比如 `double` 或 `char`。

其次是“输出换行”的问题。当我们的代码中有多个输出语句的时候，程序会在运行时按顺序执行这些输出语句。但是程序不会自己添加分隔符¹¹，它会这样输出（以刚才程序为例）：

```

-327683276704294967295

```

这不便于我们阅读和理解，所以我们应当人为地把两个输出用分隔符隔开。而 `cout` 就是一个换行符，输出它的效果相当于另起一行。我们当然可以使用其它的换行符，比如我们把输出换行的语句改成输出逗号，

```

cout << ','; // 这相当于输出一个字符字面量 ',', 于是程序会输出一个逗号作分隔符

```

那么输出应当是这样的：

```

-32768,32767,0,4294967295

```

我们现在还没到讲解输入输出控制的时候，但这方面的知识我们又不得不了解，所以在这里先开个头，以后我们还会频繁遇到的。

最后还有一个问题：假如我的运算超过了整型的表示范围，会发生什么？比如对于有符号型 2 字节的变量来说， $32767+1$ 会得到什么？答案是 -32768 ！这是一种整数溢出（Integer Overflow）现象，详细的原理我们之后再谈；总之我们需要记住，在写代码的过程中需要对可能出现的数据进行预判，尽量避免出现这种运算结果“装不下”导致的情况。

⁹关于类模版的有关知识，我们将在第十一章中讲解。

¹⁰关于函数的基本知识，我们将在第四章中讲解；而关于类的成员函数，我们将在第八章讲解。

¹¹分隔符（Delimiter），指的是将一系列内容按同样的格式分开的符号，它有点像标点符号，但又不尽然。分隔符既方便人类阅读，又让计算机能够分辨不同的数据。比如说，我们用空格将一系列词语分开，这时空格就是它们的分隔符。

浮点型

浮点型数据的编码方式比整型数据要复杂些，我们在精讲篇中再作详细探讨。

我们一般使用 `float`, `double` 和 `long double` 来存储浮点型变量。一般来说，`float` 型占用 4 字节内存空间，`double` 型占用 8 字节内存空间，而 `long double` 型占用 16 字节内存空间。我们同样可以用 `numeric_limits` 来求出它的上/下限。这里我就不再演示代码了，想要尝试的读者可以自行修改代码 2.1 并运行之。

浮点数据和整型数据有一个重要的差异在于，很多时候浮点数表示的都是“近似值”。例如，在 17 位小数的显示精度下，`double` 型的 0.1 和 0.2 相加的结果是 0.3000000000000004；而 0.3 则显示为 0.2999999999999999。

那这个结果对还是不对呢？在精度要求不高的情况下它是对的，因为当你四舍五入到 16 位小数的时候它就相等了。而 `cout` 默认显示至多 6 位有效数字，所以这样的误差是微乎其微的。¹²

还有另一个问题。假如我们需要很高精度的计算，比如要求圆周率取到小数点后 20 位，那么有效数字位数仅有 15~17 位的 `double` 型是不能满足我们的要求的。这时有经验的程序员当然会首选 `long double` 了。

```
const long double Pi = {3.14159265358979323846};  
// 定义一个长双精度浮点型常量 Pi，精确到小数点后 20 位
```

看起来没有丝毫问题，对吗？但是问题恰恰就出在字面量上！

前面我们就提过，编译器会将所有浮点字面量统一视为 `double` 类型的字面量。因此，字面量 3.14159265358979323846 本身就是一个 `double` 型数据，它早在编译时就因为不能容纳如此高的精度而发生了精度上的损失。那么用损失后的只有 15~17 位精度的数字去给 `long double` 数据初始化也是枉然！

但我们也有应对方法：指定字面量的类型。在 C++ 中，我们可以用后缀的方式来指定整型或浮点型字面量的类型。当我们在一个浮点数后加 f 后缀时，就指明了它是 `float` 单精度浮点数，比如 1.f, .57f, 2.718f；而当我们在一个浮点数后加 l 后缀时，就指明了它是 `long double` 长双精度浮点数，比如 1.l, .57l，以及 3.14159265358979323846l，这样就不致有 20 位以内的精度损失了¹³。

除了使用后缀以外，我们还有一些其它的字面量表示语法。如果你刚才已经试过输出浮点数的上/下限，那么你可能会看到这种格式的输出结果：1.79769e+308。这是什么意思呢？

实际上，浮点数表示的范围跨度很大，比如 `float` 可以表示 $-3.402'823'4 \times 10^{38}$ ~ $3.402'823'4 \times 10^{38}$ 范围的值。这么大的值不适合用一般方法表示，所以在计算机中我们有一种类似科学记数法的形式。

它的规则很简单。一个整数或浮点数都可以在后面加上 e（或 E，均可）和指数（可正可负）的形式。例如：

```
2.99792458e+8 (小写字母，带正号);  
6.02214076e23 (正号可省略);  
1.602176634E-19 (大写字母也可以);  
.000662607015E-30 (不一定非要在 1 到 10 之间嘛);  
25.81280745E+3 (形式很灵活，这样写也可以)  
3141.59265358979323846264338327950288e-3l (末尾的 l 说明它是长双精度浮点数，注意：其位置在指数之后)
```

当然，浮点的字面量表示还有更多花样，不过这里就不再介绍了。

整型数据的字面量同样有很多后缀可以用来指定类型，比如 ull 后缀规定了 `unsigned long long` 类型。但这并不是刚需，因为大多数情况下编译器都能自动为整型字面量匹配合适的类型。

¹² 这里还涉及浮点数相等性的判断问题。正因浮点数多为近似值，所以直接使用相等性运算符极易出现失误。实际操作中我们多用两数相减，通过差值的绝对值是否足够小（比如，限定小于 10^{-5} ）来判断它们是否相等。

¹³ 诚如上文所言，浮点数的微小精度损失普遍存在，但只要在我们的承受范围内就可以。

字符型

在第一章，我们就介绍过 `char` 字符类型和相应的 ASCII 编码。我们也提及，字符类型其实是一种特殊的整型。它与整型的编码方式有相同之处，而与浮点型的编码方式则是天差地别。

字符型在输出时，主要是为了表示，而非为了计算。所以在用 `cout <<` 输出字符型数据时，输出的并不是它的 ASCII 码值，而是这个字符本身，比如

```
cout << '0'; // 输出字符型字面量 '0'
```

虽然 '`0`' 的 ASCII 值是 48，但程序的输出实际上是 `0`。¹⁴

如果我们要输出它的 ASCII 码值呢？我们可以使用后文马上就要讲到的类型转换方法，将 `char` 类型数据转换成 `int` 类型来输出，或者是通过减去 ASCII 码为 0 的字符 '`\0`' 来实现——因为两个 `char` 类型之差的结果为 `int` 类型。

```
cout << '0' - '\0'; // 输出相当于 48-0，也就是 48
```

你可能有注意到，这个 ASCII 码为 0 的字符长得好像有点奇怪。在 C++ 中还有许多类似的字符，像 '`\t`'、'`\n`' 之类，它们统称为转义字符（Escape sequence）。转义字符的真实含义不是字面上的含义，它表达了特定的控制字符。比如 '`\n`' 指的是换行符，如果我们输出一个 '`\n`'，就相当于为输出换了一行。那么我们也可以用它来替代 `endl`¹⁵。

```
cout << numeric_limits<char>::lowest(); // 输出 char 类型的下限值
cout << '\n'; // 输出换行符，效果相当于 cout << endl;
cout << numeric_limits<char>::max(); // 输出 char 类型的上限值
```

不同电脑环境下 `char` 类型的范围有两种可能：一种是 -128~127，另一种是 0~255。无论哪种可能，都涵盖了 ASCII 码的基本范围 0~127。

那么剩下的范围呢，它们有什么作用？这不仅取决于你的系统，还取决于你使用的语言。如果你使用的是 Windows 中文版，你可以测试下这段代码：

```
// 适用于 GBK 编码
cout << char(196) << char(227) << char(186) << char(195);
```

它的输出应该是“你好”。你还可以在 Coliru 上测试下这段代码，这个结果不受你使用的系统和语言的影响：

```
// 适用于 UTF-8 编码
cout << char(228) << char(189) << char(160)
    << char(229) << char(165) << char(189);
```

它的输出也应该是“你好”。

实际上这里涉及到更深奥的可变宽度编码¹⁶技术。在 Windows 简体中文的环境中常用 GBK 编码，这是一种变宽编码，其中 ASCII 字符占一个字节，汉字占两个字节（比如第一段代码）；在 Windows 繁体中文的环境中早期常用 Big5 编码，这是一种定宽编码，所有字符均占两个字节；而许多系统现在都支持 Unicode，其中以 UTF-8 实现方式为多，所有字符占一至四个字节不等，而 CJK 文字¹⁷常用者为三字节（比如第二段代码），罕见字为四字节。在泛讲篇中我们不会深入讲这些知识，也不会普遍使用，我们留到精讲篇再来谈。

¹⁴ 在代码中，'`0`' 和 `0` 类型不同。但在控制界面上，无论是人类的肉眼还是计算机程序，都无法分辨它究竟是字符还是数字——甚至说，它们就是同一个东西！我们在第三章会对此有所涉及。

¹⁵ 实际上这两种换行方法有更细微的区别，即何时清空缓冲区的问题。不过它不会影响我们的输出结果，我们不必细究。

¹⁶ 可变宽度编码（Variable-width encoding）是一种字符编码方案，它对不同的字符用不同长度的编码来表示。相对地，ASCII 是一种定宽编码，它的每个字符都用统一的单个字节来表示。

¹⁷ CJK 文字是中文、日文和韩文的统称，包括全数汉字及变体、假名和谚文等。

字符串简介

字符串并非基本类型，但是它很重要，我们就在那里一并介绍。

还记得我们的[代码 1.1](#)吗？在这个代码中，我们输出的 "`HelloWorld!`" 就是一个字符串字面量。顾名思义，字符串字面量就是一串字符构成的字面量。每个字符串都有一个我们看不到的结束符作为结尾，它就是 '`\0`'。

我们可以用 `sizeof` 来取它的内存大小。这个字符串一共有 10 个大小写字母、1 个标点和 1 个空格¹⁸，外加结束符 '`\0`'，全部是 ASCII 字符，所以它的内存占用应当是 13 字节。那么我们用 `sizeof` 算算，验证一下我们的猜想。

```
cout << sizeof ("HelloWorld!"); // 也可以不加括号
```

输出果然是 13。

需要留心，字符是用单引号套起来的单个字符（转义字符是个例外，它允许你使用反斜线加一个字符）¹⁹；而字符串是用双引号套起来的任意多个字符。转义字符同样可以用在字符串中，比如

```
cout << "ABCD\nabcd";
```

这段代码的输出应为

```
ABCD abcd
```

这里的 `\n` 就起到了换行符的作用。如果要用 `sizeof` 来计算，它的内存占用应当是 10 字节。

布尔型

布尔型是一种特殊的整型，它一般用来表示一种逻辑判断的信息。举例来说，“`2>3`”是一个逻辑判断，它的值为“假”（`false`）；而 “`"HelloWorld!"`” 的内存占用为 13 字节”也是一个逻辑判断，它的值为“真”（`true`）。

布尔型数据用关键字 `bool` 来定义，它只有两个可能的取值：`true` 和 `false`。在编码时，它们分别被编为 `1` 和 `0`。

按理说，我们只需要一个比特就能表示一个布尔变量。然而，内存当中的比特并不是独立的寻址单元，所以一个布尔型变量必须要用一整个字节来存储。²⁰读者可以用 `sizeof` 来验证它。

布尔型数据在输出时默认以整型数据的格式输出，于是 `false` 会被输出为 `0`，而 `true` 会被输出为 `1`。

```
bool judgement {2>3}; // 定义 bool 型变量 judgement，其值为 false
cout << judgement; // 因为 judgement 的值为 false，所以输出 0
```

我们可以通过一些语法设置来强制 `cout` 输出 `true` 或 `false`。

```
cout.setf(ios_base::boolalpha); // 设置格式化标志
cout<<true; // 这样一来，它就会输出 true 而非 1
```

我们现在先不讨论这些细节，在第十三章中会谈及。

¹⁸在本书中，空格字符以 `_` 表示，以便于阅读。（当然，这可能会对读者使用 `Ctrl+C/V` 造成一定的麻烦）

¹⁹实际上 C++ 中允许使用单引号套起来的多字符字面量（Multicharacter literal），但我认为没有必要在本书讲它。感兴趣的读者可以阅读[What do single quotes do in C++ when used on multiple characters?-Stack Overflow](#)。

²⁰标准模版库中的 `vector<bool>` 采用了优化方法，使得每个字节可以存储 8 个布尔数据，这就提升了存储空间的利用率。

2.3 运算符

本节我们将会接触到一个非常有趣的知识：运算符。许多教材在讲运算符的时候讲解不够透彻，虽然不太影响基础层面的知识掌握，但对以后的学习，尤其是运算符的重载，是比较不利的。我在本节会用函数的视角来剖析运算符，希望能为读者带来清晰的认识和比较透彻的理解。

运算符的操作数与返回值

来看一个简单的例子：

```
int num {13 * 5 + 9}; // 定义num并初始化为13*5+9
```

我们可以把这句代码分成两步操作：第一步是把 $13*5+9$ 求出来，第二步是初始化。第一步的求值过程还可以进一步拆分，先求乘法，再求加法。那么我的问题是：乘法操作把哪两个数乘起来了？加法操作又把哪两个数加起来了？初始化操作又把哪个数的值给了 `num`？

让我们来梳理一下程序的操作过程，这样就会对这些问题有清晰的认知了：

1. 首先，乘法操作把 13 和 5 乘起来，并求得 65，这是毫无疑问的。
2. 其次，加法操作把 $13*5$ ，也就是 65，和 9 加起来，并求得 74。这时候加号左边的 $13*5$ 被加号看作一个整体，它操作的不是 5 而是 $13*5$ 。
3. 最后，初始化操作把 $13*5+9$ ，也就是 74 的值初始化给 `num`，这个过程没有再求出什么。这时候初始化所用的 $13*5+9$ 被初始化语句看作一个整体，它操作的不是单个数而是整个表达式。

从这个过程中，我们可以看出这样一个特点：有些操作过程会直接用我们给定的字面量（也可以是变量）来计算；而有些操作过程需要用到前面某一步算出来的值，并把它当作一个整体来运算。有些操作过程还会产生一个结果，后面的操作可以利用这个结果。

现在我开始甩专有名词：我们把一个运算符用来计算的数据（包括表达式整体）叫作它的操作数（Operand），而一个运算符计算出来得到的结果（一个表达式整体）叫作它的返回值（Return value）。操作数和返回值都是对于某个运算符而言的，比如 $13*5$ 既是乘法运算的返回值，又是加法运算的操作数。初始化的过程其实不涉及某个运算符²¹，所以我们这里不再探讨。

我们在关注操作数和返回值的时候必须留意它们的类型，因为类型不同可能会带来天差地别的结果。我们在前面已经提过 $8/3$ 和 $8./3$ 的区别了，这是因为：当除号的操作数都是 `int` 型时，返回值就是 `int` 型；而只要有一个操作数是 `double` 型，即便另一个操作数是 `int` 型，返回值也将是 `double` 型²²。

两个 `char` 类型数据相减，得到的结果是 `int` 类型的，因此我们上一节中讲到的 '`'0'`-'`'\0'`' 的语法能够求出 '`'0'`' 的 ASCII 码值。

赋值语句也有返回值，它返回的是左操作数的一个引用²³。在 C++ 中我们偶尔会遇到连续赋值的语法，如下例：

```
int a, b, c; // 连续定义a,b,c，但不初始化，此时它们的值均不确定
a = b = c = 0; // 连续赋值
```

鉴于我们还没有讲运算符结合性，我先用一个容易理解的带括号版本来介绍：

```
a = (b = (c = 0)); // 连续赋值，等价于a=b=c=0;
```

²¹如果涉及自定义类型的初始化，它其实是一种构造函数。

²²实际上这个过程更复杂，它先将 `int` 型经过类型转换变为 `double` 型，再进行两个 `double` 数据的计算。

²³我们会在第五章介绍引用。即便读者尚不知道何为引用，也不会对读者理解此节造成困难。

圆括号改变了计算的顺序²⁴，它将把括号内的部分当作一个整体来对待。于是这段代码执行的操作就是

1. `c=0` 中的赋值运算符将左操作数 `c` 的值变为右操作数 `0`。最后返回 `c` 的引用。
2. `b=(c=0)` 中的赋值运算符将左操作数 `b` 的值变为 `(c=0)` 的返回值，即 `c`。因为此时 `c` 的值为 `0`，所以 `b` 的值变为 `0`。最后返回 `b` 的引用。
3. `a=(b=(c=0))` 中的赋值运算符将左操作数 `a` 的值变为 `(b=(c=0))` 的返回值，即 `b`。因为此时 `b` 的值为 `0`，所以 `a` 的值变为 `0`。最后返回 `a` 的引用。

在上述过程中，每个赋值运算符都接收了两个操作数，并给出了一个返回值。当然，`a=(b=(c=0))` 的返回值就不需要使用了，因为我的目的已经达成。如果你愿意，还要以加上一个 `cout<<` 来输出 `a` 的值。

```
cout << (a = (b = (c = 0))); // 输出 a=(b=(c=0)) 的值，应为 0
```

再举一例。`<<` 在左操作数是整型数据的时候，意思是左移位运算符。而 C++ 中重载了这个运算符²⁵，当其左操作数为 `ostream` 类的对象时，实现输出功能，最后返回左操作数的引用。C++ 中我们最常用的 `ostream` 类的对象就是 `cout`，所以我们可以用它和 `<<` 操作符实现连续输出。

```
const double a {3.6e3}, b {6.02e-23}; // 定义两个double常量并初始化
cout << a << '\n' << b; // 输出a，再输出换行符，再输出b
```

我们按照相同的思路来解释一下这段代码的行为：

1. `cout<<a` 中的左移运算符的左操作数是 `cout`，所以标准输出将把右操作数 `a` 的值输出到相应设备上。最后返回 `cout` 的引用。
2. `cout<<a<<'\n'` 中的第二个左移运算符的左操作数是 `cout<<a` 的返回值，即 `cout`，所以标准输出将把右操作数 `'\n'` 这个转义字符输出到相应高备上（起到换行作用）。最后返回 `cout` 的引用。
3. `cout<<a<<'\n'<<b` 中的第三个左移运算符的左操作数是 `cout<<a<<'\n'` 的返回值，即 `cout`，所以标准输出将把右操作数 `b` 的值输出到相应设备上。最后返回 `cout` 的引用（这个返回值我们不再需要用到）。

`>>` 叫做右移位运算符。C++ 中重载了这个运算符，当其左操作数为 `istream` 类的对象时，实现输入功能，最后返回左操作数的引用。C++ 中我们最常用的 `istream` 类的对象就是 `cin`，所以我们可以用它和 `>>` 运算符实现连续输入。

```
int i, j, k; // 定义int数据i,j,k。不能定义为常量，否则将发生错误
cin >> i >> j >> k; // 先后为i,j,k连续输入
cout << i << endl << j << endl << k; // 连续输出i,j,k并以换行为间隔
```

读者可以仿照上例，对本例中连续输入的语法进行解读。

运算符的优先级

在上小学时我们就学过“先乘除，后加减”这类的口诀。这其实就体现出一个先后顺序的问题，亦即“先算什么，后算什么”。C++ 中有数十种运算符，除了我们熟知的四则运算以外，还有赋值运算符、模运算符和移位运算符等等。如果我们不人为规定一个“先操作什么，后操作什么”的顺序的话，有些代码的理解处理将会变得很麻烦。我们举个例子：

²⁴再次提醒，方括号`[]`和花括号`{}`它们有各自的作用。我们不能用它们来达到改变运算顺序的目的，只能用圆括号`()`。

²⁵对于重载后的运算符，我们仍然称其为左移运算符，但它的功能已经发生了实际上的变化。

```
num = 6 * 7; //假设num是一个已经定义了的int型变量
```

如果先操作乘法运算符，再操作赋值运算符的话，应当是这样的过程： $6*7$ 的返回值作为赋值运算符的右操作数，经由赋值运算符把它赋给 `num`。赋值运算符的返回值不需要再使用。最终 `num` 变为 42。

假如先操作赋值运算符，再操作乘法运算符呢？（虽然对于人来说有点费解，但电脑不会怀疑，只会默默执行）它先将 6 赋值给 `num`，然后将赋值运算符的返回值，即 `num`，与 7 相乘。乘法运算的返回值没有被使用。最终 `num` 变为 6。

再比如，`a+b*c` 究竟是先算加法还是先算乘法，结果很有可能是不同的。因而我们需要人为规定，某个运算符要优先于某个运算符来计算——这就是优先级（precedence）的问题。

在初学阶段，我建议读者把“优先计算”理解成“套括号”。C++ 规定乘法运算符的优先级比加法要高，那么我们就为乘法运算符和乘法运算符所操作的数套上括号，变成 `a+(b*c)`。套上括号，就意味着 `(b*c)` 是一个整体，它的返回值将会作为加法运算的右操作数。

C++ 中的赋值运算符优先级很低，比四则运算都要低。那么按照我们的思路，如果加法，乘法和赋值运算符同时出现，我们应该先给乘法套括号，然后是加法，最后才是赋值。如图 2.1 所示。



图 2.1: 代码 `num=a*b+c*d;` 的套括号解释

再看这段代码：

```
cout << 3 + 4; //输出3+4的值
```

在 C++ 中加法运算符的优先级高于移位运算符，所以它就可以解释为 `cout<<(3+4)`，就会输出 7。

比较运算符，包括大于号 `>`，小于号 `<`，相等号 `==26`，不等号 `!=` 大于或等于 `>=`，小于或等于 `<=`，它们会比较左右操作数的关系，然后以 `bool` 数据的形式给出一个逻辑判断。正如前文所说，我们可以用 `cout` 来输出一个布尔型数据（只是默认以数值的方式输出），比如这样：

```
cout << 3 != 4; //输出3!=4的结果，预期是ture，输出是1
//error: no match for 'operator!=' (operand types are
//'std::basic_ostream<char>' and 'int')
```

²⁶在 C++ 中，单个等号 `=` 是赋值运算符，而 `==` 是一个比较运算符。

但是这段代码在编译期就出现了问题，而报错信息也显得十分奇怪：“没有匹配的运算符 !=（操作数类型分别是 `std::basic_ostream<char>` 和 `int`）。”我们甚至都搞不懂为什么会出现这样的报错信息！

但是解决方法也很简单，只需为 `3!=4` 套上括号：

```
cout << (3 != 4); // 输出 3!=4 的结果，编译正常，并输出 1
```

为什么是这样呢？原因在于，`<<` 的优先级要高于这一系列的比较运算符。所以如果按照 `cout<<3!=4` 的写法的话，`cout<<3` 会先套上括号，于是变成了 `(cout<<3)!=4`。显然，`cout`（也就是 `cout<<3` 的返回值）和 `4` 比较是没有意义的，C++ 也没有定义这种语法，于是才有了我们之前遇到的问题，即“没有匹配的运算符”。正因如此，我们才需要把 `3!=4` 套上括号，以此来表示它要作为一个整体来计算。

而假如我们需要为一个 `bool` 变量来赋值的话，那就不会有这样的问题了，因为比较运算符的优先级要高于赋值运算符。

```
bool judgement; // 定义 bool 型变量 judgement，不初始化
judgement = 2 * 5 > 9; // judgement 应当被赋值为 1
```

在这个赋值语句中，乘法运算符的优先级最高，大于号次之，赋值运算符最低，于是它的正确表达就是 `judgement=((2*5)>9);`。

C++ 中的运算符实在太多，优先级规则也相当复杂，这里无法尽数讲解，读者可以参考[附录 A](#) 的内容。在后面的章节中我们会接触到更多运算符，到那时我们会再细致讲解。

运算符的结合性

那么同一优先级的运算符又该按照什么顺序来计算呢？这就涉及到结合性的问题了。

举一个简单的例子：

```
cout << 8 / 4 / 2; // 结果会是什么？
```

我们知道 `/` 的优先级比 `<<` 要高，所以套括号的顺序一定是先给除法运算符套括号。但是这里有两个除法运算符，究竟是套成 `((8/4)/2)` 还是 `(8/(4/2))` 呢？这就要涉及到结合性的问题了。

C++ 中规定了每个运算符的结合性（Associativity）。对于同一优先级²⁷来说，如果它的优先级是从左向右（Left-to-right），那么套括号的顺序就是从左向右；如果它的优先级是从右向左（Right-to-left），那么套括号的顺序就是从右向左。

除法运算符所在的优先级，其结合性是从左向右的，所以在乘法、除法和取模混合运算时，它就会从左向右套括号，而直观表现上就是“从左向右算”。赋值运算符所在的优先级，其结合性是从右向左的，所以在连续赋值的时候，它就会从右向左套括号，而直观表现上就是“从右向左算”。

所以连续除法中 `8/4/2` 就应该解释成 `(8/4)/2` 而非 `8/(4/2)`；而连续赋值中 `a=b=0` 就应该解释成 `a=(b=0)` 而非 `(a=b)=0`。如图 2.2 所示。

综上所述，运算符的优先级决定了不同种运算符套括号的顺序，而结合性决定了同种运算符套括号的顺序。于是编译器可以通过这套规则，给每个运算符都“套起括号”，从而让每个运算符都知道它的操作数是什么，而不至于出现歧义。

当然我也需要提醒读者，“为所有运算符都套括号”只是我们初学编程时的权宜之计；实际编程中，只有当默认的优先级与结合性不能满足我们的要求时，我们才通过加括号的方式改变运算逻辑（比如，在 `(a+b)*c` 中加括号是为了先算加法后算乘法）。当我们把这些知识掌握熟练了之后，我们自然就清楚在什么时候有必要加括号，而那些可有可无的括号就不会再用了。

²⁷ 相同的运算符一定是同一优先级。当然，同一个优先级可能包含若干种运算符，比如乘法、除法和模运算这三种运算符就属于同一优先级。

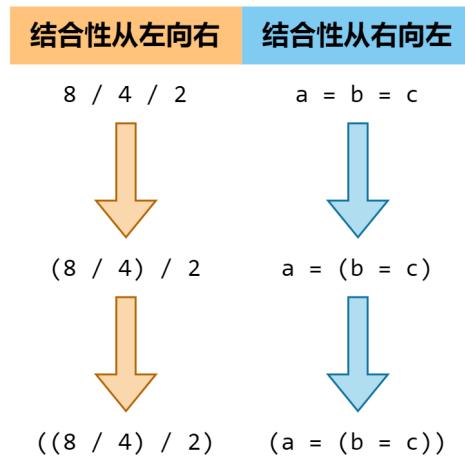


图 2.2: 除法运算符和赋值运算符的结合性

运算的语义

我们在实际编程的时候经常会犯一些语法 (Syntax) 上的错误，包括但不限于：

- 给常量赋值。这是因为常量不能赋值，编译器会禁止这种行为。
- 用字面量进行统一初始化时发生了收缩转换。比如某电脑的 `short` 类型占 2 字节，但使用了 `short s {40000};` 这样的语法。
- 写错了变量名，比如我定义的是 `num` 结果不小心写成 `nun`，然后编译器就会报错，理由是 “`nun`” 未定义。
- 写出 `cout << a <b` 这种表达式。可能你想输出 `a <b` 的结果但是忘记套括号了；也可能你想先后输出 `a` 和 `b` 但是不小心把 `<<` 写成了 `<`。但无论如何，编译器都会以“没有匹配的运算符”为由报错。

这些语法上的错误都很容易被编译器查出来，然后告诉你。你可能一眼就知道怎么回事，也可能花了好久才终于找到了问题所在，总是这些语法错误都是会在编译期由编译器告诉你的。

但是还有一类语义 (Semantics) 上的错误，包括但不限于：

- 不小心把 `a==3` 写成了 `a=3`。前一个是进行相等性判断，而后一个是赋值。这种失误常见于新手，但对于老手来说也在所难免。
- 受到数学表达的影响，在 C++ 代码中写出诸如 `2 <x <10` 这样的表达式。
- 想要计算 $8/3*1.$ 的浮点结果，但是算出来的却是整型的，原因不明。

语义错误的特点是，编译器不会认为你的代码是“错误”的。它会认为你写的代码都有你自己的目的。只要不违反 C++ 标准对于语法的规定，你就可以想怎么写就怎么写。但是很多时候，因为各种原因，“我们真正写出来的代码”并没有符合“我们想要实现的功能”，这时我们就会说，你的代码在语法上正确，但在语义上错误。这种语义上的错误是很可怕的，因为很多编译器不会给你提醒，你也不会立刻知道哪里出错，只有在你运行程序并发现结果不合预期之后，才会去找寻问题的来源。

`2 <x <10` 这句代码就属于一种语义错误，因为 C++ 没有三元比较运算符²⁸，我们不能用这样的方式进行比较。但是它在语法上正确，所以编译器会作如下分析：因为 `<` 的结合性是从左向右，那么 `2 <x <10` 可以被解释成 `(2 <x) <10`。

²⁸C++ 中唯一的三元运算符是条件运算符，它可以有三个操作数。我们之后再谈。

那么这样的解释方式能否达到我们的目的呢？我们分析一下就知道了：无论 $2 < x$ 的返回值是 **true** 还是 **false**，它都小于 10^{29} ，所以 $2 < x < 10$ 得到的返回值永远是 **true**！

那么怎样写才能达到我们的目的呢？这里要用到逻辑运算符“**&&**”（逻辑与）。逻辑与运算符用于计算两个布尔数据，仅当左右操作数均为 **true** 时，返回值才为 **true**；否则，返回值为 **false**。

那么我们拆解一下数学表达式 $2 < x < 10$ ，它的含义可以阐述为“ $2 < x$ ”并且“ $x < 10$ ”，必须两个要求都满足。于是我们可以通过逻辑与运算符来把它们拼合起来，写成 $(2 < x) \&\& (x < 10)$ 。

又因为 **&&** 运算符的优先级低于 **<**，所以我们可以不用套手动括号了，直接写成 $2 < x \&\& x < 10$ ，这才是语义上正确的写法。

至于 $8/3*1$. 为什么在语义上是错误的，我们放到下节的类型转换部分探讨。

2.4 类型转换

C++ 提供了丰富的基本类型，包括各种整型、浮点型、字符型和布尔型等³⁰。它们用途各异，表示范围也有差别。类型区分明确有很多好处，其中一点就是，许多运算符可以在操作数类型不同的情况下，表示不同的含义，得到不同的结果。将来我们会学习函数重载和运算符重载，这种方法大大增加了代码的可扩展性，并让我们可以通过自定义重载的方法针对不同类型实现多种多样的功能。前文提过，`<<` 在左操作数为 `ostream` 类时，实现输出功能；而在左操作数为整型时，实现左移位计算功能，这就是对类型多样性意义的最佳诠释。

但是，不同类型之间的隔阂也让人望而却步。假设我要输入两个整数并求它们的商和模值，而我们这么写代码：

```
int a, b; // 定义两个int型变量，无须初始化
cin >> a >> b; // 输入a和b的值
cout << a / b << endl << a % b; // 输出a/b和a%b
```

那么就会出现经典问题，整型除法的返回值自动截尾，我们得到的是不精确的结果。那么如果我们把代码改成这样呢？

```
double a, b; // 定义两个double型变量，这样double除法得到的结果就精确了
cin >> a >> b; // 输入a和b的值
cout << a / b << endl << a % b; // 输出a/b和a%b
//error: invalid operands of types 'double' and 'double'
//to binary 'operator%'
```

这样代码就会报错，因为“用 **double** 型数据与 **double** 型数据相取模是不允许的”。

类型限制太死板，难免会在这种需要灵活性的地方出现问题，而 C++ 解决这个问题的方式就是类型转换（Type cast/Type conversion）。

隐式类型转换

我们知道 '**0**' 的 ASCII 码值是 48，但是它是 **char** 型，而 C++ 中的 `cout <<` 在面对 **char** 型时会直接输出这个字符，而不是它的 ASCII 码。如果我们要知道它的 ASCII 码，要怎么办呢？

我们在此之前已经介绍过，可以用 '**0**'-'**\0**' 的方式来实现输出整数值的功能。然而实际上，C++ 并没有为 **char** 和 **char** 类型定义减法运算。那么它为什么不仅能通过编译，还能计算出正确的结果呢？这就是隐式类型转换（Implicit type conversion）的功劳了。

²⁹**bool** 型数据和 **int** 型数据比较的时候会发生类型转换，这点我们会在之后提及。

³⁰这里所列举的都属于算术类型。除此之外，基本类型中还有 **void** 和 **nullptr_t** 类型，但这里不讲。

在 C++ 中，算术运算符³¹不能接受低于 `int` 级别的操作数。在处理这些操作数的时候，将会先把它们转换成 `int`（或 `unsigned`）类型，然后再进行计算。于是 '`0`'-'`\0`' 的操作数分别被转换成 48 和 0，然后它们再经由减号计算出结果 48。

再来看这段代码：

```
int a, b; // 定义 int 型整数 a 和 b
cout << 1. * a / b; // 试图利用隐式类型转换计算 1.0*a/b 的结果
```

我们使用上一节讲过的运算符的知识来解读一下输出语句。乘除法的优先级高于左移运算符，而乘除法的优先级相等，其结合性是从左到右，于是它可以这样套括号来理解：`cout<<((1.*a)/b)`。

接下来开始分析类型。在乘法运算符遇到一个整型和一个浮点型的时候，整型会被转换成浮点型。于是在 `1.*a` 这个过程中会发生一个 `int` 到 `double` 的隐式类型转换，然后是两个 `double` 型的数据相乘，结果顺理成章地就是 `double` 型；

接下来是这个 `double` 型的 `1.*a` 作为整体与 `int` 型的 `b` 相除，于是 `int` 型的 `b` 也需要被转换成 `double` 型数据再参与运算。而 `double` 型数据的除法就不致于有截尾级别的精度损失了。整个过程如图 2.3(a) 所示。

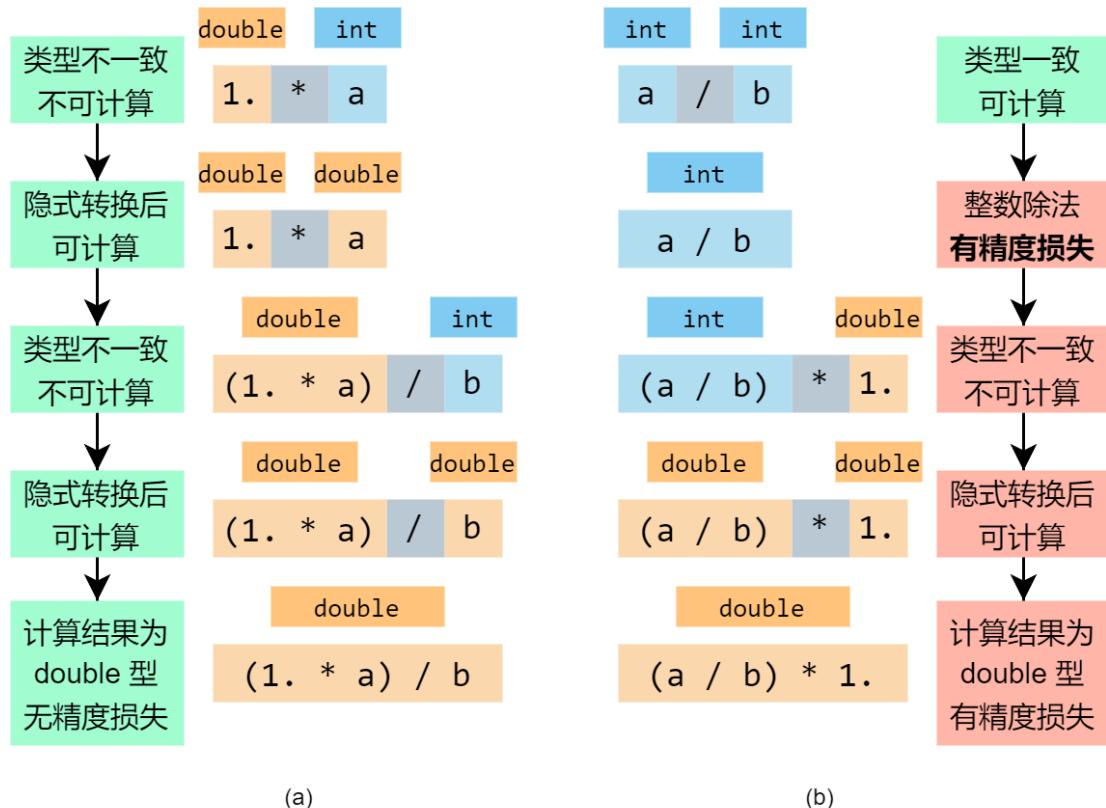


图 2.3: `1.*a/b` 与 `a/b*1.` 的隐式类型转换过程图解

那么我写成这样行不行呢？

```
cout << a / b * 1.;
```

我们同样分析一下这个语句，它应当被理解为 `cout<<((a/b)*1.)`。当除法运算符遇到两个整型数据 `a` 和 `b` 时，它会按照整型的除法来计算，这个过程中就存在精度损失！

这之后，虽然 `a/b` 作为一个整体被转换成了 `double` 型，但是之前丢掉的一部分信息再也找不回来了，于是即便最后算得 `double` 型的结果，也无济于事。整个过程如图 2.3(b) 所示。

³¹ 算术运算符包括正负号、四则运算符和取模，以及位运算；不包括自增和自减。

隐式类型转换的语法普遍存在于我们的代码中。凡是在运算符（或函数）需要某一个类型而我们提供的操作数（或实参）是另一个类型时，隐式类型转换都有可能发生。上一节中提到的语义错误代码 `2<x<10` 就是如此，`2<x` 先求出了一个 `bool` 型的结果，然后这个结果隐式转换成 `int` 型，再和 `10` 进行比较。在类型转换的过程中，如果 `2<x` 是 `false`，它就会被转换为 `0`，反之被转换为 `1`。

在赋值语句中也常常出现隐式类型转换，比如

```
double d {3.14159}; // 定义 double 型变量 d 并初始化为 3.14159
int i; // 定义 int 型变量 i, 无初始化
i = d; // 将 d 的值赋给 i, 这时会发生从 double 向 int 的类型转换, 损失小数部分
```

值得注意的是，类型转换并不意味着原变量的类型或值发生了改变！类型转换只是创建了对应类型的临时变量³²；在类型转换后 `d` 依旧是 `double` 类型，其值也依旧为 `3.14159`。

整数提升（Integral promotion）和浮点提升（Floating-point promotion）是两类特殊的隐式类型转换，它们的特点是精度完全没有损失。浮点提升是比较简单的，`float` 类型可以无精度损失地转化为 `double` 类型，就像是“升级”了一般。同样地，`char` 类型可以无精度损失地转化为 `int` 类型，也是一种整数提升。³³

布尔转换（Boolean Conversions）是隐式类型转换当中比较特殊，而又十分常用的一类转换。如图 2.4 所示，它的转换规则很简单：如果别的基本数据类型要转换为 `bool` 类型的话，`0` 会转换成 `false`，而其它的所有数都会被转换成 `true`；如果 `bool` 类型要转换成其它的基本数据类型的话，`false` 会转换成 `0`，而 `true` 会转换成 `1`。

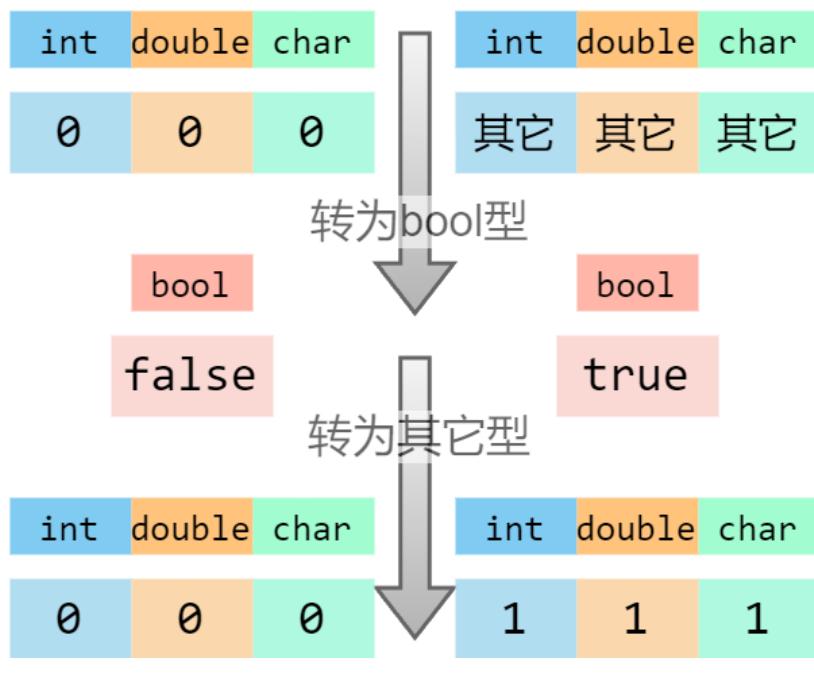


图 2.4: 布尔转换规则

显式类型转换

隐式类型转换固然方便，但并不是任何时候都能满足我们的需要；有些时候甚至会背离我们的需要，从而造成很多不便。对于这种情况，显式类型转换（Explicit type conversion）就比较有用了。

C 风格的显式类型转换语法是

³²“临时变量”这个概念对读者来说或许有点陌生。无妨，我们会在之后慢慢熟悉它的。

³³但是，并非所有的无精度损失的类型转换都是整数提升，这里没有必要细究，只把它们都当作隐式类型转换即可。

```
(<类型> <数据>)
```

这样就能得到目标类型的一个临时变量，我们可以拿它去计算了。

比如说，如果我要把整数运算 `a/b` 变为浮点运算，那么我可以这样写：

```
cout << (double) a / (double) b; // 显式类型转换
```

实际上我们只要写一个显式类型转换就可以了，另一个操作数自然会被隐式类型转换过去，不用麻烦我们再写一遍了。

如果我们嫌弃 `double` 类型的精度不够高，解决方法就是显式地转换为 `long double` 类型！

```
cout << (long double) a / b; // 显式类型转换；b 会被隐式转换为 long double
```

在 C++ 中，模运算不支持浮点型到整型的隐式类型转换，比如本节开头的例子里就体现了这一点。在保证两个操作数为整数的前提下（实际上不是整数也可以，不过两个小数本来就不可以取模，强行取模又有什么意思呢），我们也可以使用显式类型转换。

C++ 中引入了两类新的显式类型转换风格：一类是构造函数风格的类型转换；另一类是包含 `static_cast` 在内的四种特定类型转换语法。构造函数风格的类型转换语法为

```
<类型> (<数据>)
```

比如说上述的除法可以写作 `double(a)/double(b)`³⁴。而四种特定类型转换语法中我们只讲 `static_cast`，其余的留到精讲篇。它的语法是

```
static_cast<[类型]> ([数据])
```

在这里我为了避开括号对 `<>`，转而使用括号对 `[]` 来表达，请读者留意。

C 风格类型转换（和构造函数风格类型转换）最大的好处就是方便。它是一种比较“粗暴”的类型转换方式³⁵，写起来又很简单，所以新手程序员更青睐这种写法。但是在面对复杂类型转换，尤其是涉及指针等复合类型的时候，这样的转换很容易出错。因而，出于类型安全的考量，指定类型转换方式要更稳妥些。我也建议读者按照自己的需求，尽量使用 `static_cast` 等特定的转换语法，避免 C 风格那种大包大揽的转换。

比如说，如果我们要用 `static_cast` 来实现 `double` 型转 `int` 型并进行取模运算，我们可以这样写：

```
cout << static_cast<int> (a) % static_cast<int> (b);
// 将 a 和 b 都类型转换为 int，然后就可以使用模运算了
```

这里需要多加注意，无论你使用哪种风格的类型转换语法，在这里必须将 `a` 和 `b` 都显式类型转换为 `int`，因为在模运算中没有整数和浮点数之间的隐式类型转换规则。

而假如你想要把 `double` 型转换为 `int` 型来进行四则运算的话，你就要注意把每个数据都转化成 `int` 型，不然……

```
double a, b; // 定义浮点变量 a, b
cin >> a >> b; // 输入 a 和 b
cout << static_cast<int> (a) * b; // 试图进行显式类型转换
```

在这里，乘法运算符在面临一个 `int` 操作数和 `double` 操作数的时候，它会怎么做呢？如图 2.5 所示，它将把 `int` 通过隐式类型转换变为 `double` 型！这样一来我们就白干了。

总而言之，类型转换是一个非常复杂的话题。限于我们目前接触到的类型尚少，这里只作简单概括。将来我们接触复合类型和自定义类型的时候，还会对此作针对性讲解的。

³⁴注意：它不适合类型关键字中间有空格的类型，比如 `unsigned char` 和 `long double`。

³⁵它是 `const_cast`, `static_cast` 和 `reinterpret_cast` 三种转换方法的统合体。



图 2.5: 显式类型转换, 但是又被隐式类型转换改回去了

第三章 程序的流程控制

在第二章我们讲解了数据类型、运算符，以及类型转换的相关知识。对于一些初学者容易犯的错误，我们也尽量加以解释。有了这些知识之后，读者就已经具备完成一个简单的程序的能力了。

但是仅有这些还不够。回想一下我们的[计算程序](#)，我们为了求出 $(a+b*c)/d$ 的值，先定义了四个变量，再写了一个表达式，通过输出来求得算式的值。如果用户希望自定义各个数据的值呢？只能改代码。

“改代码”是很可怕的。我们不能苛求每个使用计算器的用户都有看懂并修改代码的本领。所以我们可能需要条件结构（或曰选择结构），根据用户按下的按键（加减乘除，或者归零，或者别的什么）来判断应当该使用何种运算符，然后把这些规则写到程序中。

一个计算器可以进行多次计算。它不会每算完一个数就自动关机，等你再次开（代码 1.2）机才能进行下一次计算。但是我们的程序每次算完都会终止，如何让它能够多次计算呢？我们可能需要循环结构，让这个程序周而复始地运行同一段代码，直到有一个信号让它停下来。

对于初学者来说，这些听上去可能有点天方夜谭，完全无从下手。没关系，本章我们就来讲解如何设计和控制程序的流程，以便写出功能更加复杂的代码——一个简单的计算器程序当然也不在话下了。

3.1 简介：结构、流程与次序

编译器如何处理代码？

在 2.3 节中，我们提到过“语法”和“语义”的区别。语法正确与否，事关代码能否通过编译；而语义正确与否，则事关程序能否实现我们想要的功能。在编译期，预处理器会进行一系列预处理，例如把 `iostream` 头文件的内容复制到我们的代码中，以便编译器进行编译。有些值也是在编译期进行计算的，比如 `sizeof`。这类处理和计算过程早在编译结束之前就已经操作完毕，我们将其统称为**编译时行为（Compile-time behaviour）**。

```
int a {3};  
cout << sizeof a << endl; // 输出 a 的内存占用  
cout << sizeof (double); // 输出 double 的内存占用
```

之所以这种操作在编译时就可以算出来，是因为编译器在编译期就已经可以确定它的值。还记得吗，无论 `a` 的值如何变化，它占用的内存空间总是那些，不会变多和变少。换言之，无论 `a` 的值是多少，`sizeof a` 总是一个在编译时就可以确定下来的常量。那么在编译时就把它计算出来，当然更划算了。

另一些操作，我们在编译时不能确定它的值，所以需要在程序运行时，具体情况具体分析。比如 `x+y`（假如 `x` 和 `y` 是两个变量），这个运算结果当然依赖于具体变量的值，无法预测，所以要在编译时求解。我们将其统称为**运行时行为（Runtime behaviour）**。以下所列代码均为运行时行为。

```
double d; // 定义 double 型变量 d，程序为其分配内存空间  
cin >> d; // 输入 d 的值  
d = d * d; // 为 d 赋值
```

```
cout<<d; // 输出d的值
```

读者可能好奇，代码 1.2 中的操作有哪些是编译时行为，哪些是运行时行为呢？事实上，只有 `include` 和 `using` 语句是编译时行为；而 `double` 变量的定义、表达式的计算和输出，全部是运行时行为。

编译器没有人那么智能。它判断这个表达式能否在编译时操作的依据是“它是否在编译时就能确定下来”。由变量构成的表达式当然不满足这样的条件（因为变量可以在任何时候发生改变），于是编译器一刀切，认为只要有变量参与，这个表达式就不能在编译期求得。

那么常量呢？看似可以，但它也不总是可行的！我们在 2.1 节中介绍过，常量是可以用变量来初始化的。

```
int g; // 定义一个临时变量g
cin >> g; // 通过输入来改变g的值
const int Grid = {g}; // 用g的值来为常量Grid初始化
```

也就是说，常量的值也未必能在编译期就确定下来。一般来说，编译器会对实际情况进行判断，如果一个常量能在编译期求出，这就是编译时行为；否则就放在运行期求出，这是运行时行为。

另外就是，字面量构成的表达式也可以在编译期求得。比如说

```
int a {15+8/2-3}; // 定义变量a并初始化为14
```

请注意，“ $15+8/2-3$ 的计算”和“定义数据并初始化”是两个过程！计算过程中只涉及字面量，所以编译器可以直接求得，这是编译时行为；而变量的定义和初始化是无法在编译期就完成的，这是运行时行为。

C++11 以后的标准允许我们定义常量表达式（Constant expression），来拓展编译时行为的可能性。我们可以把它理解成一种新型的字面量¹。

```
constexpr double Pi {3.14159}; // 定义常量表达式Pi，现在Pi是一个字面量啦
constexpr double Pi2 {Pi * Pi}; // 定义常量表达式Pi2，现在Pi2也是一个字面量
```

仅由字面量（广义地说，常量表达式）构成的表达式可以在编译期求出，比如这里的 `Pi*Pi`。但假如中间环节出现了变量，或者是不能在编译时确定下来的常量，那么就会出现问题。

```
const double Pi {3.14159}; // 定义常量Pi，它不是常量表达式，不能视为字面量
constexpr double Pi2 {Pi * Pi}; // 尝试用Pi来定义常量表达式Pi2
//error: the value of 'Pi' is not usable in a constant expression
```

编译器报错，显示信息为“`Pi` 的值不能用于常量表达式中”。这说明我们必须用常量表达式构成的表达式来定义常量表达式。

我们此前介绍过 `numeric_limits<int>::max()` 这类的写法，它也是常量表达式。编译器能够直接算出这个值，并把它当作字面量来看待，就不需要运行时再去计算了。

控制台如何处理输入/输出

源代码经过编译和链接等步骤形成的文件多种多样。有些是库文件（Library），它们可以作为目标文件（Object file）与其它文件链接，我们暂不讨论；有些是可执行文件（Executable），我们在前两章中有三个完整的.cpp 代码，可以编译成可执行文件（如果你使用 Windows，那么这类文件的扩展名就是.exe），并给我们输出执行结果。当然还有其它的形式，比如多媒体，我就不一一列举了。

可执行文件也多种多样。有些是图形用户界面（Graphical user interface, GUI）的，有些是文本用户界面（Text-based user interface, TUI），还有些则是命令行界面（Command-line interface, CLI）的。

¹事实上，常量表达式是字面量的超集。但用字面量的思路来理解常量表达式要容易得多。

早期的电脑为用户提供的都是命令行界面，用户和电脑之间通过纯文本来进行交互。这种方式不直观，也很难用，用户通过键盘来输入纯文本，电脑通过显示器来输出纯文本。这就给计算机学习造成很高的门槛。

文本用户界面主要基于文本，但相比命令行界面来说，在操作上要轻松一些。用户可以使用鼠标和键盘来控制输入。图 3.1 是一个基于文本用户界面的控制台程序。



图 3.1: Alpine, 一个基于文本用户界面的电子邮件客户端

图片来源：维基共享资源

图形用户界面则为用户提供了丰富的输入方式，输出方式也从纯文本扩展到多媒体等各种类型。它在呈现上也更为直观。一个浏览器就是一个典型的图形用户界面程序。笔者还记得自己开始用电脑的时候，很少使用键盘，基本上就是拿着鼠标在点点点。



图 3.2: Chrome, 一个典型的图形用户界面程序

C++ 功能丰富，无论是命令行界面还是文本用户界面，我们都可以用代码的方式来实现。而本书所介绍的内容全部适用于命令行界面的编程。我们写出来的程序也全部都是控制台程序（Console Application）。

我们与控制台程序的交互往往依靠键盘来实现输入，靠屏幕来实现输出²。C++ 使用流（Stream）来控制输入输出。我在键盘上按下一系列按键，最后按下回车，我的输入信息就以流的方式传递给程序，这是输入；程序得到了我的输入，再经过运算，求得我想要的结果，也以流的方式显示到控制台程序的命令行界面上，这是输出。

²并不尽然，比如可以通过文件操作，或者字符串等方式来实现输入、输出。我们会在第十三章和精讲篇中进行解释。

输入

想像一下我们使用命令行界面时的情形：如图 3.3 所示，有一个光标（Cursor）在界面上不停闪烁，等待我们输入。当我们按下一个按键，比如 d，光标的位置上就会出现一个 d，同时光标后移一位。如果我们按下退格键，光标就会前移一位，并删除上一个输入字符。如果用方向键前移光标的位置并再次输入内容，还可能把之前的输入覆盖掉³。



图 3.3: 命令行界面输入场景示例

值得注意的是回车键。在我们按下回车键之前，我们输入的内容并未实际发送给计算机，我们可以修改这些内容；而一旦按下了回车键，本行的输入内容将会发送给程序⁴，我们也没机会再修改了。

那么当我们按下回车键之后，计算机将会接收到什么输入内容呢？我们可以用这个程序来检测：

代码 3.1: Input_to_ASCII.cpp

```

// 这是一个简单的程序，用来将用户所有的输入转为 ASCII 码
// 读者无需掌握本代码的全部细节，后续会讲到
#include <iostream> // 标准输入输出头文件
using namespace std; // 使用命名空间 std
int main() { // 主函数，程序执行始于此
    char c; // 定义一个 char 变量 c 用以接收输入
    while (cin.good()) { // while 循环，当 cin 状态正常时继续循环

```

³只在覆盖模式下有效。计算机文字处理器都有输入两种模式：插入模式和覆盖模式。对于有些系统来说，命令行界面默认使用的是插入模式。

⁴这才是真正意义上完成了一次输入。

```

    c = cin.get(); //通过cin.get()接收输入，并存入c
    std::cout << static_cast<int>(c) << std::endl;
    //强制类型转换为int，故以ASCII码值形式显示输入内容
}
}

```

读者可以自行尝试这个程序。如果你单独按下一个回车键，程序会给出输出 10。这说明，回车键也是一种输入！当你按下回车键的时候，既有“发送输入内容”的作用，又有“输入一个回车字符”作用。这点我们现在还不必深究，读者只需有一个印象即可。

输出

如果说输入是我们在命令行中敲下若干字符的过程的话，那么输入就是程序在命令行中敲下若干字符的过程。⁵想象一下，在输出过程中有一个输出光标，程序每输出一个字符，光标就会后移一位；输出换行符时，程序就会换行。

以后我们会谈及更多细节，这里就不再赘述。

程序的结构

科拉多·博姆⁶和朱塞佩·雅可比尼⁷于 1966 年在论文⁸中提出了结构化程序理论（Structured program theorem）。结构化程序理论证明了，任何计算过程都可以用以下三种结构及其组合来表示：

- 一个接一个地执行一系列操作，这叫做顺序（Sequence）。
- 根据一个判断条件⁹，选择执行两个操作中的一个，这叫做选择（Selection）。
- 只要满足某个判断条件，就重复执行某个操作，直至条件不满足，这叫做循环（Iteration/Loop）。

图 3.4 是对结构化程序理论的直观解释。



图 3.4: 顺序、选择和循环结构

⁵这当然是不严谨的。一般来说输出流有缓冲区机制，会先把输出内容存入缓冲区，再一次性将缓冲区内容输出，以提高效率。程序输出的逻辑与人工输入并不相同！这里只为方便初学者理解而如是描述。

⁶科拉多·博姆 (Corrado Böhm)，意大利计算机科学家，以其对结构化程序理论和λ演算等的贡献而闻名。

⁷朱塞佩·雅可比尼 (Giuseppe Jacopini)，意大利数学家和计算机科学家，结构化程序理论的提出者之一。

⁸Flow Diagrams, Turing Machines And Languages With Only Two Formation Rules, 1966 年发表于《ACM 通讯》。

⁹一般是一个 **bool** 变量，或者可以隐式类型转换为 **bool** 类型的数据。当然，**switch** 语句是个例外。

对于顺序结构，我们已经很熟悉。我们之前已经尝试了好几个程序的代码。在这些程序的主函数中，代码的顺序就对应着程序执行的顺序。所以一个变量要先定义，后使用。

```
int a {1234}; //先定义
cout << a; //后使用
```

如果把这两句代码的顺序颠倒，编译器就会报错。

```
cout << a; //先使用
//error: 'a' was not declared in this scope
int a {1234}; //后定义
```

报错信息的意思是，“a 尚未定义”。

所以说程序运行过程中还有一个不得不关注的次序问题，我们马上就来讲解一些有关的例子。

语句的运算次序

C++ 中有一对有趣的运算符：自增运算符 `++` 和自减运算符 `--`。

自增运算符作用于各种类型的变量¹⁰，可以使它的值增加 1。自减运算符反之，可以使它的值减小 1¹¹。如果我们反复操作自增或自减运算符，可以使数据增加或减小任意值。这种性质使其在循环结构中很好用，我们之后就会介绍。

自增运算符的语法有两种，自减运算符的语法可以仿照写出来，我就不赘述了。

```
<变量> ++; //后缀自增运算
++ <变量>; //前缀自增运算
```

它们实现的功能都是为 `<变量>` 加一，但区别在于“返回值”。前缀自增的返回值是增加之后的值；而后缀自增的返回值是增加之前的值。让我们用一个很简单的例子来说明这个问题吧：

```
int a {3}; //定义 a=3
cout << a++ << '\u'; //输出 a++, 观察返回值
cout << a << endl; //输出 a, 观察 a 的值
cout << ++a << '\u'; //输出 ++a, 观察返回值
cout << a; //输出 a, 观察 a 的值
```

程序的运行结果如下：

```
3 4
5 5
```

程序给了两行输出，第一行分别是 `a++` 的返回值和 `a` 的值。可以看出，`a` 在自增之后给到的返回值依然是原来的（增加之前）3；而这时 `a` 的值其实是 4。第二行分别是 `++a` 的返回值和 `a` 的值。可以看出，`a` 在自增之后给到的返回值就是增加之后的值了。

自减运算符的道理是相同的，读者可以把上述代码中的 `++` 全部改成 `--`，先猜一下它的运行结果，然后再编译运行一下，检验你的猜想。不出意外的话，程序的运行结果应当是：

```
3 2
```

¹⁰包括整型、浮点型和字符型，乃至指针等类型。但 `bool` 型是个例外，C++17 标准起已明文禁止对 `bool` 进行自增和自减运算。

¹¹但不要忘记每个类型都有它的范围和精度限制。对 `int` 表示范围的最大值自增将会发生溢出；对 `1e50` 这种过大的数据自增/自减已经超出了其精度承受范围。

1 1

一些人会把前缀自增/自减和后缀自增/自减的区别解释为“前缀写法是先加后用，后缀写法是先用后加”。这种理解方式很直观，先加后用就是先增加，再提供返回值；先用后加就是先提供返回值，再增加。

但是我在那里也要提醒读者，这种理解方式未必是正确的！对于内置类型的自增/自减运算来说，不同编译器可能给出不同的运算方式。如果读者能够理解汇编¹²代码，可以比较一下 x86 msvc v19.38 和 x86-64 gcc 13.2 如何编译这段代码：

```
int a {3}, b {a ++};
```

答案是，x86 msvc v19.38 将后缀自增处理为“先用后加”，先返回这个变量本身，再进行自增运算；而 x86-64 gcc 13.2 将后缀自增处理为“先加后用”，先进行自增运算，再提供返回值，而且此处的返回值不是这个变量本身，而是一个存储了原先值的临时变量。

Compiler	Assembly Code (Hex)
x86 msvc v19.38	<pre> 1 b\$ = -8 2 _a\$ = -4 3 _main PROC 4 push ebp 5 mov esp, ebp 6 sub esp, 8 7 mov DWORD PTR _a\$[ebp], 3 8 mov eax, DWORD PTR _a\$[ebp] 9 mov DWORD PTR _b\$[ebp], eax 10 mov ecx, DWORD PTR _a\$[ebp] 11 add ecx, 1 12 mov DWORD PTR _a\$[ebp], ecx 13 xor eax, eax 14 mov esp, ebp 15 pop ebp 16 ret 17 _main ENDP </pre>
x86-64 gcc 13.2	<pre> 1 main: 2 push rbp 3 mov rbp, rsp 4 mov DWORD PTR [rbp-4], 3 5 mov eax, DWORD PTR [rbp-4] 6 lea edx, [rax+1] 7 mov DWORD PTR [rbp-4], edx 8 mov DWORD PTR [rbp-8], eax 9 mov eax, 0 10 pop rbp 11 ret </pre>

图 3.5: 后缀自增运算在不同编译器下的汇编代码

左图为 x86 msvc v19.38；右图为 x86-64 gcc 13.2

编译支持：[Compiler Explorer](#)

读者尚无必要去纠结这些细节，只需从这个例子中体会到，很多时候，我们或别人“总结”出来的规律只是一种管中窥豹，仅在一定范围内是正确的；一旦离开这个范围，这些规律非但可能不适用，还有可能会为我们准确理解事物逻辑造成更大的障碍。所以读者必须具备这样的意识，对于各种第三方——包括本书在内——总结出来的“规律”保持警觉，并最好通过亲手操作的方式来验证之。

回到自增/自减运算。考虑这样一个赋值语句：`b=a++`。自增/自减运算符的优先级比赋值运算符的优先级高，所以它可以解释为 `b=(a++)`。我们可以进一步把这个过程拆解成三个操作：赋值，`a` 增加一，以及 `a++` 提供返回值。那么问题来了，哪个操作在先，哪个操作在后呢？这就是次序（Order）问题了。

首先我们不难理解，“`a++ 提供返回值`”这个操作肯定要早于“赋值”操作。否则赋值语句就不知道该赋什么值。既然要算出返回值，那么赋值运算符右边的所有操作都应在赋值之前做完，于是“`a 增加一`”这个操作肯定也早于“赋值”操作。

接下来问题来了，“`a 增加一`”和“`a++ 提供返回值`”这两个操作谁先谁后呢？刚才我们就看到了，不同编译器会给出不同的操作次序。但是无论以何种次序以何种次序计算，编译器总会给出正确的结果。¹³

¹²汇编语言（Assembly language），是一类用于各种可编程器件的低级语言。汇编语言不是一个单一的语言，它是一系列语言的统称。汇编语言的指令集严重依赖于具体的器件，不同的器件可能采用不同的指令集，因而汇编代码的移植性很差。

¹³我们也称之为“不定序”。一般来说，这种不定序的情况不会影响到我们的日常编程，因为结果总是一样的。但是也请注意防范“未定义行为”的发生，我们会在后面讲到。

但是并非所有这类操作都能给出“正确的结果”——或者说，压根就没有正确的结果！一个最经典的例子就是

```
int a {0};
cout << a++ + a++;
```

这段代码在不同编译器下的结果是不同的，而且也没有标准答案！其原因在于，加法运算符并不确定左右各个操作的顺序。

如果要追究本源，这就要看 C++ 标准是如何规定的了。C++17 起的标准明确规定，= 右端的所有值计算和副作用发生¹⁴都要早于左端的任何值计算和副作用发生。而 C++ 标准仍未规定加法运算符两端操作的运算次序，所以不同编译器就有不同的理解。

逻辑运算符

在 C++ 标准中，有三个逻辑运算符：逻辑非 (!)、逻辑与 (&&) 和逻辑或 (||)。它们在选择和循环结构中很常用，所以在这里不得不提。我们在前面已经分析了很多运算符，这里只要按照相同的思路来分析就可以了。先来分析逻辑与运算符。

a && b		b	
		false	true
a	false	false	false
	true	false	true

a b		b	
		false	true
a	false	false	true
	true	true	true

a	! a
false	true
true	false

图 3.6: 逻辑与、逻辑或、逻辑非运算符的真值表

逻辑与运算符只能接收 `bool` 类型的操作数；非 `bool` 型的操作数都会通过[布尔转换](#)来变成 `bool` 型。

逻辑与运算符的返回值也是 `bool` 类型，只有当两个操作数的值都为 `true` 时，它的返回值才是 `true`，否则就是 `false`。

逻辑或运算符和逻辑与运算符很相像，唯一的区别是返回值，只有当两个操作数的值都为 `false` 时，它的返回值才是 `false`，否则就是 `true`。

简单说来，逻辑与运算符要求两个操作数都为真，而逻辑或运算符要求两个操作数有至少一个为真¹⁵。

逻辑非运算符比较特殊，它只有一个操作数¹⁶，而且只能以前缀的形式表达。`!a` 是正确的，但 `a!` 就不对了。

逻辑非的功能不复杂：如果操作数的值是 `true`，返回值就是 `false`；如果操作数的值是 `false`，返回值就是 `true`。但是要注意：逻辑非运算符不能直接改变操作数的值，这和自增/自减运算符是不

¹⁴值计算和副作用将在第四章讲解。在此之前我们可以把它们当作所有操作的统称。

¹⁵在不同语境下，自然语言中的“或”可能指的是“互斥或”或者“可兼或”。而编程语言中的“异或”与“或”是有很明确的规则的，不可混淆。

¹⁶像逻辑非、自增/自减运算符这种仅有一个操作数的运算符，我们有时称它们为一元运算符或单目运算符。

一样的。比如 `!a`, 完了之后 `a` 的值是不变的。

关于这三个运算符的优先级和结合性, 读者可以自行查阅附录 A 的表, 我这里就不谈了。图 3.6 是这三个运算符的真值表, 读者可以对照此表, 加深对这三种运算符的印象。

至于运算次序, C++ 对于逻辑与/逻辑或运算符的运算次序有明文规定, 运算符左边的操作必须早于右边的操作完成。

短路求值

逻辑与/逻辑或运算符有一个短路求值 (Short-circuit evaluation) 的特性。对于 `&&` 运算符来说, 如果左操作数的值算完了, 发现是 `false`, 那么无论右操作数的值是什么, 整个表达式的返回值都只可能是 `false` 了。于是程序为了节省时间, 就会跳过右操作数的计算。

```
constexpr int init {0}; // 定义常量表达式init, 值为1
int a {init}; //用init来初始化变量a
a++ && a++; //用&&连接两个a++, 预期会使a自增两次
cout << a - init; //a当前值减去初始值, 预期输出2
```

这个程序的最终输出为: 1。这可能有点令人吃惊, 但仔细分析一下, 你就会明白其中原因了。

在 `a++ && a++` 语句中, `&&` 的左操作数会优先计算 (C++ 标准明文规定), 这里 `a++` 后缀自增, 使 `a` 变为 1, 而返回值为 0。

根据布尔转换规则, 0 将转换为 `false`, 这说明无论右操作数为何, 整个计算的结果必然是 0, 于是右操作数的计算过程被跳过, 到输出的时候, `a` 还是 1, 减去 `init` 当然就是最终结果 1 了。

读者可以把 `init` 改为 1 或者是其它数, 输出结果将变为 2。

关于 `||` 的短路求值是同理的, 如果左操作数的值是 `true`, 就会跳过右操作数的计算过程。这不是本章的重点, 所以我就不再赘述了。

3.2 选择结构

在此之前我们遇到的代码都是顺序结构的, 程序一个接一个地执行一系列操作。仅用顺序结构是不能完成复杂工作的, 比如根据一定的条件, 作出不同的反应。这时我们就需要用到选择结构了。

`if-else` 结构是最常用的选择结构, 而 `switch-case` 结构在处理特定的条件判断时, 会更加高效。本节我们就来介绍这两种结构。

if-else 结构

`if-else` 结构的基本格式是这样的:

```
if (<条件>) { //if是必需的
    <若干操作>;
}
else { //如果不需要else部分, 可以不写
    <若干操作>;
}
```

其中的 `<条件>` 要么是一个 `bool` 数据, 要么是可以隐式类型转换为 `bool` 数据的表达式。

这个结构其实不复杂, 我说一遍你就懂了: 如果 `<条件>` 为 `true`, 那么程序就会执行 `if` 块内的代码, 跳过 `else` 块内的代码; 如果 `<条件>` 为 `false`, 那么程序就会跳过 `if` 块内的代码, 执行 `else` 块内的代码。当然, 如果只有 `if` 块而无 `else` 块, 规则就更简单了。

初学者一般都会见过这样的问题：输入一个正整数，要求程序判断它是奇数还是偶数，并输出相应的内容。我们就用 **if-else** 结构来设计这样一个程序。在设计之初，我们需要想清楚一个问题：如何判断一个正整数的奇偶？

我们希望有一个表达式，它要么是 **bool** 类型的，要么可以通过布尔转换成为 **bool** 类型，并且能提供“某正整数是奇数还是偶数”这个信息。这里我们选择取模运算，因为一个正整数在对 2 取模运算后得到的值只能是 0 或 1——如果这个数是奇数，那么得到 1；如果是偶数，那么得到 0。

那么有了模运算的结果之后，如何把它表达成一个“条件”呢？这里我们可以使用两种方法：其一是直接把它作为条件，这个运算的结果会隐式转换为 **bool** 类型，奇数意味着 **true**，偶数意味着 **false**；第二种方法是用相等性运算符 ==^{17} ，我可以用计算结果和 1 比较，等于 1 意味着 **true**；不等于 1 就意味着 **false**。

好，到这里我们已经想清楚了关键部分，那么接下来我们梳理一下我们的程序需要做什么：

1. 定义整型变量（可以使用 **int**，或者考虑到输入一定是正数而使用 **unsigned**），以便后续输入。
2. 输入这个数。
3. 再定义一个数，用来保存这个数对 2 取模的值。
4. 写一个选择结构（**if-else**），根据上一步的值是否等于 1 来采取不同的操作。（这里采用第二种方法）

有了基本的设计思路之后，我们可以开始写代码了。

首先，定义整型变量。我们可以任意起名，但最好起一些有实际含义的名字，这样我们一眼就能知道它是什么，代表什么。比如说，我们就给它起名叫 **num** 吧。

```
int num; // 也可以用 unsigned
```

接下来是输入部分，很简单，用 **cin>>** 就可以了。

```
cin >> num; // 输入 num 的值
```

然后我们定义一个新的变量，可以叫 **mod**，来保存模值。因为这个模值不需要改变，我们可以选择将其定义为 **const** 常量，来防止误改动。

```
const int mod {num % 2}; // num 模除 2 的值；也可以不用 const
```

最后是整个程序最关键的部分：选择结构。我们以 **mod==1** 作为条件，在这个 **if** 块内让程序输出“奇数”，而在 **else** 块内让程序输出“偶数”。

```
if (mod == 1) { // 如果 mod 为 1 满足，mod==1 返回值就是 true，执行此段
    cout << "奇数"; // 输出 "奇数"
}
else {
    cout << "偶数"; // 输出 "偶数"
}
```

这个程序的流程图如图 3.7 所示。可以看出，前面部分是顺序结构，后面部分是选择结构。

最后 Ctrl+V 一下文件包含等等乱七八糟的代码，就是这样：

代码 3.2: **odd_or_even.cpp**

```
// 这段代码可以判断输入的正整数是奇数还是偶数
#include <iostream>
```

¹⁷前面介绍过，当相等性运算符的左右操作数相等时，返回值为 **true**；不相等时，返回值为 **false**。



图 3.7: 奇偶判断程序流程图

```

using namespace std;
int main() { // 主函数，代码顺序执行
    int num; // 也可以用unsigned
    cin >> num; // 输入num变量
    const int mod {num % 2}; // num模除2的值；也可以不用const
    if (mod == 1) { // 选择结构
        cout << "奇数";
    }
    else {
        cout << "偶数";
    }
    return 0;
}
  
```

读者可以自行测试一下，例如输入 1，程序就会给出输出 奇数；输入 2，程序就会给出输出 偶数。

如果甲方有什么其它的奇怪要求，比如“如果是偶数就输出，如果是奇数就不输出”，这时我们就只需要为偶数部分写一个 `if` 块即可，没有必要再写 `else` 块，代码可以这样写：

```

if (mod == 0) { // 注意，判断条件是mod是否为0
    cout << "偶数"; // mod为0说明它是偶数
} // 奇数时什么也不做，那就不需要写else了
  
```

多路分支的选择结构

刚才接触到的选择结构是两路分支的，我们可以用一个简单的 **if-else** 结构来实现这样的功能。但是有些时候我们需要实现更复杂的多路分支。现在我们需要写一个程序，输入单个字符，并判断它是“大写字母”“小写字母”“数字”还是“其它”，那么我们要怎么做呢？

首先，我们要知道我们应该用什么样的“判断条件”。如何判断一个字符（起个名字，`ch`）是大写字母呢？或许我们可以连用逻辑或来构成一个表达式

```
if (ch == 'A' || ch == 'B' || ch == 'C' || <此处省略23个>)
```

但这样写毕竟还是太麻烦了。我们可以用下面的简单方法来实现：

```
if (ch >= 'A' && ch <= 'Z')
```

还记得我们之前反复提及的 ASCII 码值吗？'A' 到 'Z' 在 ASCII 码表里是连续排列的，如果 `ch` 是 26 个大写字母之一，那么它一定在大于等于 'A' 且小于等于 'Z' 的范围内；相反，如果它不是 26 个大写字母之一，那么它一定不在这个范围内。同样的道理，我们可以用 `ch>='a'&&ch<='z'` 来判断它是不是小写字母，用 `ch>='0'&&ch<='9'` 来判断它是不是数字。

关于条件，我们想清楚了，那么如何实现多路分支呢？我们可以看一下这段代码的实现方式：

```
if (ch >= 'A' && ch <= 'Z') { // 判断是否为大写字母
    cout << "大写字母";
}
else if (ch >= 'a' && ch <= 'z') { // 判断是否为小写字母
    cout << "小写字母";
}
else if (ch >= '0' && ch <= '9') { // 判断是否为数字
    cout << "数字";
}
else { // 其它情况
    cout << "其它";
}
```

有些参考资料将其称为 **if - else if - else** 结构，以 **if** 加条件为开头，中间全用 **else if** 加条件的形式，结尾用 **else**。

但是以我个人的观点来看，实际上并没有 **else if** 这个关键字。它是 **else** 嵌套了 **if** 的结构，本质上只是对 **if-else** 结构的一种特殊应用。这段代码与下面的代码并无任何区别¹⁸：

```
if (ch >= 'A' && ch <= 'Z') {
    cout << "大写字母";
}
else
    if (ch >= 'a' && ch <= 'z') {
        cout << "小写字母";
    }
    else
        if (ch >= '0' && ch <= '9') {
            cout << "数字";
        }
```


¹⁸与 Python 等一些语言不同，C++ 对代码的缩进、换行和标识符间的空格几乎没有限制，所以缩进的修改、换行的使用，乃至特定情况下是否套花括号 {} 都不会对编译造成影响。

```

else {
    cout << "其它";
}

```

这样就是 **if-else** 方式理解了。所以 **else if** 只不过是一种更紧凑的写法而已，不能称为一个“关键字”。它的 **else** 部分属于上一个 **if-else** 结构，而 **if** 部分属于下一个 **if-else** 结构。图 3. 描述了这样一种结构是如何搭建起来的。



switch-case 结构

switch-case 结构是一种在特定情况下可以方便地实现多路选择的选择结构。它的基本语法是

```

switch (<整型数据>) {
    case <字面量>: // 判断分支
        <操作>
        break; // break 并非必需，但请注意后果
    case <字面量>: // 判断分支
        <操作>
        break;
    default: // 默认情况
        <操作>
        break; // break 并非必需，尤其对于最末的 case 而言
}

```

switch-case 结构与 **if** 结构不同，它的判断是通过“匹配”进行的。

switch 块中的每个 **case** 都是一个标签，能对某个位置进行标记。**switch** 跟随的整型数据将会去匹配每个 **case** 标签后的字面量¹⁹。一旦匹配到了合适的字面量，程序就会从本句开始顺序执行。

¹⁹ 其实不光是字面量，所有常量表达式都是可以用的。

现在我们要输入一个 1~6 之间的正整数，并输出它的英文 (one, two, ...); 如果输入不是 1~6 之间的正整数，就什么也不做。我们可以按照下面这个使用 **switch-case** 结构的代码来实现这个功能。

```
int num; // 定义待输入变量，注意必须用整型、字符型或布尔型
cin >> num; // 输入 num 的值
switch (num) {
    case 6: // case 可以从 1 到 6，也可以从 6 到 1，也可以打乱顺序，对应即可
        cout << "six" << endl; // 如果 num 匹配 6，就从这里开始顺序执行
        break; // 用 break 来退出 switch 块
    case 5:
        cout << "five" << endl; // 如果 num 匹配 5，就从这里开始顺序执行
        break;
    case 4:
        cout << "four" << endl;
        break;
    case 3:
        cout << "three" << endl;
        break;
    case 2:
        cout << "two" << endl;
        break;
    case 1: // 最末的 case 可以不加 break
        cout << "one" << endl;
}
}
```

可以看出，这样写要比用 **else if** 然后加一众 `num==` 的方式要简洁一些。读者可以自行测试这段代码，看看效果。

switch-case 结构有一个特性，叫做穿透效应（Fallthrough behavior）。因为 **case** 只是一个标签，不能起到退出 **switch** 结构的作用，所以如果在写每个 **case** 之后不加以 **break** 的话，程序将会继续运行下一个 **case**、再下一个 **case**，直到遇到一个退出语句或者运行到 **switch** 的末尾为止。

举个例子来说，如果上面的代码不加 **break** 的话，程序运行的结果将是这样的²⁰:

```
4
four
three
two
one
```

而加上了 **break** 之后就会得到这样的运行结果:

```
4
four
```

我们还可以做合并标签的操作，这个效果相当于“如果 <整型数据> 匹配了 <字面量1> 或者 <字面量2>，就从这里开始执行”。

²⁰本书默认：键盘输入的内容用黑体标识，程序输出的内容不用黑体。换行符不单独显示，行末空格和回车也忽略掉。如有特殊情况，会特别说明。

举个例子，某个百分制的成绩根据分数划定等级，90~100 分定为 A, 80~89 分定为 B, 70~79 分定为 C, 60~69 分定为 D, 0~59 分定为 E。我们可以用 **switch-case** 结构来实现输入成绩，输出等级的操作。

首先思考一下我们该用什么思路。如果直接按照 100 分制来写 **case** 的话，那么我们要为 **score**（代表分数的整型变量）变量写 100 个 **case**，这个实在太麻烦了。即便考虑到可以用 **default** 来表示 60 分以下的情况，我们也要为 60 及以上的分数写 41 个 **case**。这还不如用 **if-else** 呢，好歹这种方式可以表示范围。

为了简化我们的代码，我们可以取个巧：用 **score/10** 来匹配数据（还记得吗，整型变量的除法是自动截尾的）。这样我们就只需为 6, 7, 8, 9 和 10 来写 **case** 了。

```
switch (score / 10) { //用 score/10 来匹配数据
    case 10:
    case 9: //合并 9 和 10 两个 case, 如果匹配 9 或 10 都从这里开始顺序运行
        cout << "A" << endl; //输出 A
        break; //不要忘记 break, 否则还会顺序执行后面的代码
    case 8:
        cout << "B" << endl;
        break;
    case 6: //打乱 case 的顺序? 完全没问题, 编译器不会误解的
        cout << "D" << endl;
        break;
    case 7:
        cout << "C" << endl;
        break;
    default: //如果以上均不匹配, 就应该是 E 等了吧
        cout << "E" << endl;
        break; //最末 case 可不加 break, 加了也行
}
```

3.3 循环结构

在上一节，我们通过选择结构来实现一些“判断”的功能。但是我们的程序还有一些美中不足：它们只能单次运行。每次我打开这个程序，输入完毕再得到一次输出，然后程序就终止了。如果我要多次输入，我就要反复打开程序——这就太麻烦了。所以我希望有一个程序，能够接收任意多次的输入，并在我给定某个条件后终止。循环结构就可以起到这样“反复执行”的作用。

for 循环和 **while** 循环都是常用的循环结构，而 **do-while** 结构用得比较少。另有一些循环算法，比如 **for_each**，我们留到精讲篇再介绍。

while 结构

while 结构的基本格式是这样的：

```
while (<条件>) {
    <若干操作>;
}
```

它与 **if** 结构非常相似，区别仅仅在于，**if** 结构中的内容只会运行一次；而 **while** 的内容可以反复运行（循环）。**while** 结构的规则是：如果 <条件> 为真，那么执行 **while** 块内的若干操作；执行完毕后如果 <条件> 依然为真，那么再次执行若干操作。

那么我们就用 **while** 结构来修改一下我们的奇偶数判断程序，使它可以无限次接收输入——那意思就是需要无限循环。所以最简单的方法就是用 **true** 当作条件了，这样它就永远不会执行下去。

```
int num; // 定义 num
while (true) { // while 的<条件>永远为 true，所以它是无限循环
    cin >> num; // 每次输入一个 num 的值
    const int mod {num % 2}; // num 模除 2 的值
    if (mod == 1) { // 如果 mod 为 1 满足，那么 num 就是奇数
        cout << "奇数" << endl;
    }
    else { // 否则 num 就是偶数
        cout << "偶数" << endl;
    }
}
```

这段代码的结构是 **while** 套上 **if-else**，有点像俄罗斯套娃。其实，这种结构与结构之间的嵌套（Nesting）在程序设计中是普遍存在的。

我们可以想像自己就是一个程序，按照顺序的方式执行代码，遇到 **while** 就检测要不要循环，遇到 **if** 就检测要走哪个分支，想必会更容易理解这种过程。

1. 在程序定义了 **num** 之后，因为 **while** 的条件是 **true**，所以循环块的代码开始执行。
2. 当用户输入了一个值之后，程序会定义 **mod** 来存储 **num** 对 2 的模值。接下来判断 **mod**，并给出相应的输出。至此，一次循环完成。
3. 程序检测 **while** 的条件，因为条件是 **true**，所以循环块的代码开始执行（回到上一步）。

读者可以自行测试这个程序的功能。

让我们思考一下另一个问题：如果用户输入很多次之后要结束程序了呢？我们的 **while(true)** 结构就不尽如人意了——它永远不能自己停下来。虽然我们自己测试的时候可以用窗口上方的关闭按钮来强行关闭，但这一招并不是在任何时候都管用的。现在我们要想一种新的写法，用户可以通过输入特定的内容来结束程序。

一种思路是，输入 **-1** 结束程序。因为用户必须输入正整数，所以 **-1** 已经是非法输入了，不会与程序的正常功能相冲突。那么我们可以试着把这段代码写出来：

```
int num {0}; // 定义 num，这里必须初始化，因为 while 中就需要用到 num 的值
while (num != -1) { // 如果 num 不等于 -1，就说明用户还需要继续输入
    cin >> num; // 每次输入一个 num 的值
    const int mod {num % 2}; // num 模除 2 的值
    if (mod == 1) { // 如果 mod 为 1 满足，那么 num 就是奇数
        cout << "奇数" << endl;
    }
    else { // 否则 num 就是偶数
        cout << "偶数" << endl;
    }
}
```

这段代码看上去好像满足了我们的要求。但是真的是这样吗？以下是一个程序运行示例：

```
5
奇数
8
偶数
1
奇数
-1
偶数
```

至此程序结束，但是好像出现了一些问题：

- 输入 `-1` 之后，程序应该直接结束，而不是继续给输出一个结果，然后再结束。这说明我们的程序逻辑可能有一些问题。
- 另外，当我们输入 `-1` 之后，即便它多做了一次判断，也不该输出“偶数”这个结果。这说明我们的判断逻辑可能也有潜在问题。

我们先来分析第一个问题。其实只要你把自己想像成程序，然后模拟一下整个过程，就可以理解问题何在了。当用户输入 `-1` 之后，程序并不会直接终止，而是继续顺序执行“定义 mod”“判断和输出”这些步骤。要解决这个问题，我们可以用后面讲到的 `break` 语句，或者把程序的逻辑修改成这样：

```
cin >> num; //在while块之外先接收一次输入
while (num != -1) {
    //定义mod和选择结构部分的代码省略
    cin >> num; //在循环末尾接收下次输入，这样下一步就会进行条件判断
}
```

另一个问题是我们的选择结构，貌似在输入 `-1` 时会判断为偶数。负整数并不是本程序的预期输出，所以这个问题可以无视；但出于知识学习的目的，我在这里需要讲一下。这个问题的根源在于我们的取余操作，**负数对正数取余得到的结果可能是负数！**

因此 $-1 \% 2$ 的结果是 `-1`，它当然不等于 `1`，所以就会被归入 `else` 状况之下，给出 “偶数”的输出。

解决方法可以是把 `if` 的条件改为 `mod==1 || mod===-1`，用来判断负奇数；或者是直接用 `mod==0` 判断偶数，而把剩下的情况当作奇数来对待。以下是实现代码：

```
int num; //定义num，可不初始化
cin >> num; //先输入第一个num
while (num != -1) { //如果num不为-1，就继续循环
    const int mod {num % 2}; //num模除2的值
    if (mod == 0) { //判断是否为偶数
        cout << "偶数" << endl;
    }
    else { //mod可能是1或-1，我们把它们都归入else中
        cout << "奇数" << endl;
    }
    cin >> num; //接收下一个输出，下一步就会判断num是否为-1
```

```

}

cout << "程序结束"; // 输出一个提示语，告诉用户程序结束

```

图 3.9 是这个程序的流程图，读者可以参考它来理顺这个代码的逻辑。

我们发现，这个程序不仅可以判断正整数的奇偶，还可以判断负整数的奇偶。因此，它的功能可以得到拓展。不过这样就会出现一个新的问题——输入 -1 的时候怎么办呢？如果还把 -1 作为判断程序结束的标志，那我们就不能通过这个程序来判断 -1 的奇偶；如果输入 -1 的时候也要给出奇偶判断，那么我们就应该用新的方式来标记程序结束。比如说，如果用户输入一个 q (或者别的字母)，我们就结束程序。



图 3.9: while 循环奇偶判断流程图

这种实现方式是可行的，并且相当好用。我在这里先放代码，然后再做解释：

代码 3.3: while 循环奇偶判断

```

// 这是一个基于while循环的奇偶判断程序，当输入为字母时停止循环
#include <iostream> // 标准输入输出头文件

```

```

using namespace std; //命名空间使用
int main() { //主函数
    int num; //定义num, 可不初始化
    while (cin >> num) { //输入num并使用cin的返回值作为判断条件
        const int mod {num % 2}; //num模除2的值
        if (mod == 0) { //判断是否为偶数
            cout << "偶数" << endl;
        }
        else { //mod可能是1或-1, 我们把它们都归入else中
            cout << "奇数" << endl;
        }
    }
    cout << "程序结束"; //输出一个提示语, 告诉用户程序结束
}

```

这里最巧妙的操作在于使用 `cin>>num` 作为 `while` 循环的判断条件。前面我们提过, `cin>>num` 的返回值还是 `cin` 本身。而 `ostream` 类重载了 `operator bool`, 所以作为 `ostream` 类的对象, `cin` 可以被隐式类型转换为 `bool` 类型, 这是它能作为判断条件的前提。

那么什么情况下 `cin` 会被隐式类型转换为 `true` 呢? 就是在输入状态一切正常的情况下。在 C++ 中, 有很多情况会导致输入状态不正常, 比如:

- 期望输入的是一个整数, 但输入了非数字的字符, 或者输入了浮点数²¹。
- 遇到了 EOF²²。
- 其它可能导致 I/O 错误的软/硬件问题。

一般情况下 `cin` 的状态是正常的, 转换为 `bool` 类型后返回 `true`; 而一旦遭遇这些情况, `cin` 的状态就会改变, 从而转换为 `bool` 类型后返回 `false`。

所以说, `while(cin>>num)` 实现的功能是: 先输入一个 `num`, 然后返回值 `cin` 被隐式类型转换为 `bool`。如果输入的是整数, 那就一切正常, 返回 `true`, 那就进入循环; 如果输入的是字母 `q`, 或者别的字母, 那就返回 `false`, 那就不会进入循环。²³

for 结构

`for` 结构的基本格式是这样的²⁴:

```

for (<初始化语句>; <条件>; <迭代操作>) {
    <若干操作>;
}

```

`for` 圆括号内的三个部分都可以留空不填²⁵。

`for` 循环和 `while` 循环一样, 都可以用来执行循环。如果不考虑一些特殊的情况(比如条件留空或含 `continue` 语句), 上述 `for` 循环结构完全等价于下面的 `while` 循环:

²¹ 输入浮点数的情况更加特殊, 程序会把小数点之前的部分单独作为一个整数来处理(表征出来就是, 多循环了一次), 而将小数点作为非数字字符阻断, 留到下次输入。

²² 文件结尾(End-of-file)是一个特殊的标记, 表示程序不能再从信息源读取更多信息。EOF 不是 ASCII 中的一部分, 不过有些系统会用值为 -1 的字符型数据来表示它。

²³ 值得注意的是, 如果输入浮点数, 情况还有会有所不同。这里就不再深究了。

²⁴ C++11 起另有一个很好用的范围 `for` 循环, 但是现在还没到讲它的时候。

²⁵ 这点与 `if` 和 `while` 结构都不同, 它们的 <条件> 如果留空, 那就不知做什么了。

```
{
    <初始化语句>;
    while (<条件>) {
        <若干操作>;
        <迭代操作>;
    }
}
```

所以理论上，我们可以用 **while** 循环来替代所有常规的 **for** 循环，但 **for** 循环写起来比较简洁（尤其是在涉及数组数据处理方面），所以 **for** 是相当常用的循环语法。关于循环的思路，我已在 **while** 循环部分介绍过，这里就着重介绍一下 **for** 循环的特殊语法。

首先是 <初始化语句>。虽然叫做“初始化”，但既可以是定义语句，又可以是赋值语句（对先前已经定义过的变量赋值），甚至还可以是其它类型的语句，比如输入、输出、计算等各种类型。之所以叫做“初始化”语句，只是因为实际编程中我们一般在这里进行循环的初始化²⁶，而不是做些别的杂七杂八的工作。初始化语句部分只会执行一次。

其次是 <条件>。**for** 结构中的条件允许留空，留空的话将默认以 **true** 作为条件。条件会在每次循环开始前都执行一次。

最后是 <迭代操作>。迭代操作永远在 **for** 块内的 <若干操作> 运行完毕后才会执行。值得注意的是，即便在 **for** 块内执行了 **continue** 语句，迭代操作也是不会被跳过的，它依然会执行。迭代操作会在每次循环结束后都执行一次。

以下是一个典型的 **for** 循环输出 1 到 10 的示例代码：

```
for (int i=1; i<=10; ++i) { // 定义并初始化 i，从1起到10止，每次循环自增
    cout << i << endl; // 输出i的值并换行
}
```

接下来我们分析一下这段代码的内容：

首先，定义并初始化 **i** 的值为 1，这是循环初始化的部分。接下来会判断条件，因为此时，**i<=10** 的返回值为 **true**，所以循环部分开始执行，程序输出 1 并换行。最后迭代操作执行，**i** 变为 2。

下一次，先判断条件，此时 **i<=10** 的返回值依然为 **true**，所以循环部分开始执行，程序输出 2 并换行。最后迭代操作执行，**i** 变为 3。

中间的部分同理，不再赘述。

直到 **i** 的值为 10，此时 **i<=10** 的返回值为 **false**，所以循环部分开始执行，程序输出 10 并换行。最后迭代操作执行，**i** 变为 11。

下一次，因为判断条件 **i<=10** 的返回值为 **false**，这个循环不再运行，宣告终止。

各种 **for** 循环结构还可以嵌套，形成更复杂的代码，从而实现更复杂的功能。比如下面的代码是一个两层 **for** 循环，实现的功能是按照 5×5 的布局输出 1~25 的数字。

```
for (int i = 0; i < 5; i++) { // i++ 与 ++i 的效果相同
    for (int j = 1; j <= 5; j++) {
        cout << i * 5 + j << ' ';// 每输出一个数字，以空格隔开
    }
    cout << endl; // 每输出五个数字，以换行隔开
}
```

请留意，外层 **for** 循环的初始化为 **int i=0**，条件为 **i<5**；而内层循环的初始化为 **int j=1**，条件为 **j<=5**。

²⁶ 所谓“循环的初始化”指的是每次循环开始要预先做的准备工作，而不是在定义变量时做的初始化。

同样是循环 5 次，为什么使用不同形式的初始化和条件呢？读者可以尝试修改它的初始化和条件，然后自行观察输出结果，想必就能领会到其中关键所在了。

do-while 结构

do-while 结构非常容易理解，它的基本格式是这样的：

```
do {
    <若干操作>;
} while (<条件>);
```

它与 **while** 结构的区别是：**while** 结构会先检验条件，判断是否运行 **while** 块内的部分；而 **do-while** 结构会先运行块内部分的 <若干操作>，再检验条件，判断是否再次运行块内的部分。正因如此，**do-while** 结构会保证它的块内代码至少运行一次。

这种结构在我们日常编程中用途有限，而且也完全可以用 **while** 或 **for** 替代，所以这里就不展开讲了。

continue 和 break 语句

在循环结构中常常还会用到 **continue** 或 **break**，它们可以为我们写代码带来方便。鉴于我们已经在 **switch-case** 结构中介绍过 **break** 语句，那我们就先来讲讲它吧。

break 可以用于循环结构或 **switch-case** 结构中，其作用是退出当前所在的循环或 **switch** 块。

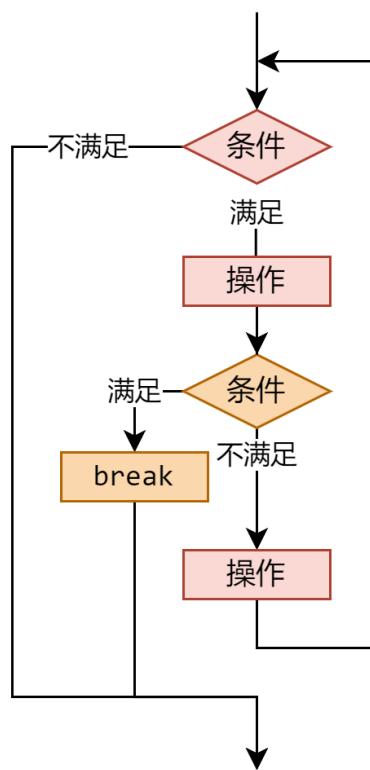


图 3.10: **break** 结构的流程图

举例来说，我们可以用这种方式来重写代码 3.3 的主函数部分，效果相同。

```
int num; // 定义 num，可不初始化
while (true) { // 永远循环，靠内部的break可以退出循环
```

```

    cin >> num; // 输入 num
    if (!cin) { // 如果 cin 状态不正常，将执行 break 语句
        break; // 退出该循环
    }
    if (num % 2 == 0) { // 可以不用定义中间变量 mod，直接用 num%2 来表示
        cout << "偶数" << endl;
    }
    else {
        cout << "奇数" << endl;
    }
}

```

在这里，我们用 `!cin` 来作为判断条件，如果 `cin` 遭遇了不正常输入，它隐式转换会得到 `false`，那么 `!cin` 就是 `true`，于是 `break` 就会执行。

在 `while` 语句中，`break` 执行的效果是直接退出循环，后面的内容也不再执行。在 `for` 语句中，`break` 执行的效果也是直接退出循环，而且迭代操作也不会执行（因为即将退出循环，就没有迭代的必要了）。

读者需要特别注意：`break` 语句只能退出当前所在的循环或 `switch-case` 结构，而且只能退出一层。我们不能使用 `break` 来退出 `if` 块（至少不能仅以退出 `if` 块为目的）。在上面的代码中我们也能看到，使用 `break` 的目的不是为了退出 `if(!cin)`（虽然事实上也实现了这样的效果），而是为了退出 `while(true)`。

请读者分析下面的代码，并猜测可能的输出结果，然后再自己运行一下，加以验证。

```

for (int i=0; i<5; i++) {
    for (int j=1; j<=5; j++) {
        if (i + j > 6) // 如果 i+j>7 就退出
            break; // 会退出到哪里呢？
        cout << i * 5 + j << ' ';// 每输出一个数字，以空格隔开
    }
    cout << endl; // 换行
}

```

实际的运行结果是

```

1 2 3 4 5
6 7 8 9 10
11 12 13 14
16 17 18
21 22

```

从结果上可以看出，`break` 只退出了内层的 `for` 循环，而不会退出外层的 `for` 循环。否则它应该输出到 14 就彻底终止了。

再来看 `continue`。它只能用于循环结构中，作用是跳过后面的代码，直接开始下一轮循环。

需要特别注意的是，`continue` 用在 `for` 循环中，不会跳过迭代操作。也就意味着，在 `for` 循环中使用 `continue` 不是“重新开始本轮循环”，而是“直接从下一轮循环开始”。

`continue` 的用途很广泛，我们来举个实际一点的例子：有些时候，我们需要用户输入一些数字，但我们没有一个机制来防止用户输入不合理的内容（比如，需要用户输入数字，但用户却输入了字母）。一旦用户输入了不合理的内容，`cin` 就会进入错误状态，然后拒绝再读取输入。

图 3.11: `continue` 结构的流程图

为了让 `cin` 读取输入，我们需要清除状态，并清理输入流。我们暂时还不必关注这么多细节，我可以用一个简单的函数来把这项工作包揽：

```

void input_clear() {
    cin.clear(); // 清除错误状态
    while (cin.get() != '\n') // 清除本行输入
        continue;
}

```

我们会在下一章讲函数，在此之前你只需要管怎么使用就可以了。

现在我们试着用这个方法来写一个输入数字求和的程序。用户可以输入若干整数，当输入 0 时结束循环，并给出以上所有数据的和。这里是完整代码：

代码 3.4: sum.cpp

```

#include <iostream>
using namespace std;
void input_clear() {
    cin.clear(); // 清除错误状态
    while (cin.get() != '\n') // 清除本行输入
        continue;
}
int main() { // 主函数
    int sum {0}, x {1}; // x 初始化为 1 是为了防止误结束循环
    while (x != 0) { // 当 x 为 0 时结束循环
        cin >> x; // 输入 x 的值
    }
}

```

```

if (!cin) {
    input_clear(); // 清除错误和错误输入
    x = 1; // x 赋为 1, 否则可能导致循环误结束
    cout << "请输入数字! 输入0结束计算" << endl;
    continue; // 跳过 sum+=x 的操作
}
sum += x; // 这是一个复合赋值运算符, 等效于 sum=sum+x
}
cout << "总数为: " << sum;
return 0;
}

```

这段代码的主函数部分分别定义了 `sum` 和 `x`, 其中的 `sum` 用于求出所有数据的和, 而 `x` 用于在每个迭代过程中存储新的数据。在 `while` 块内, 程序将先读取 `x` 的输入。如果发现 `cin` 的状态不正常, 就说明用户输入了不合理内容²⁷。

如果用户读取了不合理内容, 我们需要做两件事: 一是将 `cin` 恢复到正常状态, 以便下次输入; 二是用 `continue` 跳过后面的部分, 以防 `sum+=x` 误执行导致计算结果出现问题。

这里涉及到了一点复合赋值运算符的应用, 我们简单一说便好: 复合赋值运算符的返回值是赋值之后的左操作数的引用。比如加赋值, `sum+=x` 其实相当于 `sum=sum+x`; 减赋值, `sum-=x` 相当于 `sum=sum-x`; 还有乘赋值、除赋值、模赋值等运算符, 它们都可以按照相同的规律来解释。

3.4 作用域初步

现在我们希望用 `for` 循环实现这样一个输出, 先在 1 到 10 之间输出每个数(共 10 个), 再在 11 到 29 之间每隔一个数输出一个数(共 10 个), 最后在 31 到 58 之间每隔两个数输出一个数(共 10 个)。看上去很简单对吧。我们考虑一下这段代码:

```

for (int i = 1; i <= 10; ++i) { // 从1到10每次i增加1
    cout << i << ' ';
}
for (i = 11; i <= 29; i += 2) { // 从11到29每次i增加2
//error: 'i' was not declared in this scope
    cout << i << ' ';
}
for (i = 32; i <= 58; i += 3) { // 从31到58每次i增加3
//error: 'i' was not declared in this scope
    cout << i << ' ';
}

```

我们的代码思路很清晰, 在第一个 `for` 循环处定义了 `i`, 并且初始化和判断条件都设计得非常准确, 看上去毫无瑕疵。但是如果你把这段代码拿去编译, 就会发现有问题。

编译器的报错信息已经以注释的方式放在代码中, 它的意思是: “`i` 在这个作用域中没有定义。”但是我们在前面明明定义了 `i` 啊! 而且, 我们每次使用 `i` 的位置都在定义之后, 不应该出现上述问题才对。其实这个问题的关键就在于 **作用域 (Scope)**。

在 C++ 中, 并非所有变量一经定义就可以永久使用。在很多场合之下, 我们需要使用一些临时变量, 它们可以帮助我们更简单地实现一些功能。但是任何变量都会占用内存空间, 如果临时变量太

²⁷实际情况可能更复杂, 比如遇到了 EOF。我们可以用一些代码来专门检测不正常的原因是否是 EOF 造成的, 但是我们在本章还没有必要细究这些问题。

多，可能会导致内存空间被浪费（它们大都只在很短的时间里使用寥寥几次，却要长期占据宝贵的空间）。

我们希望这种临时变量只有很短的生存期，它们只在我们需要的时候“被定义出来”，而在我们不需要的时候“被销毁回收”，腾出内存空间。C++ 如何控制变量的生存期呢？就是通过作用域来实现的。

这里我们只对作用域作简单介绍。最简单的情况，一个花括号{} 套住的范围就是一个作用域²⁸。下面的代码展示了一个最基本的嵌套作用域问题。

```
int main() { //这是一个外层作用域
    int x; // 在此作用域内定义的变量可以在更内层的作用域中使用
    { //这是一个内层的作用域
        int y; //在此作用域内定义的变量可以在本层作用域中使用
        x = y = 2; //外层作用域的x和本层作用域的y都可以使用
    } //作用域结束，在此作用域内定义的变量全部失效
    x = 3; //本层的x可以使用
    y = 2; //错误！y的生存期已经结束，不能再使用
    {
        //这是另一个作用域了。在这里，变量x能使用，但y不能使用
        int y; //y经过定义就可以使用了，但这里的y不同于前面的y，它是另一个变量
    }
}
```

if, else, for, while 等等结构控制语句也是自带一层作用域的。比如说，**for** 的初始化操作中定义的内容，只在 **for** 及其循环体内可以使用，然而一旦出了这个循环体，**i** 就失效了，无法使用。这个不受花括号使用的限制——有些情况下，我们可以省略花括号，但这些控制语句仍然自带一层作用域

```
int main() { //外层作用域
    if(<条件>) //自带一层作用域
        int x; //相当于在内层作用域定义了变量x
    x = 3; //错误！在外层作用域中，x已失效，不能使用
}
```

在 **main** 函数体之外，还有一个全局作用域。全局作用域仅供我们定义变量，而其它的操作，如赋值，或者结构控制，必须在函数体内完成。全局作用域下的变量又叫全局变量，它们的生存期是从程序开始到程序结束。**cin** 和 **cout** 就是两个典型的全局变量，它们定义在 **std** 命名空间中。

我们会在后面，尤其是第七章，详细讲解作用域及命名空间等概念。

3.5 实操：简易计算器的设计

在本章的开首，我们就在考虑设计一个计算器。但因为尚不掌握程序流程控制的方法，所以不能实现。

现在读者已经具备这种能力了，那就让我们写一个简单的计算器，以此温习我们本章的编程知识。

我们先设计一个只支持四则运算和取模的计算器，比如下面的例子，黑体字是输入内容，白体字是输出内容：

²⁸在变量定义的统一初始化时，我们也用到了花括号，但是那个不能称之为一个作用域。详细的内容我们暂且不讲。

```
8/3
=2.66667
8%3
=2
q
程序结束
```

显然，我们需要用 `double` 或者别的浮点类型来存储数据，这样计算除法时才不致有精度损失。那么遇到取模运算的时候要怎么办呢？我们可以用显式类型转换的方法来变成 `int` 型，然后再计算。

接下来考虑输入的问题，类似于 `8/3` 这样输入要怎么读取呢？实际上，这点我们不用太过关心，因为当输入数据为数值类型时，程序会自动在输入流的非数值的符号处阻断（我们会在第十三章中更详细地进行探讨，这里读者只需知道结论即可）。接下来我们用一个字符输入就可以读取这个运算符字符。最后再用另一个数值类型读取右边的数字即可。

```
double num1, num2; // 定义两个操作数 num
char op; // 定义一个字符用来存储运算符输入
cin >> num1 >> op >> num2; // 依次输入左操作数、运算符和右操作数
```

这样就可以读取 `8/3` 这种格式的输入了。

接下来的主要问题是读取到的 `op` 如何处理。这个计算器可以支持四则运算和取模这五种运算，所以 `op` 的可能取值有五种，分别对应着加减乘除模的 ASCII 码值。要根据具体情况来做不同的运算，那么用 `switch-case` 结构当然是比较方便的选择了。

```
switch (op) { // 判断 op 是什么
    case '+': // 根据 op 的值，采取相应的操作
        double result {num1 + num2}; // 定义成 const 更好，可以防止误修改
        break;
    case '-':
        double result {num1 - num2};
        break;
    case '*':
        double result {num1 * num2};
        break;
    case '/':
        double result {num1 / num2};
        break;
    case '%':
        int result {static_cast<int>(num1) % static_cast<int>(num2)};
        // 显式类型转换，将 double 型的 num1 和 num2 转换为 int，这样才能计算
        break; // 末尾的 break 可省略
}
cout << result; // 试图输出 result 的值
// 'result' was not declared in this scope
```

这段代码如果真的运行的话，编译器可能会报大量的错误。我以注释的方式将其中一条放在这个代码中，它的含义是“`result` 在这个作用域中没有定义”。

这是因为我们遇到了老问题，`switch` 内部是一个内层作用域，我们在内层作用域中定义的 `result` 只在 `switch` 的作用域内有效，一旦离开这个作用域，`result` 的生存期就结束了，这个变量失效。于是编译器就会报告这样的错误。

解决这个问题的方法有两种，一是直接不定义 `result` 了，在每个 `case` 之下直接输出；二是在外层作用域中定义变量 `result`（这时就不能再定义成 `const` 了，因为我们要使用赋值的方式来存储计算结果）。这里我们采用第二种方法。

最后，我们希望这个计算器可以多次运行。我们指定，当用户提供一个非预期的值（即，每行的开头不是 `num1` 预期得到的数字，而是字母或者别的什么，比如 `q`）时程序结束，否则就可以反复循环运行。

这里可以用 `cin` 的状态作为 `while` 循环的条件来判断循环是否要终止，而在 `cin` 之后必须检测一次 `cin` 的状态，如果不正常，就要 `break`。

```
while (cin) { //如果cin状态正常，就进行循环（非必需，改成true也可）
    double num1, num2, result; //定义两个操作数num及结果值result
    char op; //定义一个字符用来存储运算符输入
    cin >> num1 >> op >> num2; //依次输入左操作数、运算符和右操作数
    if (!cin) { //如果cin状态不正常，说明输入了非预期内容，退出循环
        break;
    }
    //switch-case结构部分省略
    cout << "=" << result << endl; //输出result的值
}
cout << "程序结束" << endl; //提示用户程序结束
```

那么我们的思路就比较清晰了。现在让我们把头文件包含等等杂七杂八的代码加上，就可以形成一个完整的程序了。

代码 3.5: 简易计算器.cpp

```
//这是一个简易计算器，可以支持简单的四则运算或模运算。不支持复杂表达式的计算
#include <iostream>
using namespace std;
int main() {
    while (cin) { //如果cin状态正常，就继续循环
        double num1, num2, result; //定义两个操作数num及结果值result
        char op; //定义一个字符用来存储运算符输入
        cin >> num1 >> op >> num2; //依次输入左操作数、运算符和右操作数
        if (!cin) { //如果cin状态不正常，说明输入了非预期内容，退出循环
            break;
        }
        switch (op) { //判断op是什么
            case '+': //根据op的值，采取相应的操作
                result = num1 + num2; //通过赋值的方式存储结果
                break; //记得用break
            case '-':
                result = num1 - num2;
                break;
            case '*':
                result = num1 * num2;
                break;
            case '/':
                result = num1 / num2;
        }
        cout << "=" << result << endl;
    }
    cout << "程序结束" << endl; //提示用户程序结束
}
```

```
        break;
    case '%':
        result = static_cast<int>(num1) % static_cast<int>(num2);
        // 显式类型转换，将double型的num1和num2转换为int，这样才能计算
        // 末尾的break省略
    }
    cout << "=" << result << endl; // 输出result的值
}
cout << "程序结束" << endl; // 提示用户程序结束
return 0;
}
```

读者可以自行测试此计算器的效果。

第四章 函数初步

在前面的章节中我们讲过了数据、运算符、语法/语义、语序，还有流程控制。从细枝末节到整体结构，我们可以一窥编程大厦的样貌。笔者犹记得，自己当时只学了结构控制，就拿着 C++ 来写命令行界面小游戏了——其实不难，无非就是人机战斗，用户给个输入，用选择结构判断该做什么，由程序来算几个四则运算，再给出输入。最后外面套个 `while(true)` 循环，一个自制小游戏就这么做完啦。

仅有我们此前所学的知识已经足够做出一个完整的、有交互功能的程序，只是工作量会大一点而已。但是别高兴太早，当你真正去实践编程的时候就会发现，要真正实现复杂功能，还是需要极高的工作量，并且其中的许多工作是无意义重复的。在我的游戏当中，我选择用 `Ctrl+C/V` 来解决这个问题，但这还是很麻烦。而且，如果我发现这部分的内容需要调整，我就要把所有相关代码全改一遍！

本章我们先来解决这些重复代码的问题，我们的选择是函数（Function）。

4.1 函数的概念

什么是函数？它是数学意义上的函数吗？

在数学意义上，一个函数 f 是从一个集合 \mathbb{X} （值域）到另一个集合 \mathbb{Y} （到达域）的某种映射关系¹。对于 \mathbb{X} 集合中的某个元素 x 来说，总有唯一确定的 \mathbb{Y} 集合中的元素 $y = f(x)$ 与之对应。举例来说，我们记 $f(x) = x^2 + 2x + 1$ ，其中 $x \in \mathbb{R}$ ，那么对于某个输入 $x = 3$ ，就能通过这个函数算出 $f(3) = 16$ 来，这个结果就是函数的输出。

三角函数也是数学意义上的函数。比如正弦函数，它的名字就是 \sin 。不过它不像我们刚才用到的 f 那样，我们不知道它的表达式，如果你要问我 $\sin 1$ 是多少，我也不方便徒手计算，要用计算器才行。但是无论何时何地，我算出的 $\sin 1$ 和张三算出的 $\sin 1$ 、李四算出的 $\sin 1$ 都是一样的。所以说， \sin 的输入信息和输出信息之间有确定的对应关系。我不知道 \sin 的内部构造，也不知道计算器是用什么原理来实现的，但是我给它某个输入，它就会给我对应的输出，这就是一个黑盒（Black box）（见图 4.1）。



图 4.1: \sin 函数就是一个黑盒，给定某个输入信息就会有对应的输出信息

在编程当中，函数的概念可以借用数学上的函数概念来阐释。举个例子，`cmath` 库中有一个函数 `sin`，它可以接收一个 `double` 类型的参数，并返回一个 `double` 类型的结果。所以我们可以这么说它的定义域 \mathbb{X} 就是 `double` 型的所有数据，到达域 \mathbb{Y} 也是 `double` 型的所有数据。

¹这里介绍数学意义上的函数，只为引入编程意义上的函数概念。如果读者拥有相关数学基础，自然更好；即便没有相关数学基础，也不妨碍对后续知识的理解和应用。

```
#include <iostream> // 标准输入输出头文件
#include <cmath> // sin函数定义在cmath库中
using namespace std; // 使用命名空间std
int main() {
    cout << sin (3.14159); // 使用sin函数求出sin(3.14159)的值
    return 0;
}
```

这段代码的输出是

2.65359e-06

它是一个非常小的数，这是合乎我们的预期的。²

数学上还有多元函数的概念，也就是接收一个或多个输入，并给出一个输出的函数。在程序设计中，函数也可以接收一个或多个输入，甚至接收空输入（我们在前面用到的 `numeric_limits<int>::max()` 就是一个空输入的函数）。但是函数只能返回一个输出³或者返回 `void`⁴（即空输出）。我们在下一节中就会提到这些。

我们熟识的运算符就可以看成是一种函数⁵。加法运算符就是一个黑盒，它的两个操作数就是两个输入信息，而返回值（输出信号）就是它们的和。运算符中有操作数和返回值的概念，这些概念对应到函数中就是参数和返回值。

C++ 的各种库为我们提供了许多函数，我们可以直接使用这些函数来实现我们想要的功能，而不需要自己把每个功能实现出来。比如说 `cmath` 库中有丰富的数学函数，除了刚才的正弦函数以外，还有求绝对值函数 `abs`、开平方函数 `sqrt`、下取整函数 `floor` 等。如果真的要我们自己写代码实现的话，这是非常麻烦的（试想，如何用一些结构控制语句和四则运算来求开平方呢？这好像很难办到）。

而 C++ 的函数封装了一些已经实现好的功能，我们不再需要考虑如何写一个开方代码，思路是什么，需要注意哪些细节——直接用 `cmath` 库给我们的解决方案就好了。

```
double num; // 定义一个num用来接收输入
cin >> num; // 输入num的值
cout << sqrt (num); // 输出num开方后的值
```

我们还可以自己定义函数。比如在[代码 3.4](#)中，我提供了一个 `input_clear` 函数，用来清除 `cin` 的错误状态并清理本行输入。这个函数在其它地方也可以用⁶，只需要写一个 `input_clear();` 就可以了，而不需要把函数体当中的那三行代码再写一遍——这样就很方便了。

而且更重要的是，如果我有朝一日不使用 `cin` 而是用别的来进行输入（还记得吗？`cin` 只是 `istream` 类的一个对象，我们还可以使用这个类或者派生类⁷的其它对象来进行输入），那么我只需要在 `input_clear` 的定义中修改一次即可。但如果我不用函数而是每次都写那三行代码呢？修改起来也会相当麻烦。

使用函数还有一个优点，我们可以把一个复杂的大任务拆分成几个简单的小任务。其实在之前写代码的过程中，我们也是有意把程序的思路梳理清楚的，这个功能应该怎么做，那个功能应该怎么做。而函数看上去更加直观，我们为每一项操作起了一个名字，然后分别把它们写到不同的代码中

²注意，`cmath` 库中的 `sin` 函数接收的参数是按照弧度值传入的，所以 $\sin 3.14159 \approx 0$ 。

³如果我们需要让返回多个值，可以使用结构体 `struct` 或者 `std::tuple`。我们将来会接触到这种情况的。但这并不违反“至多只能返回一个输出”的规定，因为一个结构体或 `tuple` 就是单个输出。

⁴`void` 也是一个基本数据类型，但它不能用来定义数据，可以用来定义指针。在函数中，我们会经常见到这种类型的。

⁵实际上运算符和函数并不相同，不过它们有很多相似之处，可以用于类比。

⁶前提是需要定义，或者声明并在有关的代码中提供了定义。详见下一节。

⁷有关继承和派生类的概念，我们将在第九章介绍。

去，这样就方便很多了。

接下来我们就开始学习如何定义和使用函数，以后我们会频繁用到的。鉴于我们还有很多复合数据类型相关的知识没有学习，本章只是对函数作一些初步讲解。

4.2 函数的定义和使用

基本技术

定义一个函数的基本语法是：

```
<返回类型> <函数名>(<参数列表>) {
    <若干操作>; //花括号中的内容又叫函数体
}
```

其中 <返回类型> 可以是任何一个类型，也可以是 `void`（空）类型。<参数列表> 可以接收若干个参数，也可以不接收参数。一般来说，每个函数的参数都是固定数量的，不过也存在“变长实参”的情况，我们暂不讨论。

而函数体内可以进行各种操作，比如赋值，选择、循环等等。注意：如果返回类型不为空，那么函数体内必须有 `return` 返回值，否则将发生未定义行为，后果难料。

我们在此之前已经接触过一些函数，除了 `numeric_limits<int>::max()` 和 `input_clear` 以外，还有一个我们一直忽视的函数，那就是 `main`。主函数也是一个函数，它的返回类型必须为 `int`，可以接收参数⁸。因为它的返回类型为 `int`，所以它也需要有返回值，我们一般写作 `return 0;`，这样你就明白之前的那些代码中为什么总要加上这句了吧⁹。

主函数是程序运行的起点。程序运行时会自动从主函数的第一句开始向下运行，直到主函数结束，或者遇到了返回语句 `return`。而其它的函数不会直接被使用，我们必须手动使用。下面我们就来尝试一个最简单的例子。现在我们试着自己来写一个求绝对值的函数 $f(x) = |x|$ ，它可以允许对浮点数求绝对值。让我们想一想，这个函数的定义要怎么写？

首先确定返回类型和参数。这个函数允许浮点数的计算，所以返回类型肯定也要能够表示浮点数——任何一种浮点类型都能做到，所以我们就用 `double` 好了。

接下来确定参数。这个函数只接收单个浮点数输入，所以我们只需要一个 `double` 型的参数，起名为 `x`。

函数体内的部分需要分情况处理，如果 $x \geq 0$ ，那么直接返回原数就可以；如果 $x < 0$ ，那么就需要返回它的负值。既然涉及到分情况处理，那当然要用选择结构来实现啦。

```
double f(double x) { //返回类型为double，接收一个double型参数x
    if (x >= 0) { //如果x>=0，返回x本身
        return x;
    }
    else { //如果x<0，返回x的负值
        return -x;
    }
}
```

接下来我们就可以使用这个函数来求绝对值，而无需每次用到时都反复写好几遍代码。这个“使用”过程又叫作调用（Call）。

⁸但是，主函数接收参数的情况不同于其它函数，这里不作细致讨论。我们也不常使用这种写法。

⁹实际操作中，如果没有在 `main` 函数中写返回语句，编译器会为我们自动添加。所以取决于编译器的具体情况，我们可以不必在 `main` 函数中写返回值。

```

int main() {
    cout << f(-.1) << endl; //输出-0.1的绝对值，然后换行
    for (int i = -2; i <= 2; i++) { //输出-2到2每个数的绝对值
        cout << f(i) << ' ';
    }
    return 0;
}

```

程序的运行结果如下：

```

0.1
2 1 0 1 2

```

第一行是 `-0.1` 的绝对值，看起来确实达到我们的要求了。第二行是一个 `for` 循环，先定义了 `int` 型的 `i`，然后让它从 `-2` 自增到 `2`，输出 `i` 的绝对值。程序的结果看上去也是正确的。

但细心的读者可能会发现一个问题：我们定义的 `f` 接收的参数类型是 `double`，但是为什么 `f(i)` 不会报错呢？这里的 `i` 不是 `int` 类型吗？

其实这是因为隐式类型转换在起作用。还记得我们当时的说法吗？如果某处期望一个类型，但代码中提供的是另一个类型的数据，编译器可能考虑对此数据进行隐式类型转换，以符合类型需要¹⁰。所以实际传入的参数并不是 `i` 本身，而是 `i` 隐式转换为 `double` 之后的数据。

函数的作用域

我们在先前简单介绍过作用域的概念，凡是局部变量都有它的生存期，一个作用域结束后，它的生存期宣告终止，我们不能再使用这个变量。之前那些都属于块作用域（Block scope），比较容易理解。这里我们再谈谈函数有关的作用域。

每一个函数体都是一个独立的作用域，各个函数作用域之间互相没有嵌套关系——这点和块作用域很不相同。在讲块作用域的时候我们说，内层作用域中可以使用外层作用域里定义的变量。但是函数作用域彼此独立，一个函数中定义的变量在另一个函数中不可见¹¹，如图 4.2 所示。

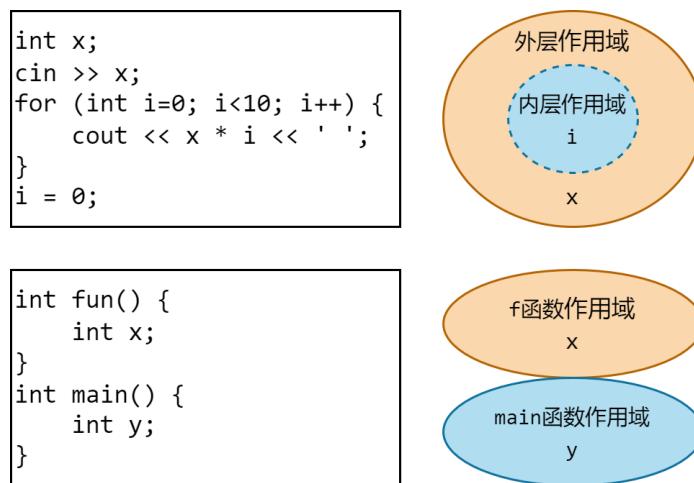


图 4.2: 块作用域与函数作用域的区别

¹⁰仍要提醒读者，这是不完全的。比如，`double` 类型的取模是不允许的，这时编译器不会尝试将其转换为 `int` 型。

¹¹一个函数作用域的变量对另一个函数不可见，这并非意味着生存期结束且变量被销毁。我们在第七章中会再谈及此类问题。

这种关系有点像是动物园。在动物园中，每个动物（局部变量）都被关在自己的围栏（函数作用域）内生活，而其它围栏内的动物不能和它们互相接触。动物饲养员则像全局变量，它可以进入各个围栏内部。

那么假如我需要在两个函数中传递信息（比如，在主函数中告诉 `f` 函数，需要求哪个数的绝对值），我该怎么办呢？这时就需要用到参数传递和返回值了。

实参与形参

回顾一下我们刚才写的自定义绝对值函数 `f`。

```
double f(double x) { // 返回类型为 double，接收一个 double 型参数 x
    if (x >= 0) { // 如果 x>=0，返回 x 本身
        return x;
    }
    else { // 如果 x<0，返回 x 的负值
        return -x;
    }
}
```

这里的 `x` 是它的一个参数。我们在调用 `f` 时，程序会新定义一个 `x`，而括号内的数据会作为初始化信息传递给 `x`。举例说，`f(-.1)` 在主函数中被调用，这时程序会新定义一个 `x` 并初始化为 `-.1`，然后开始顺序执行 `f` 中的代码。换言之，每次调用 `f`，程序都会重新定义一个 `x`，所以我们可以把参数列表当作是“函数中的一种变量定义语句”。

那么如果我把这个函数中的所有 `x` 都换成 `y`，这个函数的本质发生变化了吗？

```
double f(double y) { // 返回类型为 double，接收一个 double 型参数 y
    if (y >= 0) { // 如果 y>=0，返回 y 本身
        return y;
    }
    else { // 如果 y<0，返回 y 的负值
        return -y;
    }
}
```

答案当然是不会！名字是可以随便起的，无论用 `x` 还是 `y`，还是换成 `num` 或者 `arg`，都没问题。但是，只要函数的逻辑不变，它的本质就没有发生变化，对于相同的输入，永远会给出相同的输出。数学上也是如此，对于相同的定义域来说， $f(x) = |x|$ 和 $f(y) = |y|$ 当然是同一个函数。

真正会改变函数值的不是参数的名字，而是具体传入函数的输入信息。`f(3)` 和 `f(4)` 当然是不同的；`f(3)` 和 `f(-3)` 虽然相同，但它们传递的信息还是有差异的，只是输出恰好一致。所以说，同样是“参数”，`x` 或 `y` 仅仅代表一个名字，而 `3` 或 `4` 却能传递真正有效的信息，看来它们还是有一定的区别的。

我们把 `x` 和 `y` 这类在函数定义过程中用到的名字称为形参（Parameter/Argument），而把 `3` 和 `4` 这类在函数调用过程中传递了真实信息的数据称为实参（Argument/Parameter）。¹²请注意，实参未必就“没有名字”，它可以是字面量、常量表达式、常量或变量；形参和实参的区别应该在于：你是在定义还是在调用。

¹²parameter 和 argument 这两个词都可以用来指代参数。不过习惯上，parameter 指代形参，而 argument 指代实参。

函数的使用

举个例子，现在我们要写一个 `max` 函数，它可以接收两个整数输入，返回值是其中较大的那个整数。

首先确定返回类型和参数。这个函数只需接收整数参数，返回整数值，所以返回类型可以是任何一种整型，具体哪种就看我们需要了。为了能涵盖比较大的数据范围，我们在这里可以选择 `long long`。我们需要两个参数，它们都是 `long long` 类型的。名字可以随便起，比如 `a` 和 `b` 吧。

函数体内的部分需要返回 `a` 和 `b` 的较大值，这就需要我们分析一下如何实现：如果 `a` 大于 `b`，那我们就返回 `a`，这没问题；如果 `a` 不大于 `b`，那我们就返回 `b`，也不会出错。所以我们需要一个选择结构。我们可以这么写：

```
long long max(long long a, long long b) {
    //接收两个long long参数，给出long long返回值
    if (a > b) { //当a>b时返回a
        return a;
    }
    else { //否则返回b
        return b;
    }
}
```

接下来写一下主函数的部分就可以了。这是我们熟知的内容，所以我只放代码，不再讲解思路。

```
int main() {
    long long a, b; //定义int型变量a,b
    cin >> a >> b; //输入a,b的值
    cout << max(a, b); //调用max
    return 0;
}
```

请留意：主函数中的 `a` 和 `b` 与 `max` 函数中的 `a` 和 `b` 是完全不同的概念。它们分别属于不同的、相互独立的作用域，互不干涉。

如果我们要输入三个数并找出其最大值呢？一种方法是，先用 `max` 求出其中两数的最大值，然后再求出它和第三个数的最大值。

```
int main() {
    long long a, b, c; //定义三个int型变量a,b,c
    cin >> a >> b >> c; //输入a,b,c的值
    cout << max(max(a, b), c); //输出它们三个的最大值
}
```

我们来解析一下 `max(max(a,b),c)` 这段代码，不难：

首先，`max(a,b)` 先行计算，返回的是 `a, b` 中的最大值。这个返回值又作为 `max` 的参数与 `c` 比较，最后返回的就是 `a, b, c` 中的最大值。

当然还有别的方法，我们也可以定义一个 `max3` 函数¹³，接收三个参数并求出它们的最大值。

```
long long max3(long long a, long long b, long long c) {
    //接收三个long long参数，给出long long返回值
    const long long max_ab {max(a,b)}; //先求出a,b的最大值
    if (max_ab > c) { //如果a,b的最大值大于c，返回前者
}
```

¹³ 我们很快就会讲到重载，那时就可以直接重载一个 `max` 函数。

```

        return max_ab;
    }
    else { // 否则返回后者
        return c;
    }
}

```

这样我们就可以用 `max3` 函数来求三个数的最大值了。

初学者可能有这样的误会，认为只有主函数才能调用其它函数。不是的，所有函数都可以调用其它函数，只要有声明（我们稍后谈到）。函数可以调用它自身，这就是递归¹⁴。其它函数甚至可以调用主函数，但这往往容易引起困惑，所以我不推荐这么做。

如果涉及大量数据求最大值的问题，这种方法就显得不太合适，这时我们可能考虑寻求 `valarray` 等其它方案，这些我们之后再谈。

函数的声明

有些程序员在写代码的时候更倾向于把主函数写在靠前的位置上，这样一来，程序的主要操作是什么就一目了然——毕竟，主函数是程序开始执行的地方。

不过如果单纯只是这么写的话，编译器就会报错。以下是例子：

```

int main() {
    long long a, b, c; // 定义 long long 型变量 a,b,c
    cin >> a >> b >> c; // 输入 a,b,c 的值
    cout << max3(a, b, c); // 输出 a,b,c 的最大值
//error: 'max3' was not declared in this scope
}

long long max(long long a, long long b) {
    // 省略
}

long long max3(long long a, long long b, long long c) {
    // 省略
}

```

编译器报错信息的含义是：“`max3` 在这个作用域中没有定义。”读者可能会误会，认为把 `max3` 定义在 `main` 函数中就可以了。但是，传统意义上的一个函数不能定义在其它函数当中，而必须定义在全局作用域中¹⁵！这些函数之间的关系是并列的，而非 `max3` 从属于 `main`。

Visual C++ 编译器返回的报错信息更清晰：“error C3861: 'max3': identifier not found。”它的意思是：“没有找到 `max3` 这个标识符。”这是因为，编译器处理代码是从前向后处理的。它遇到一个函数声明（或定义）就会记住；然后一旦遇到函数调用，就去寻找能匹配这个调用的函数。现在我们把 `max3` 的调用放在前，而 `max3` 的定义放在后，那么编译器自然会“not found”了。

我们既想要把长篇累牍的函数体放在后面以突出重点（主函数），又不得不在主函数之前把“存在这样一个函数”的信息告诉编译器，那么最好的解决方案就是声明（Declaration）了。

所谓函数的声明，就是把一个函数的外部特征告诉编译器，这样编译器就可以在调用相应函数时匹配到它。至于这个函数会做什么，先不要管它，等到定义（Definition）中再告诉编译器。

声明一个函数的基本语法是

```
<返回类型> <函数名>(<参数类型列表>); // 注意用分号结尾
```

¹⁴ 我们会在后面的内容中讲到递归。

¹⁵ 我们在精讲篇中会介绍 lambda 闭包，它是一种可以在局部作用域中定义的函数。

简单说来就是，把花括号包起来的函数体部分去掉，然后用一个分号结束该句即可。

在函数声明的语法中，我们只需要列出参数的类型，而不需要指明参数的名称——它只是个形参而已，定义成什么名字其实无所谓，而且我们又无需在函数体（因为没有写）中使用它，所以仅仅指明类型，让编译器知道它该接收什么参数就足够。

如果我们要为前面定义的 `f` 写一个声明，可以这么写：

```
double f(double); // 形参名可省略，或者任意取名
```

如果我们要为 `max` 和 `max3` 写声明，可以这么写：

```
long long max(long long, long long);
long long max3(long long, long long, long long);
```

所以我们把代码整理一下，就可以形成一个完整的程序：

代码 4.1: max3.cpp

```
// 这个程序可以接收三个输入整数，并给出它们的最大值
#include <iostream> // 标准输入输出头文件
using namespace std; // 使用命名空间 std
long long max3(long long, long long, long long); // 声明
int main() {
    long long a, b, c; // 定义 long long 型变量 a,b
    cin >> a >> b >> c; // 输入 a,b 的值
    cout << max3(a, b, c); // 输出 a,b,c 的最大值
    return 0;
}
long long max(long long a, long long b) {
    // 接收两个 long long 参数，给出 long long 返回值
    if (a > b) { // 当 a>b 时返回 a
        return a;
    }
    else { // 否则返回 b
        return b;
    }
}
long long max3(long long a, long long b, long long c) {
    // 接收三个 long long 参数，给出 long long 返回值
    const long long max_ab {max(a,b)};
    if (max_ab > c) { // 如果 a,b 的最大值大于 c，返回前者
        return max_ab;
    }
    else { // 否则返回后者
        return c;
    }
}
```

这里有个问题需要读者留意：为什么这里只需要声明 `max3` 而不需要声明 `max` 呢？其原因在于，`max` 是在 `max3` 中调用的，而 `max` 的定义在 `max3` 之前，所以编译器不会找不到 `max`，参见图 4.3 的蓝色箭头。

```

unsigned factorial(unsigned n) {
    if (n == 0){
        return 1;
    }
    else {
        return n * factorial(n - 1);
    }
}

```

图 4.3: main 函数调用了 max3, 而 max3 调用了 max, 它们都能够找到对应的函数

这也就是说, 其实 main 函数没有调用 max, 调用 max 的其实是 max3。这种关系对于初学者来说可能相当复杂, 不过即使现在很难理解也没有关系, 我们在日后的学习过程中会慢慢体会到的。

“值计算”与“副作用”

用函数的视角来理解运算符是一种很重要的思想。C++ 中的自增/自减运算符可以当作一个函数来看待, 它接收某个类型(实际上它可以接收很多类型)的参数, 然后返回同类型的参数。如果用于后缀形式, 它的返回值是原数; 如果用于前缀形式, 它的返回值是原数加/减 1 后的值¹⁶。

然而它的作用不仅仅停留在“提供一个返回值”, 它还有改变原数(参数)的功能。自增/自减作用于某个变量, 会导致这个变量增加/减少 1。这类功能不是通过返回值表现出来的, 我们称它为副作用(Side effect); 而对应地, 把通过返回值表现出来的功能称为值计算(Value computation)。

有些时候, 比如在 `for` 循环的迭代操作中, 我们使用自增/自减运算符是为了使用它的副作用, 而不是值计算。对于函数来说也是同理。还记得我之前提供的 `input_clear` 函数吗? 它的返回类型是 `void`(空), 我们不需要接收它的什么返回值, 而只需要使用它的副作用(清除错误状态, 清除本行输入)就行。

```

void input_clear() {
    cin.clear(); // 清除错误状态
    while (cin.get() != '\n') // 清除本行输入
        continue;
}

```

我们还会自定义很多这类的“只用其副作用而不用其值”的函数, 这种情况下我们可以将返回类型定为 `void`。`void` 函数中可以写 `return`; 或者 `return void{};`¹⁷这样的返回语句, 或者压根什么返回语句也不写, 没有问题。

4.3 函数重载

C++ 中的运算符可以接收不同类型的操作数。`.1+.2`, 这里的操作数都是 `double` 类型的; `1+2`, 这里的操作数都是 `int` 类型的; `1ll+2ll`, 这里的操作数都是 `long long` 类型的(还记得吗, 整数带 `ll` 后缀将是 `long long` 类型的)。我们希望同一个函数也能像运算符那样, 支持多种类型。比如 `max` 吧, 它是否既可以支持 `double` 类型又可以支持 `int` 类型呢?

¹⁶这里忽略整数溢出和浮点精度问题。

¹⁷`void{}`相当于一个 `void` 类型的临时对象, 我们会在后面经常遇到这类语法的。

这种可能性是完全存在的。想想吧，当我们调用函数时，编译器能知道的信息只有函数名和实参——而实参能够提供“参数类型”这则信息。因此我们如果定义一个“接收不同类型参数”的同名函数，编译器仍然可以分得清。

当然这只是可行性分析，不代表该语言能允许我们这样做——C 语言就不支持这种方法。不过好消息是，C++ 支持这种方法，它叫做**函数重载（Function overloading）**。

要重载一个函数是非常简单的，只要你用同一个函数名写不一样的参数列表就行了。举例来说，我们在上一节中定义了 `max3`，其实我们可以直接用 `max` 这个名字，它就是对原来 `max` 的重载。

```
long long max(long long, long long); //本行代码是非必需的
long long max(long long, long long, long long); //此重载max接收三个long long参数
int main() {
    long long a, b, c;
    cin >> a >> b >> c;
    cout << max(a, b, c); //编译器自动找到max(long long,long long,long long)
    return 0;
}
long long max(long long a, long long b) {
    //省略
}
long long max(long long a, long long b, long long c) {
    //省略
}
```

我们还可以重载 `double` 版本的两数 `max` 函数和三数 `max` 函数，只需要在上面的代码中再添加：

```
\\"声明部分如下
double max(double, double); //此重载接收两个double参数
double max(double, double, double); //此重载接收三个double参数
\\定义部分如下
double max(double a, double b) {
    if (a > b) {
        return a;
    }
    else {
        return b;
    }
}
double max(double a, double b, double c) {
    const double max_ab {max(a,b)};
    //这里编译器会调用max(double,double)而非max(long long,long long)
    if (max_ab > c) {
        return max_ab;
    }
    else {
        return c;
    }
}
```

图 4.4 即 `max` 函数的四种重载方案。每种重载方案都可以视为一个独立的函数，只是它们名字不同而已。



图 4.4: `max` 函数的重载

注意，同一个函数的返回类型不能重载。我们写成这样是不行的：

```

// 声明部分如下
double max(double, double);
long double max(double, double);
//error: ambiguating new declaration of 'long double max(double, double)'

```

编译器的报错信息意为：“`long double max(double, double)` 的定义会引发歧义。”这不难理解。因为在调用函数的时候我们无法指定这个函数的返回类型，所以一旦我们定义了两个完全相同的函数——除了它们的返回类型不同以外，编译器就不可能把它们分开。这就是一种二义性（Ambiguity）。

二义性说白了就是歧义。我们日常使用的语言不可避免地会有歧义，但大多数时候我们都能根据实际情况来判断状况，而不致造成错误理解（但这种情况还是时常发生，不是吗）。编译器不具备人的理解能力，它面对二义性问题时无法判断程序员的真实意图，所以只会报错。

在涉及到重载时，还有很多种情况会导致二义性的发生，比如这个：

```

void fun(long long); // 声明了一个接收 long long 型变量的函数 fun, 定义省略
void fun(double); // 声明了一个接收 double 型变量的函数 fun, 定义省略
int main() {
    fun(1ll, 1.); // 实参分别是 long long 类型和 double 类型, 如何是好?
// (GCC) error: call of overloaded 'fun(long long int, double)' is ambiguous
// (MSVC) error C2666: 'fun': overloaded functions have similar conversions
// (clang) error: call to 'fun' is ambiguous
}

```

先不看编译器的报错信息，我们来分析一下这段代码的行为。我们重载了 `fun` 函数，其中一个版本可以接收 `long long` 类型的参数，而另一个版本可以接收 `double` 类型的参数。在主函数中，我向 `fun` 中传入了两个参数，分别是 `long long` 型的 `1ll` 和 `double` 型的 `1.`。现在问题来了，编译器究竟是会把 `1ll` 隐式转换成 `double` 类型，还是会把 `1.` 隐式转换成 `long long` 类型呢？

编译一下就会发现，无论是 GCC，Visual C++ 还是 Clang，都会给出类似于歧义的报错。其中 MSVC 的报错提到了“have similar conversions”，这正是问题的根源：“把 `1ll` 转换为 `double`”或者“把 `1.` 转换成 `long long`”都是可行的，这两种方案高度相似，编译器也无法决定怎么转换，于是就出现了二义性问题。

怎么解决呢？我们可以使用强制类型转换的方法来把一个参数转换成别的类型，比如都转换成 `double`，这样编译器就能直接找到匹配的函数了。

还有一种方式就是再定义一个 `fun(long long, double)` 重载函数。但是这样就别提有多麻烦了——那我们是不是还要考虑定义一个 `fun(double, long long)`，以防有人使用 `fun(1., 1ll)` 呢？这

样的麻烦无穷无尽, 那是很烦人的。¹⁸况且, 因为 `int` 既可以转换为 `double` 又可以转换为 `long long`, 那么在调用 `max(1,2)` 时也会出现“编译器不知该使用哪个重载”的二义性问题, 那么我们还要再定义 `int max(int,int)` (以及各种变形) 呀?

不过这仅是出于语法层面的考量而言的。实际编程中我们大多会使用同一类型的数据来求最大值, 所以只需要定义两(三)个同类型参数的重载, 就足以应付大多数需求了。至于更细致的知识, 尤其是有关编译器如何处理“类型转换”和“匹配哪个函数”的问题, 其实非常复杂, 本章不再赘述。我们会在泛讲篇中更深入地探讨这个问题。

4.4 默认参数的设置

在数学上, 对数函数 $\log_a N$ 是一个二元函数, 其参数分别为 a 和 N 。不过在数学当中, 我们一般都用 $a = e$ 作为对数的底。因此为了方便, 我们就约定俗成, 不写底数的时候默认以 e 为底, 写成 $\log N$ 。有些数学文献中也用 $\ln N$ 代替底数为 e 时的对数函数。

n 次方根函数 $\sqrt[n]{a}$ 也是一个二元函数, 其参数分别为 n 和 a 。我们最常用的是二次方根, 所以当 $n = 2$ 时, 我们习惯省略它, 直接写作 \sqrt{a} 。

以上是在数学中常见的。而在 C++ 语言中, 我们也可能遇到类似的问题——某个函数的某个参数在多数时候都是某个特定值, 我们能否想一种方法, 省略掉一些常常为特定值的参数, 这样我们就不必在每次调用此函数时都写这个参数了呢?

答案是肯定的。例如我们要写一个开 n 次方根函数, 我们就可以用上一节提到的重载方法, 写一个接收 a 和 n 的 `root` 函数, 再写一个只接收 a 的 `root` 函数(将 n 当作 2)。鉴于 `root` 函数本身的实现比较麻烦, 我们退而求其次, 使用 `pow(a,1./n)`¹⁹ 来实现它。

```
#include <iostream>
#include <cmath>
using namespace std;
double root(double, int);
double root(double);
int main() {
    cout << root(64, 3) << endl; // 将调用 root(double,int)
    cout << root(64) << endl; // 将调用 root(double)
    return 0;
}
double root(double radicand, int index) {
    return pow(radicand, 1. / index); // 注意 index 是 int 型, 所以要用 1./index
}
double root(double radicand) {
    return pow(radicand, .5); // 默认开平方根, 就可以直接用 0.5 次幂表示
}
```

关于函数重载, 读者已经比较熟悉了, 所以这里我就不再对代码作过多解释。这里的 `root(double)` 也可以定义成下面这个样子, 效果相同:

```
double root(double radicand) {
    return root(radicand, 2); // 利用 root(double,int) 的返回值
}
```

¹⁸ 所以你就能理解为什么我们需要泛型编程了, 详见本章第六节。

¹⁹ `double pow(double base, double exp)` 是 `cmath` 库中的一个函数, 返回值为 `base` 的 `exp` 次幂。这个函数还重载了其它浮点类型的版本, 但我们在那里不需要它们。

除了重载之外，我们还可以使用另一种方法：为函数设置默认参数（Default argument）。

当我们在声明或定义一个函数的时候，我们可以为它设置一些默认值。这样，当我们调用函数的时候，如果把对应的参数留空，编译器就会用默认值来替代它。以下是一个例子：

```
double root(double, int = {2}); // 等号不能省略，花括号并非必需，但建议使用
int main() {
    cout << root(64, 3) << endl; // 将调用 root(double,int)，第二个参数传入3
    cout << root(64) << endl; // 将调用 root(double,int)，第二个参数取默认值2
    return 0;
}
double root(double radicand, int index) {
    return pow(radicand, 1. / index); // 注意 index 是 int 型，所以要用 1./index
}
```

看起来函数重载和默认参数这两种方法都可以达到我们的目的，那么它们的区别是什么呢？

其实这两种方法最大的区别在于，函数重载是“定义了两个函数”，而设置默认参数“不会定义新函数”！在函数重载的情况下，我们计算 `root(64,3)` 时，调用的是 `root(double,int)`，而计算 `root(64)` 时，调用的是 `root(double)`；但如果只是设置了默认参数，那么无论计算 `root(64,3)` 还是 `root(64)`，都会调用 `root(double,int)` 这个函数。如果我们只是想设置默认参数而无需做大的细节改动，那么用默认参数的方法当然比重载要方便了（我们无需重新定义一个函数！）。

而函数重载应该用在更需要处理细节改动的情况下，比如两个数求最大值和三个数求最大值，函数内部的细节是不太相同的——这时若用默认参数就显得更麻烦了，而不是更简单。

在默认参数方面，其实还有很多需要留意的内容。不过大部分问题不常见，我在泛讲篇中就不多说了，只说几个小的要点。

其一，默认值最好是在函数声明时就规定出来，而不是等到定义时再规定。这是因为，编译器遇到函数调用的时候，会向前找寻函数声明。只有在函数声明中规定了默认值的情况下，编译器才会考虑匹配；如果在函数声明中没有规定默认值，编译器就找不到这个函数（或者好巧不巧地匹配上了其它同名函数，但那不是我们想要的），即便我们后面的函数定义中再规定默认值也是枉然！

其二，有默认值的参数必须在函数参数列表的右侧。这可能有点费解，我举个例子你就懂了。

```
// 假设这四个函数定义在不同场合下，互不影响
double root(double, int = {2}); // 允许
double root(int = {2}, double); // 这是禁止的！
// error: default argument missing for parameter 2 of 'double root(int, double)'
double root(double = {1.}, int = {2}); // 允许
double root(int = {2}, double = {1.}); // 允许
```

编译器的解释方式是，但凡某个参数有默认值，从它开始到后边的所有参数都应该有默认值。因此，我们定义函数时，必须要把有默认值的参数放在参数列表的右侧。

我们在先前接触过一个自定义函数 `input_clear()`，它可以清理错误输入。我们最常用 `istream` 类的 `cin` 对象来进行输入，但这不代表我们在其它时候不需要用别的对象。为此，我们可以改一下 `input_clear` 函数，让它可以接收任何一个 `istream` 类的对象²⁰。而鉴于我们常用 `cin`，所以不妨把它设为默认参数。

```
// 不单独声明，直接定义
void input_clear(istream &in = {cin}) { // 不提供参数时使用默认参数 cin
    in.clear(); // 清除错误状态
    while (in.get() != '\n') // 清除本行输入
```

²⁰事实上还可以接收 `istream` 派生类的对象，但这就说得远了。

```

    continue;
}

```

这里的形参长得有点不同，它是一个引用，我们会在下一章中讲到。

4.5 函数递归

我们提及过，不只有主函数可以调用其它函数，任何函数都可以调用其它函数。我们也在先前的例子中看到，在 `max(double, double, double)` 中调用 `max(double, double)` 是完全可行的。那么一个函数能否调用它本身呢？C/C++ 给出的答案是可以。这种“一个函数调用它本身”的情况，在编程领域有一个专门的名字，叫作递归（Recursion）。

你可能会有困惑：我怎么能用一个东西来定义它本身呢？那不就成了逻辑学上的循环定义了？别急，且先听我慢慢道来。

数学上有个函数叫作阶乘（Factorial），对于非负整数 n ，它的定义是 $n! = 1 \times 2 \times 3 \times \dots \times n$ （特殊定义 $0! = 1$ ）。它还有一种递推定义： $0! = 1; n! = n \times (n - 1)!$ 。

如何理解这个递推定义呢？其实就是， $0!$ 的值是给定的，而 $n!$ 的值要由 n 乘以 $(n - 1)!$ 来计算。那么 $(n - 1)!$ 如何计算呢？要通过 $n - 1$ 乘以 $(n - 2)!$ 来计算。这样不断推导下去，就能一直推到 $0!$ 这个确定的数据，因此只要知道了 $0!$ ，就可以一步一步推出 $n!$ 的值来。

而在编程当中，我们可以用函数递归的方法来计算阶乘，下面是一个示例代码：

代码 4.2: Factorial_with_Recursion.cpp

```

// 用递归方法实现阶乘函数
#include <iostream>
using namespace std;
// 如果 factorial 的参数大于 12，就会发生运算结果溢出。可以考虑用 unsigned long long
unsigned factorial(unsigned n) { // 阶乘的参数和值都不是负数，所以定义成 unsigned
    if (n == 0) { // 终止条件，不可或缺
        return 1; // 0! 为 1，直接返回
    }
    else { // 如果没有到达终止条件，就调用 factorial(n-1)，离终止条件更进一步
        return n * factorial(n - 1); // 递归，n! 用 n*(n-1)! 表示
    }
}
int main() {
    cout << factorial(12); // 计算并输出 12! 的值
    return 0;
}

```

我来解释一下这段代码，并回答一下读者可能关心的问题。

“我用 `factorial` 来定义 `factorial`，编译器不会报错吗？”

不会的，因为函数的定义就是一种声明。所以编译器在 `factorial` 函数给定参数列表时就已经知道了它的存在（图 4.5）。

“这段代码会怎么运行？”

想像你就是那个程序，在主函数中，当你遇到 `factorial(12)` 时，你会调用这个函数并代入实参 $n=12$ 从而求出它的返回值。而在运行时发现，因为 $n==0$ 不满足，所以你不得不再去求 `factorial(11)`，然后是 `factorial(10)`，以此类推。如果一切顺利的话，你会在求 `factorial(0)` 的时候直接返回 1，然后用 $1 * factorial(0)$ 算出 `factorial(1)` 的返回值；用 $2 * factorial(1)$ 算出 `factorial(2)`

```
unsigned factorial(unsigned n) {
    if (n == 0){
        return 1;
    }
    else {
        return n * factorial(n - 1);
    }
}
```

图 4.5: factorial 的定义就是一种声明, 所以编译器能够找到它

的返回值; 用 `3 * factorial(2)` 算出 `factorial(3)` 的返回值……一直到你算出 `factorial(12)` 为止。图 4.6 展示了这一过程。

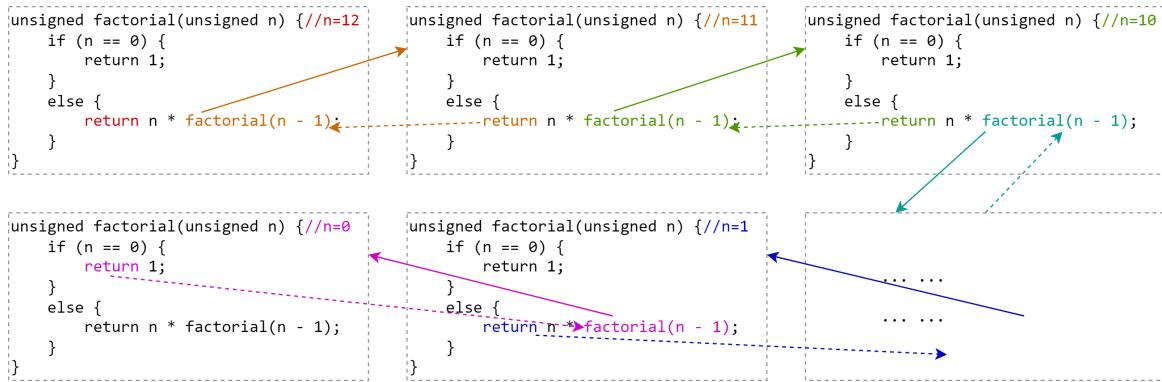


图 4.6: factorial 函数递归的运行过程

“函数递归运行的过程中, 难道还能真的像图 4.6 那样, 运行到一半再跑到开头吗? ”

读者可能容易产生这样的误会, 认为“既然它是同一个函数, 那递归的时候不就是在这一一个函数中打转嘛”。

不然。这个函数在编译时和运行时的概念是不同的。在编译时, 编译器会认为它是一个函数; 但在运行时, 内存中会为程序创建一个调用栈 (Call stack) 来存储函数调用的信息。每次函数调用 (包括一般调用和递归调用) 都会在栈中压入一个堆栈帧 (Stack frame), 这个堆栈帧中存储了本次调用的必要信息 (比如, 本次调用的实参是什么, 返回地址是什么)。在结束调用时, 返回值传回给调用它的函数 (栈的结构保证了调用它的函数也在调用栈中), 然后堆栈帧移除, 如图 4.7。

简言之, 虽然只有一个函数, 但有很多个堆栈帧, 每个堆栈帧存储了各自的调用信息。所以自然不会有冲突了。

“为什么一定要有终止条件呢? 难道不能像 `while(true)` 语句这样永远循环吗? ”

我们可以把递归结构当作是一种循环, 而 `for` 或 `while` 可以更具体地说是一种迭代 (Iteration)。从功能上讲, 递归和迭代是非常相似的, 它们可以互相替代, 而关于“用递归还是迭代”的讨论也是旷日持久。这里我们先不参与此讨论, 只解答原本的问题。

递归与迭代有一点不同在于, 迭代语法不需要依赖调用栈, 比如 `for(int i=0; i<1e9; i++)`, 无论循环多少次, `i` 永远占据一个 `int` 的内存空间; 但递归是需要依赖调用栈的, 并且调用栈的大小有限, 一旦内存不够, 就会发生堆栈溢出 (Stack overflow), 直接导致程序故障罢工。正因如此, 我们可以写无限循环的迭代, 但不能写一个无限循环的递归。

希望读者看过上述的讲解以后, 已经对递归有了基本的认知。

在编程时, 善用递归可以帮助我们节省很多写代码的麻烦。再举个例子, 我们打算写一个简单的



图 4.7: 调用函数时压入堆栈帧, 返回值后移除堆栈帧

求斐波那契数²¹的函数, 通过传入的正整数参数 n 来求出斐波那契数列的第 n 项。

如果用递归来写这个函数, 就要比迭代轻松不少 (尤其是在我们还没有学习数组的时候)。

```
unsigned fibonacci(unsigned n) {
    if (n <= 2) { // 前两个数的值都是 1, 直接给定
        return 1;
    }
    else { // 第  $n$  个数由第  $n-2$  个数加第  $n-1$  个数得到
        return fibonacci(n - 2) + fibonacci(n - 1);
    }
}
```

4.6 函数模板简介

在重载 `max` 时, 我们发现一个问题: 如果我们只提供这两种重载:

```
double max(double, double); // 接收两个 double 类型参数
long long max(long long, long long); // 接收两个 long long 类型参数
```

那么当我们调用 `max(1,2)` 时就会出现二义性问题。这是因为, `int` 隐式类型转换为 `double` 类型或 `long long` 的优先性相同, 编译器就会面临两难处境, 不知该转换成哪种类型是好。解决的方法也很简单, 我们再重载一个 `int max(int, int)` 就好了嘛。

```
int max(int, int); // 接收两个 int 类型参数
```

²¹ 斐波那契数列 (Fibonacci sequence), 是一个特殊的数列。它的前两项都是 1, 而后面的每个斐波那契数都由前两项相加得到。前十一个斐波那契数为: 1, 1, 2, 3, 5, 8, 13, 21, 34, 55。

但这不是一劳永逸的方案。如果我们之后又需要做两个 `long double` 求最大值的操作，那么我们还需要再作如下重载：

```
long double max(long double, long double); // 接收两个 long double 类型参数
```

实际操作中我们不一定碰到这么多类型一起出现的情况，但是为了同样的功能写这么多重载，而且每次用别的类型时都要考虑“是否还要加一个重载”，这是很麻烦的。能不能有一种方案，可以针对各种不同的类型，一次性给出同样的解决方案呢？泛型编程（**Generic programming**）的理念就这样应运而生了。

泛型编程理念的核心在于，我们无需考虑具体的数据类型，只要给它们一套通用的模版（**Template**）即可。而编译器会根据代码中的需要，生成对应的函数实例（**Instance**）。

以求两数最大值的函数为例，我们可以定义如下的函数模版（Function template）。

```
template<typename T> // 假设一个模版参数 T, T 可以是任何一种类型
T maximum(T a, T b) { // 返回类型为 T, 接收两个 T 类型的参数
    return a > b ? a : b; // 用条件表达式实现, 代码更简洁
}
```

这里之所以使用 `maximum` 名字是因为 `std` 命名空间中已有 `max` 模版，为了防止重名引起一系列麻烦，就在此处换用它名。²²

这里我们用 `template` 关键字定义一个模版，这个模版有一个模版参数，名为 `T`，它就是“某个类型”。

然后是函数定义（声明）部分，我们指定了这个函数模版的返回类型为 `T`，名称为 `maximum`，接收两个 `T` 类型参数。

再看函数体，这里涉及到了一个条件表达式，用到了条件运算符“`@? :@`”。条件运算符的功能很容易理解，它接收三个操作数，如果第一个操作数的值是 `true`²³，那么条件运算符的返回值就是第二操作数；如果第一个操作数的值是 `false`，那么条件运算符的返回值就是第三操作数。在本函数模版中就可以这样理解：如果 `a>b` 得到 `true`，就返回 `a`；否则返回 `b`——这和使用 `if-else` 结构的作用是相似的。

接下来我们就可以在主函数中使用 `maximum` 函数模版了。非常简单：

```
int main() {
    cout << maximum(1, 2) << endl; // 调用 int maximum(int,int)
    cout << maximum(1ll, 0ll) << endl;
    // 调用 long long maximum(long long,long long)
    cout << maximum(1., 2.) << endl; // 调用 double maximum(double,double)
    cout << maximum(1.l, .1l) << endl;
    // 调用 long double maximum(long double,long double)
}
```

编译器在知道了这个函数模版之后，每当遇到需要的函数（比如，调用 `maximum(1,2)`，需要一个 `maximum(int,int)`），就会根据这个模版，制造一个 `maximum(int,int)` 函数来匹配它。

那么在这个主函数中我们用四种类型的参数调用 `maximum` 函数，编译器就会根据需要，制造四个函数：

```
int max(int a, int b) { // int 版本
    return a > b ? a : b;
}
```

²² 我们会在第七章中讲解如何规避这类问题。

²³ 如果第一操作数不是 `bool` 类型，会进行布尔转换变为 `bool` 类型，下同。

```

long long max(long long a, long long b) { //long long版本
    return a > b ? a : b;
}
double max(double a, double b) { //double版本
    return a > b ? a : b;
}
long double max(long double a, long double b) { //long double版本
    return a > b ? a : b;
}

```

所以说，使用函数模版相当于我们给编译器提供了一个范本，而编译器会根据这个范本来制造对应类型的重载。这样不用我们手动写一大堆函数重载了。



图 4.8: 从函数模版到函数实例

我们可以再加一个三数求最值的函数模版。我们可以把它称为函数模版的重载。

```

template<typename T> //假设一个模版参数T, T可以是任何一种类型
T maximum(T a, T b) { //返回类型为T, 接收两个T类型的参数
    return a > b ? a : b; //用条件表达式实现, 代码更简洁
}
template<typename T> //注意, 每次声明(定义)模版都需要写template, 不能共用
T maximum(T a, T b, T c) { //返回类型为T, 接收三个T类型的参数
    return a > b ? (a > c ? a : c) : (b > c ? b : c); //请读者自行分析
}

```

本节只是对模版函数和泛型编程作一个简单介绍，我们会在第十一章更详细地探讨这方面的问题。

第五章 复合类型及其使用

在前面的章节中，我们讲了基本数据类型。不同类型数据的使用可以帮助我们解决一些小规模的问题；再搭配函数的使用，可以让我们的代码更成体系，更有逻辑。

复合类型（Compound type）的出现让函数的功能大放异彩。借助复合类型，我们可以实现更加复杂的功能，比如数据的批量处理（数组），函数的实参修改（指针和引用），以及动态内存分配。很多技术含量较高的代码必须借助复合类型才能实现，所以本章所介绍的内容有着承前启后的作用。

本章主要介绍指针、引用和数组相关的知识；至于结构体、联合体和类，我们留到下一章再讲解。

在本章，我们也将使用 `typeid` 和 `std::is_same` 等运算符或函数，来帮助我们梳理复合类型与基本类型之间的关系，它们是我们处理类型问题时相当有用的工具。

5.1 指针

“我认为赋值语句和指针变量可以说是计算机科学最具价值的宝藏。”¹

——高德纳²

内存与地址

在一个 C/C++ 程序运行时，内存中会存储着有关这个程序的信息。我们可以把这些内存空间分为五个区段（如图 5.1 所示）：

- 代码段（Code/Text Section）。这个区域存储着一系列指令，可以告诉电脑这个程序要做什么。比如说，函数的定义就在在代码区中，这部分内容告诉电脑它要做什么。
- 数据段（Data Section）。这个数据区不意味着“存储所有的数据”。它只存储一些全局变量或已初始化的静态变量，也就是在函数之外的域中定义的数据³
- BSS 段（BSS Sectino）。通常用于存放未初始化的静态变量。
- 栈段（Stack Section）。局部变量（比如主函数中定义的变量）和每次函数调用时的实参等信息，都存储在栈区（想想我们上一章中讲到的“调用栈”）。每次我们定义一个新数据，这个数据的信息就会被压入栈中，当这个数据的作用域结束时，它就会出栈。
- 堆段（Heap Section）。用于动态内存分配。我们会在本章中介绍动态内存分配。

内存中有无数字节，不同的数据需要不同的字节数量来存储，我们可以用 `sizeof` 来计算字节数量的值。

¹原文：I do consider assignment statements and pointer variables to be among computer science's "most valuable treasures."

²高德纳（Donald Ervin Knuth），美国计算机科学家和数学家，1974 年图灵奖得主。高德纳成就颇丰，其中最负盛名的是它的著作《计算机程序设计艺术》（*The Art of Computer Programming*）。

³我们会在第七章讲解有关知识。



图 5.1: 程序的内存布局

既然内存中有这么多字节，那么程序要怎么判断自己要用的数据在哪里呢？这就需要用到内存地址（Memory address）了。

内存中的每个字节都有一个内存地址。就像我们根据门牌楼号来找到一间房子那样，程序也需要通过内存地址才能快速找到一个字节，并且读取或者修改它的值。

举例来说，我们在主函数中定义一个 `char` 型变量，命名为 `ch`。在运行时，每当遇到了这个指令，程序就会在栈段当中找到一个闲置的字节，用来存储这个变量的值。那假如我们定义一个 `double` 型的变量 `d` 呢？程序会在栈区中找到八个连续的闲置字节（在绝大部分系统中，`double` 型的内存空间占用都是 8 字节），用来存储这个变量的值。

在 C++ 中，`&` 运算符可以对某个变量求地址。一般说来，如果要输出地址的话，地址值都是用十六进制的形式⁴来表示的。`&` 运算符单独作用于一个变量时，返回值是它的地址⁵。

```
int main() {
    double d {3.1415926}; // 定义一个 double 型变量 d
    cout << &d; // 用&取 d 的地址值并输出
}
```

这个程序的输出结果是：

0x7ffccff275b8

不同计算机的实际情况可能大相径庭，不同编译器处理内存分配的方式也可以大同小异，所以这个地址的具体值因机器而异，我们需要在意的只是格式。在这里，它输出了一个十六进制的结果，这正是 `d` 的地址值。

细心的读者可能会有疑问：`d` 作为一个 `double` 型数据，明明占据了八个字节，为什么输出结果只给了我们一个地址呢？

这是因为，对于任何一种类型，在取地址时只会返回它的第一个字节的地址。因为任何一个变量占据的内存都是连续的一段，所以我们只要知道了第一个字节在哪里，当然就知道整个变量占据了

⁴即，以 `0x` 开头（有些编译环境，如 MSVC，输出的地址值是不带 `0x` 开头的，所以别惊讶），后面表示为 `0~F`（或用小写）的一串数字，如 `0xe23df5cc`。

⁵并不是所有的数据都可以取地址！我们会在精讲篇中说明，它关系到左值和右值的问题。

哪个区间的内存了。



图 5.2: d 在内存空间中的示意图

如图 5.2 所示，既然 `0x7ffccfff275b8` 是 `d` 的地址，而 `sizeof(double)` 又是 8，那么自然而然，`d` 的信息应当存储在从 `0x7ffccfff275b8` 开始的 8 个字节，一直到 `0x7ffccfff275bf` 为止。

所以无论哪个类型，其内存地址指的都是它所占内存空间中的第一个字节的地址⁶。请牢记这点，它会让你后面的学习过程更轻松的。

补充一条：读者可能会在自己尝试的时候发现一个有趣的现象：如果试图输出一个 `char` 类型的地址，输出的结果可能会是各种奇奇怪怪的内容，但绝对不像是个指针。我们会在字符串那一节再介绍这个问题。如果你坚定地想输出 `char` 变量的地址，你可以采用这种写法：

```
char ch {48}; // 定义char型变量并赋初值'0'
cout << (void*)&a; // 指针类型转换为void*, 这样就会以地址值的形式输出
// 也可以把(void*)&a换作reinterpret_cast<void*>(&a)
```

指针的定义和使用

仅仅知道地址值还不够，我们很难把它用起来。我们的当务之急是，找到一种可以“存储地址值”的数据类型。可是很遗憾，虽然地址值的表示方式像一个整数，但是我们不能把它的值存到整型数据当中。实际上，C/C++ 专门有一大类存储地址值的数据类型，叫作指针变量，简称指针（Pointer）。

请留意，指针不是一个数据类型，而是“一群”数据类型。“指向 `int` 的指针”和“指向 `double` 的指针”是不同的数据类型。

定义一个指针的基本语法如下，这里有两种主流写法可供选择，它们是等价的：

```
<类型>* <指针名>; /*写在<类型>一侧，与<指针名>分开
<类型> *<指针名>; /*写在<指针名>一侧，与<类型>分开
```

⁶除非你重载了取地址函数 `&`，这种情况我们不讨论。

第一种写法更清晰，它说明了这个名字是一个指针类型。

```
int a {0}; // 定义一个 int 型变量 a，并初始化为 0
int* pa {&a}; // 定义一个 int 指针 pa，并初始化为 a 的地址
```

但是它也会引发一些困惑……

```
int* p1, p2; // p1 是 int* 类型，但 p2 是 int 类型！没想到吧
```

第二种写法则不会出现这种困惑，因为本身就是要在指针名一侧写 * 的。

```
int *p_1, p_2, *p_3; // p_1 和 p_3 是 int* 类型，而 p_2 是 int 类型
```

这种写法还能降低其它有关问题的理解成本，我们很快就会遇到。

那么究竟使用哪种写法呢？不同的人当然有不同的理解和习惯，不必强求。不过在编写本书的过程中，我选择我最喜欢的写法：只在描述返回类型的时候用第一种写法，否则用第二种写法。

习惯上，我们喜欢把“p 存储了 a 的地址”称为“p 指向了 a”。这当然是一种很形象的表述，但很多教材会为了这点“形象”而忽略了对本质的阐述，这是得不偿失的。

现在让我们假想这样一个过程：我先定义了一个 `double` 型的变量 `d`，然后又定义了一个 `double*` 型的变量 `pd`（这是一个指针变量）。

```
double d {3.14159}; // 定义一个 double 型变量 d
double *pd {&d}; // 定义一个 double* 型指针变量 pd，它指向 d
```

理论上讲，一个程序只要知道了某个变量的地址，就具备了读取或修改对应内存空间的能力。那么 `d` 这个名字，也就无所谓有没有了。我们能否只根据 `pd` 中保存的地址值，就实现读取和修改 `d` 的功能呢？当然可以！

这里我们需要一个运算符：取内容运算符⁷。读者可能会困惑——这不是乘法运算符吗？其实你可以把它当作一种重载！当它接收两个操作数时，它的含义就是乘法运算；当它接收一个操作数时，它的含义就是取指针的内容（见图 5.3）。



图 5.3：我们可以把 * 接收不同数量操作数的情况当成一种重载

说回原来的话题。通过 * 运算符，我们可以无需变量名就可以读取一个指针的内容；而且在允许的情况下，我们还可以修改其内容，这个修改是直接对内存中的内容进行修改，和修改 `d` 的值一样直截了当。

```
double d {3.14159}; // 定义一个 double 型变量 d
double *pd {&d}; // 定义一个 double* 型指针变量 pd，它指向 d
cout << *pd << endl; // 输出 pd 取内容的结果，当然是 3.14159
*pd = 2.71828; // 修改 pd 对应内存中的内容，等效于直接修改 d 的值
cout << d; // 输出 d 的值，会发现结果是 2.71828
```

读者可以自行运行这段程序，或者写一些别的代码试试，会发现 `d` 和 `*pd` 的特征非常相似，它们几乎就是同一个事物！

从本质上讲，变量的名字只是一个“表象”而已，藏在背后的最关键的东西还是内存中对应的若干字节中存储的信息。C/C++ 允许我们自定义变量名，这样的好处在于，我们可以不必像汇编语言

⁷也有很多资料将其称为解引用运算符。

那样，用一些枯燥的 `rip`, `rsp`, `eax` 之类的名字来描述真实世界中丰富多彩的信息，而是用一些顾名思义的名词，让我们和别人看了都能懂。

但计算机还是要把这些名字还原成内存中的一个个信息，然后再处理。变量名对于计算机来说，只是一个绑定了相应内存地址的名字罢了。于是 `d` 和 `*pd` 没什么分别；`&d` 和 `pd` 也没什么分别。图 5.4 阐述了它们的关系。



图 5.4: 变量 `d`、地址 `&d`、指针 `pd` 与内容 `*pd` 的相互关系

这个关系是循环的，我们可以先取地址再取内容，最后得到的东西和 `d` 是一回事。所以我们还可以对这个东西再取地址，再取内容，再取地址，再取内容……以至无穷。

```
cout << *&*&*&*&d; //*&*&*&*&d 相当于 *&*&*&d, 相当于 *&d, 相当于 d
```

不过这种写法就太没意义了，绕了一大圈，最后还是回到 `d`。实际编程中我们不会这么做。

但是不要止步于此。指针的存在还为我们提供了一种新的可能性：我们可以绕过“变量名”这一步，直接用指针来访问和修改内存中的信息。这是我们后续要讲的指针参数传递、数组和动态内存分配的基础。

指针参数传递

在写函数的时候，我们可能会试图通过函数来改变实参的值。举个例子，我们想写一个函数 `exchange`，来交换它的两个实参的值。为了方便阐述，我在这里就不用函数模版了，我们假定它接收两个 `int` 参数。

```
void exchange(int a, int b) { //这里只需实现副作用，无需求值，故设返回类型 void
    int tmp {a}; //定义一个临时变量 tmp，用以存储 a 的值
    a = b; //赋值，现在 a 获得了 b 的值，我们的目标完成一半
    b = tmp; //赋值，现在 b 获得了 tmp 的值，也就是 a 原来的值
    return; //对于返回类型为 void 的函数来说，return 是可有可无的
}
int main() {
    int a {3}, b {4}; //定义 a=3, b=4
    exchange(a, b); //交换 a 和 b 的值，预期是 a 变成 4, b 变成 3
    cout << a << ' ' << b; //输出 a 和 b 的值，检验一下结果
    return 0;
}
```

这个程序的运行结果是

3 4

这个代码的逻辑看上去很正确，但是为什么它完全不起作用呢？

回想一下我们之前讲过的内容。每次程序调用一个函数的时候，都会在栈区压入一层堆栈帧。这个堆栈帧中就含有在本次调用过程中创建的变量，如图 5.5 所示，这时调用栈中发生修改的是 `exchange` 对应内存空间中的 `a` 和 `b`，而不是 `main` 函数中的 `a` 和 `b`。这两对变量虽然同名，但它们对应的是内存空间中完全不同的区域。



图 5.5: 在调用 `exchange` 函数时，调用栈中发生的变化

所以在函数参数传递的过程中，程序并没有把“整个变量”传递给目标函数，而只传递了它的“值”。至于被调用的那个函数，它会另外定义一个新的变量（它在内存空间中另一自己的一席之地）来接收传入的值。很多资料会把它称为副本（Copy）。



图 5.6: `main` 向 `exchange` 中传入的信息只有值

我们会发现，不同函数之间只能共享值，这种现象好像一种屏障——在某些时候，它显得十分安全，我们不会在一个函数中乱改其它函数中的信息；但在另一些时候，它显得非常不灵活，如果我们用别的函数只能读取而不能修改此函数中的值，函数的功能就会受到很大限制——比如我们试图写一个值交换函数而不能。

所以我们需要找到一种方法，使我们可以跨过函数作用域的屏障，来修改特定的变量值。我们的

答案是使用指针传递（Passing by pointer）。

回顾一下前文中讲过的三个基本要点：

1. 地址是一个值。我们可以把它当作和整数值、浮点值、字符值和布尔值等并列的事物来看待。
2. 只要知道了某个变量的地址，我们就有可能修改内存中相应区域的内容。我们可以通过取内容运算符来读取或修改其中的内容，效果等同于使用相应的变量名。
3. 指针是一大类数据类型，它们存储的信息是地址值。如果一个指针存储了某个变量的值，我们可以说“这个指针指向那个变量”。

搞清了以上三点之后，我们就不难想到另一种可能性——如果我们把 a 和 b 的地址作为参数传给 exchange 呢？

地址是一个值，因此它可以作为实参来传递，没有问题。

只要 exchange 函数知道了 a 和 b 的地址，那么它自然具备了修改 a 和 b 的内容的能力。也没问题。

那么 exchange 函数要用什么形参来接收地址值呢？当然是用指针，因为只有指针才能存储地址值。

于是一切顺理成章，我们的解决方案就给出来了。现在我们就来试着来改一下 exchange 函数：

```
void exchange(int *pa, int *pb) { // 它接收两个int*参数
    int tmp = *pa; // 定义一个临时变量tmp，用于存储*pa的值
    *pa = *pb; // 赋值，现在*pa获得了*pb的值
    *pb = tmp; // 赋值，现在*pb获得了tmp的值，也就是*pa原来的值
}
int main() {
    int a {3}, b {4}; // 定义a=3,b=4
    exchange(&a, &b); // 向exchange函数传递&a和&b的值，也就是地址
    cout << a << ' ' << b; // 输出a和b的值，检验一下结果
    return 0;
}
```

最后的运行结果果然不出我们所料，正是

4 3

所以这种函数参数指针传递的方式要比我们之前见过的值传递（Passing by value）更有效。但是话又说回来，并不是任何时候用指针传递都比用值传递要更好的。初学者可能很难搞清楚“什么时候要用什么”，其实没关系。你只需要多写一些代码，等到经验丰富之后自然就清楚了。

还请读者留意：虽然我们人为地划分出了“值传递”和“指针传递”的概念，但它们的本质都是在传递值！只不过后者传递的是“指针值”罢了。

野指针问题

说完了指针在函数传递中的应用，读者应当对指针的强大有了初步认识。指针为我们编写程序带来了极大的灵活性，但其中也潜藏着一些风险。所以现在就让我们返回到一些细节的讨论上来。

我曾说过，如果定义一个局部变量而不初始化的话，它将会存储一个不确定的值。使用这种不确定的值可能会导致程序运行的结果不可预测，所以我们需要在使用它之前通过初始化、赋值或输入等等各种方法让它成为一个可控的变量。

指针亦如此。如果我们不进行初始化或赋值，让它指向一个安全的位置，那么它可能会指向内存中的任何一个字节，我们把这种指向不确定的指针叫作野指针（Wild pointer）。野指针是很可怕的，一旦我们试图读取或修改对应未知空间中的信息，我们可能会把这个程序乃至其它进程改爆，从而导致严重的后果⁸。因此，在使用指针之前，我们也要进行初始化或者赋值⁹。

我们可以用同类型变量¹⁰的地址来为指针赋值，我们已经在前面的例子中接触过这种语法了。不同类型数据的地址不能互相赋值，比如我们不能用 `float` 型变量的地址来为 `double*` 型指针赋值。

```
float f; // 定义 float 变量 f
double *pd; // 定义 double* 指针 pd
pd = &f; // 试图将 f 的地址赋值给 pd
//error: cannot convert 'float*' to 'double*' in assignment
```

这个报错信息的意思是：在赋值时，`float*` 类型（即 `&f`）不能隐式类型转换为 `double*` 类型（即 `pd`）。这说明指针类型之间不能随便进行隐式类型转换。

如果我们定义了一个指针，但暂时还不想让它指向哪个变量，而又害怕空置会产生野指针，那么我们还有一个选择：`nullptr`。

```
long long *pll = {nullptr}; // 定义 long long* 型指针并指向空地址 nullptr
```

空地址（`nullptr`）不是一个运算符，它是一个常量地址。`nullptr` 的类型比较特殊，它是 `nullptr_t` 类型的，我们知道这个也没什么用。但这个类型的特点在于，它可以隐式类型转换为任何一个指针¹¹类型。因此，`nullptr` 可以为各种指针进行初始化。

`nullptr` 是受保护的。我们对它的内容进行的读取和修改都没有任何意义，也不会造成任何风险。所以当我们不需要这个指针指向什么时，最好让它指向空地址 `nullptr`。我们在动态内存分配章节中就会讲到它的一种应用，那就是在动态内存回收之后，为防野指针出现，就让这个指针指向空地址。

指针的运算

接下来讲解一下指针的运算。虽然指针的值很像整型数据，但是它的加减法规则与整型数据截然不同。

两个指针的加法是没有意义的，因为我们根本不能确定加完了之后得到的地址是指向什么的（这不是野指针吗）。

而指针与整型的加/减法是有意义的，尤其是在数组当中。一个指针与整数相加/减，它的返回值是和原来指针相同的类型（比如说，`int*` 与 `short` 相加/减，返回值为 `int*`）。

```
float f, *pf {&f}; // 这里不需要初始化 f，因为只需用到其地址，而不需要其值
cout << pf << endl << pf - 1 << endl; // 输出 pf 和 pf-1 的值，它们都是地址值
long double ld; // 同理，只是改成了 long double 型
cout << &ld << endl << &ld + 1; // 直接输出 &ld 和 &ld-1，效果相同
```

运行结果是这样的¹²：

```
0x7ffc4bf3837c
0x7ffc4bf38378
```

⁸对于个人电脑来说，这种后果可能很轻微——大不了我们重启电脑，这时内存中的一切又焕然一新了。但对于服务器等需要长期运转且不能轻易停机的设备来说，损失可能非常大。

⁹我们不能通过“输入地址”的方式来改变指针的值，这同样是很危险的。

¹⁰实际上，指针也是一种变量。但是人们习惯上把“指针”和“变量”视为互不重合的两个概念。本书也沿用这种习惯，通常把指针和变量这两个概念分开。如果需要把指针当作变量的一部分，会特殊说明。

¹¹乃至高阶指针，见后面的章节。

¹²再次提醒读者，实际输出的内存地址因机而异，我们应当关注的是几个输出地址之间的相互关系。

```
0x7ffc4bf38380
0x7ffc4bf38390
```

输出内容是很长的十六进制形式，我们来分析下。

首先输出的两个是 `pf` 和 `pf-1` 的值。从数值上看，前者是 ...37c，而后者是 ...378，后者虽然是 `pf-1`，但地址却减小了 4 个字节。

接下来输出的两个是 `&ld` 和 `&ld+1` 的值。从数值上看，前者是 ...380，而后者是 ...390，后者虽然是 `&ld+1`，但地址却增加了 16 个字节。

之所以会出现这种情况，关键就在于不同类型数据在内存中占用的字节数目不同。一般说来，`float` 型占据 4 字节内存空间，而 `long double` 型占据 16 字节内存空间。

指针和整型的加减法并不是单纯地移动多少个字节，而是移动了多少个数据（可以理解为，偏移量乘以单个数据占用的字节数），如图 5.7 所示。这样设计是有它的道理的，等我们讲到数组，读者就会很容易理解了。




图 5.7: 指针加法运算的偏移量是以数据为单位的，而不是地址值

两个同类型指针可以相减，其返回值是一个特殊的类型，叫作 `ptrdiff_t`。不过我们也无需纠结这种细节，因为 `ptrdiff_t` 可以隐式类型转换为整型，所以我们可以直接把它当作整型来用，比如输出。

```
int a, b, c;
cout << &a << endl << &b << endl << &c << endl;
cout << &a - &b << ' ' << &c - &a << endl;
```

运行结果是这样的：

```
0xffff604ad654
0xffff604ad658
```

```
0x7fff604ad65c
```

```
-1 2
```

我们可以看到，这里的 `a`, `b`, `c` 地址值依次递增 4，而 `&a-&b` 得到 `-1` 而非 `-4`，这说明指针的减法也是在计算数据偏移量，而不是字节数偏移量。

5.2 “常量指针”与“指向常量的指针”

我们在前面讲基本数据类型时，曾经用 `const` 限定符来标记一个变量，使之成为常量；或用 `constexpr` 限定符来标记一个变量，使之成为常量表达式。

既然指针也是“变量”的一种，那么我们能否用 `const` 或 `constexpr` 来把它们变成常量或常量表达式呢？

先说结论：我们可以使用 `const`，将指针限定为“常量指针”或者“指向常量的指针”乃至“指向常量的常量指针”。但是我们不能定义成 `constexpr`，因为编译器是不可能未卜先知，知道某个变量在运行时的地址。

那么什么是常量指针，什么是指向常量的指针呢？本节就来介绍这两个概念。

当我们拿到一个没有任何限制的指针时，我们可以对它的指向进行修改——也就是修改这个指针所存储的地址值；我们还可以通过取内容运算符 `*` 来对它的内容进行修改——也就相当于修改对应变量的值，而修改之后这个指针依然指向原来的位置。如图 5.8 所示。

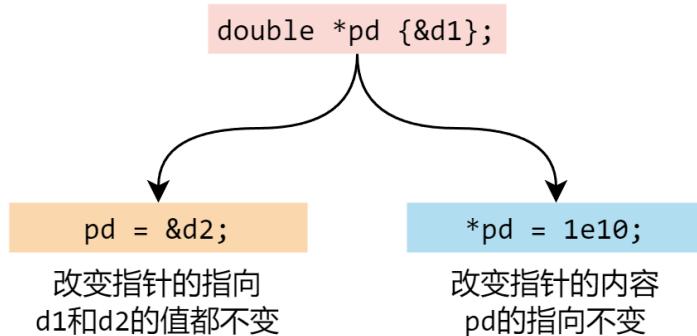


图 5.8: 修改指针的指向/修改指针的内容

我们可以通过 `const` 来限制指针的一部分修改能力，从而将其变为常量指针或指向常量的指针。为了避免在代码上出现误解和混淆，我先介绍概念。

- **常量指针 (Constant pointer)** 限制了指针改变指向的能力。这种指针一经初始化，就不能改变指向。但是这不影响我们可以修改它的内容。
- **指向常量的指针 (Pointer to constant, 简称指针常量¹³)** 限制了指针改变内容的能力。我们不能用这种指针来改变内容，但是它可以改变指向。虽然名为“指向常量的指针”，但它也完全可以指向变量。如果它指向变量，那么我们可以用变量名来修改内容；但是不能用这个指针来修改内容。

我们还可以用更符号化的表述来阐释它们之间的关系：

如果 `pd` 是一个常量指针，那么 `pd` 不能改变；但 `*pd` 是有可能改变的。

如果 `pd` 是一个指向常量的指针，那么 `*pd` 不能改变；但 `pd` 是有可能改变的。

¹³笔者十分不推荐使用“指针常量”这个名字！它极易与常量指针混淆。

当你理顺了它们的区别之后，我们就来讲讲怎么用 `const` 限定符来把指针限制成常量指针或指向常量的指针。这是定义的语法：

```
const int *ptc1; // 定义一个指向常量的指针。它可以改变指向，所以无需初始化
int const *ptc2 {nullptr}; // int与const的位置可互换，也是定义指向常量的指针
int* const cp {nullptr}; // 将const置于*之后，定义一个常量指针，必须初始化
```

怎么理解这个定义语法，并把这三种看上去非常相像的语法区分开呢？我们可以这样想：

`const` 会对它所标记之物作出限制，使其不能改变。如果 `const` 限制的是 `p`，那么 `p` 就不可改变，但 `*p` 可以改变——这正是常量指针的特性；如果 `const` 限制的是 `*p`，那么 `*p` 就不可改变，但 `p` 可以改变——这正是指向常量指针的特性。

回到我们的定义语法。`const int *ptc1` 这里，我们看，`const` 之后的部分除了 `int`（这个不用管）就是 `*ptc1`，于是 `const` 直接限定了 `*ptc1`，所以 `*ptc1` 不可变，而 `ptc1` 可变，所以它是指向常量的指针；

`int const *ptc2` 同理，`const` 直接限定了 `*ptc2`，所以 `*ptc2` 不可变，而 `ptc2` 可变，所以它也是指向常量的指针；

到了 `int* const cp` 这儿，情况有点不太一样。`const` 直接限定了 `cp`，所以 `cp` 不可变，而 `cp*` 仍然可变，所以它是常量指针。

图 5.9 可以帮助你梳理它们之间的区别。

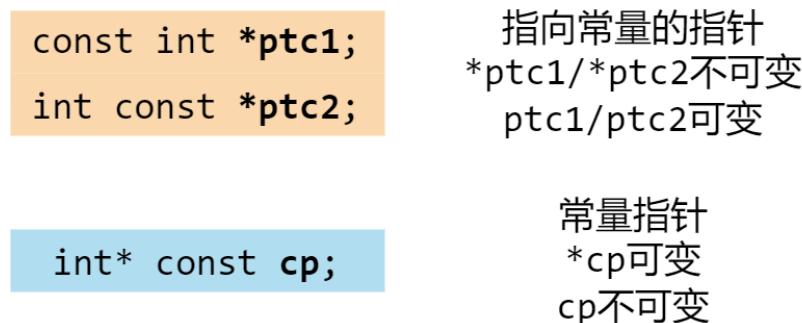


图 5.9: `const` 限制了什么？

知道了这个语法规则，那么定义一个“指向常量的常量指针”的语法也就很容易理解了：

```
const int* const cptc {nullptr}; // 定义一个指向常量的常量指针
```

在这里，第一个 `const` 限制了 `*cptc` 不能改变，而第二个 `const` 限制了 `cptc` 不能改变，所以这个指针一经定义，既不能改变指向，也不能改变内容。

指向常量的指针常见于函数参数，因为很多时候我们需要限制函数对参数的修改能力，确保有些信息是只读的，以免在函数中不小心修改与参数有关的信息。举例来说，`cstring` 库中有 `strlen` 函数，它可以求出一个字符串¹⁴的长度。这个函数的声明格式是

```
std::size_t strlen( const char* str );
```

这很好理解。既然它只是求算字符串的长度，那么当然没有必要让它具备修改目标字符串的能力，因此直接定义成指向常量的指针就没有潜在风险了。

¹⁴ 我们会在后面讲到字符串。

5.3 (左值) 引用与引用参数传递

我们在前文中介绍了指针参数传递。这种方法固然强大，但是每次传递参数都要使用指针或地址，这就显得有点麻烦了。如果读者了解 C 语言的话，应该就会知道，每次我们使用 `scanf` 来进行输入，都要用取地址符来传入相应变量的地址方可。

```
int num;
scanf("%d", &num); // 传递 num 的地址，这样才能改变 num
```

而在 C++ 中，每次我们使用 `cin` 来输入变量的值时，都不需要取其地址。但是按照我们之前的讲解，如果按值传递的话，我们只能修改副本中的数据，而不会影响原数据。这是怎么回事呢？

```
int num;
cin >> num; // 为什么不用传递地址，也可以改变 num 的值？
```

要解决这个问题，我们就需要了解引用¹⁵ (Reference) 及其在参数传递过程中的作用。

什么是引用？

我们曾言，变量名不是变量的本质。如果两个不同的变量名绑定了同一个地址，那么它们表达的信息就是相同的¹⁶。我们可以用其中一个名字来读取或修改它们的值，当然也可以用另一个名字。

引用的作用相当于变量的别名，定义一个引用的基本语法是

```
<类型> &<引用名> = {变量}; // 必须在定义之时初始化
```

这里的 `&` 不是取地址运算符的意思，而是表示我们在定义引用。一旦这个引用绑定了这个变量，它就充当了这个变量的别名，我们使用引用的效果与使用变量名等同。

```
int a {3};
int &ref {a}; // 定义一个引用，它充当 a 的别名
++ref; // 更改 ref 相当于更改 a
cout << a; // 输出 a 的值，观察结果
```

这个程序的输出结果将会是 4。这说明我们用 `ref` 和用 `a` 的效果是相同的。

如果你去输出一下它们的地址就会发现，`ref` 与 `a` 的地址是相同的。

```
cout << &ref << endl << &a; // 输出 ref 和 a 的地址，它们应当相同
```

我们还可以定义常量引用，它同样是一种引用，但 `const` 限制了我们通过这个引用来修改变量值的能力。

```
int a {3};
const int &ref {a}; // 定义一个常量引用
++a; // 没问题，a 是一个变量
++ref; // 错误！
//error: increment of read-only reference 'ref'
```

在这种情况下，我们可以用 `a` 来修改相应的值，但不能用 `ref` 来修改相应的值。这说明，“变量”和“常量”并不是直接体现在数据中的信息，而只是“变量名”对数据内容是否拥有修改权限的体现。

至于本来就定义成常量的数据，如果我们用普通引用来作为它的别名，编译器就不会允许。

```
const double std_gravity {9.80665}; // 这是一个常量
double &refgravity {std_gravity}; // 错误！
```

¹⁵泛讲篇中不讲解右值引用，这里提及的所有引用都指左值引用。

¹⁶当然，这两个变量名必须是同一类型的，因为类型会影响内存信息的解释方式。

```
//error: binding reference of type 'double&'  
//to 'const double' discards qualifiers  
const double &ref_gravity {std_gravity}; //正确
```

总而言之，我们只能用常量引用来绑定常量。而我们可以使用普通引用或常量引用来绑定变量。如果使用常量引用来绑定变量，我们可以用变量名来修改变量的值，但不能使用引用。

引用参数传递

还记得我们在讲指针时介绍的 `exchange` 函数吗？如果要使用引用来接收实参，那么我们就相当于在 `exchange` 函数中创造了这个实参的别名，它和 `main` 函数中的变量共享了相同的内存地址。于是我们可以直接用这个“别名”来修改实参的值了。这种方式又被称为按引用传递（Passing by reference）。

```
void exchange(int &a, int &b) { //接收两个引用参数  
    int tmp {a}; //临时变量  
    a = b;  
    b = tmp;  
}  
  
int main() {  
    int a {3}, b {4};  
    exchange(a, b); //传入实参  
    cout << a << ' ' << b; //输出，检验结果  
    return 0;  
}
```

最后的输出结果也合乎我们的预期，正是

4 3

这说明我们的确可以用它来完成数值交换的操作。

另外你可能还记得，我们在前面介绍了一个设置了默认参数的 `input_clear` 函数，用以清除错误输入。它的定义中就使用了引用参数：

```
void input_clear(istream &in = {cin}) { //不提供参数时使用默认参数cin  
    in.clear(); //清除错误状态  
    while (in.get() != '\n') //清除本行输入  
        continue;  
}
```

为什么要使用引用参数呢？这是因为，我为了清除 `cin`（或其它 `istream` 对象）的错误状态，必须要对实参作出修改。如果按值传递的话¹⁷，我修改的只能是 `in` 这个副本的状态。

引用参数传递还有一些其它的功用。很多时候我们希望把某个类型的对象（变量）传入函数中，我们不需要修改它的值，所以按值传递也可以。但是这个对象可能占用非常大的内存空间（通常是某种数据结构或类），如果在函数调用时要为它建立一个副本的话，那就既浪费内存空间，又浪费算力和时间。这时我们会选择这样定义函数：

```
void func(const Type &obj) {接收Type类型的常量引用  
    //...
```

¹⁷实际上这是不可能的，`istream` 类已经删除了拷贝构造函数，所以这个语法根本不能通过编译。

```
}
```

这样只是为传入的实参创建了一个别名而已，并不需要浪费大量的时间和空间来作复制工作。如果要防止误修改实参，我们也可以把它定义成常量引用，这样就不会出问题啦。

引用作为返回值

来看一看这个语句，它初看上去可能有点费解：

```
(num *= num) %= 11; //这是在做什么？
```

让我们用前面学过的运算符的有关知识来分析一下吧：

首先，`%=` 运算符把 `(num*=num)` 与 `11` 隔开。而在 `num*=num` 表达式中，`*=` 的作用是乘赋值，于是这个表达式的作用是把 `num` 变成 `num` 的平方。

下一步，因为赋值语句返回的是左操作数本身，所以 `(num*=num)%=11` 的作用相当于 `num%=11`。

我们可以试着写一两个函数来模拟这个语句的行为，比如说，一个叫乘赋值 `mul_ass`。它接收的第一个参数是引用，这是为了能够改变它的值；第二个参数是常量引用，这是因为我们无需用 `b` 来修改它的值。

```
int mul_ass(int &a, const int &b) {
    a = a * b;
    return a;
}
```

这样一来我们就可以用 `mul_ass(num, num)` 来实现和 `num*=num` 一样的功能了。

接下来我们应该把它的返回值扔到 `rem_ass` 当中了。

```
int rem_ass(int &a, const int &b) {
    a = a % b;
    return a;
}
```

这样我们就可以用 `rem_ass(num, 11)` 来实现和 `num%=11` 一样的功能了。

但是如果我们这么写，编译就会出现问题：

```
int num {5};
rem_ass(mul_ass(num, num), 11);
//error: cannot bind non-const lvalue reference of type 'int&'
//to an rvalue of type 'int'
cout << num;
```

编译器报错信息的意思是：“不能把 `int&` 型的左值引用绑定到 `int` 型的右值上。”关于左值右值的问题，我们暂不讨论；但是这个问题，我们需要解决。

问题的关键在于，函数返回的返回值，其实是一个“副本”，而不是 `return` 所跟的变量本身！因此我们是在对着一个不应该取引用的内容¹⁸按引用传递参数，那当然就会产生问题了。

这和我们在按值传递参数的过程中面临的窘境如出一辙。而解决方法也很相似，就是使用引用返回值。

```
int& mul_ass(int &a, const int &b) {
    a = a * b;
    return a; //返回值按引用传递，就不会再创建副本了。
```

¹⁸我们在精讲篇中会更详细地探讨此类问题。简而言之，不是所有数据都可以取地址的，也不是所有数据都可以被引用的。

```

}

int& rem_ass(int &a, const int &b) {
    a = a % b;
    return a; // 同上
}

int main() {
    int num {5};
    rem_ass(mul_ass(num, num), 11); // 现在它能正常运行了
    cout << num;
}

```

引用的类型与 `is_same`

我们发现，引用类型与基本数据类型有太多相同之处。比如说，我们可以把引用完全当作变量名来看待，从而我们可以读取或修改内容。还有，我们可以为引用再取一个别名，其效果相当于为原来的变量取一个别名：

```
int num, &ref {num}, &rref {ref}; // 效果等同于&rref{num}
```

再看地址，`num` 和 `ref` 的地址也永远相同，它们的内存大小可以用 `sizeof` 求得，这也是相同的。

看了这么多，我们发现，引用好像是一个分身，或者是真假美猴王那样的关系，我们根本分辨不清谁是本体，谁是别名。

那么，变量与引用的类型一样吗？其实是不一样的。`num` 是 `int` 类型无疑，而 `ref` 和 `rref` 都是 `int&` 类型的。这几个名字看似一模一样，但正主还是原变量，六耳也终究不是孙悟空。¹⁹

那么如何检验类型呢？我们可以用 `type_traits` 库的 `is_same` 来检验之。它是一个类模版，可以接收两个模版参数，并检验它们是否是同一类型。如果相同话，其静态成员 `value` 的值就是 `true`；如果不同的话，其静态成员 `value` 的值就是 `false`。²⁰

```
// 需要包含头文件 type_traits
cout << is_same<int, int>::value << endl; // int 与 int 相同，故输出 1
cout << is_same<double, long double>::value; // 不同，故输出 0
```

提醒读者，`cout` 输出 `bool` 类型的值时，会默认以整数的形式输出。我们也可以用 `cout.setf(ios_base::boolalpha)` 来让它以布尔值的方式输出。

但是这里有另一个问题：尖括号中只能接收类型信息，我们不能直接把一个变量，或者引用，或者指针塞进去。这时我们就要用到 `decltype` 了。`decltype` 是一个编译时操作，它会解释出一个表达式的类型。

```
int num;
cout << is_same<decltype(num), int>::value; // 将输出 1
```

因此我们可以用 `decltype` 配合 `is_same` 来判断类型的差异了。

先来看一下 `num`, `ref` 和 `rref` 是不是同一个类型。

```
int num, &ref {num}, &rref {ref};
cout << is_same<decltype(num), decltype(ref)>::value << endl;
cout << is_same<decltype(ref), decltype(rref)>::value;
```

¹⁹ 其实从汇编代码中看，C++ 中的引用全都是通过指针实现的。所以说，在定义引用的过程中，程序上会创建一个我们看不见的指针，包括传引用参数等操作，本质上都是传指针。关于这里的细节，我就不多谈了。

²⁰ 这里出现了很多新概念，比如类模版，模版参数、静态成员等。读者无须知道细节，我们会在后面慢慢道来。

这两句的输出分别是 0 和 1，说明 `ref` 和 `rref` 都是同一个类型的，它们都和 `num` 不是同一个类型的。

接下来我们具体看一下它们三个分别是什么类型。

```
cout << is_same<decltype(num), int>::value << endl;
cout << is_same<decltype(ref), int&>::value << endl;
cout << is_same<decltype(rref), int&>::value << endl;
```

这三个输出的结果全部为 1，说明 `num` 是 `int` 类型的，而 `ref` 和 `rref` 是 `int&` 类型的，它们并不相同。

`is_same` 是一个很实用的类型判断工具，我们在后面也会用到它的。

5.4 一维数组

在前面的章节中，我们用各种数据类型、运算符和选择结构，可以处理一些小规模的问题。循环结构允许我们用少量的代码处理一些规模较大的问题，但是我们所掌握的数据方面的知识太少，还没有跟得上这样突飞猛进的处理能力。试想，如果我们需要 100 个变量来存储不同信息，并在我们需要时对它进行处理，那么“如果把这 100 个变量存下来”就成了我们的难题。我们要定义 100 个变量吗？这样写起来好像也很麻烦吧。而且更可怕的是，如果我们也不能确定需要多少个数据（可能 100 个，或者 100000 个），那怎么办？我们要怎么搞到这么多变量名啊？

且慢。我在本章中一再提醒读者，变量名并不是变量的本质。如果要读取或者存储某个变量的信息，我们是可以不需要变量名的。假如说现在有三个 `float` 型的变量（每个变量占 4 字节内存），我暂且用 `a`, `b`, `c` 来称呼它们，如果它们在内存中的地址是挨着的，比如图 5.10 中的这种情况，我们可以定义一个 `float*` 类型的指针 `pf=&a`，让它指向 `a`。




图 5.10：如果三个变量在内存中的地址是挨着的，我们可以用一个指针来访问这三个数据

接下来我们就可以用这一个指针访问这三个数据。还记得我们讲过指针的运算吧，`pf+1` 相对于 `pf` 偏移了一个数据（而非一个字节）。既然 `pf` 是 `a` 的地址，那么 `pf+1` 就是 `b` 的地址，`pf+2` 就是 `c` 的地址。

试想一下，如果有 100 个同类型数据，它们都是紧挨着的，那么我们用一个指针 `p` 指向第一个元素，那接下来不就可以用 `p+index` 表示第 `index+1` 个数据的地址了吗？²¹

不过 C/C++ 标准从来就没有保证过“连续定义的若干变量在内存中必须是紧挨着的”。所以我们需要一点点手段来确保这个前提——这就是数组（Array）。

本节我们先来介绍一维数组，高维数组留待后面再讲。

一维数组的定义和使用

数组是一大类复合类型，它可用于批量定义数据。定义一个数组的基本的语法是

```
<类型> <数组名>[<数组长度>] = {<初始化列表>};
```

其中的长度是一个 `size_t` 类型的常量表达式²²。话虽这么说，但因为整型数据都可以隐式类型转换成 `size_t` 类型，所以我们直接用整型的常量表达式来定义就可以。

以下是一些正确的定义方式：

```
double array1[3] = {1e5, .3, -1}; // 正常格式，可省略=号
int array2[4] {1}; // 省略部分或全部内容，省略的部分使用默认值(0)
float array3[] {0.1f, 0.2, 0.3d}; // 省略长度，数组长度会被定为{}内的数据个数
```

而以下的定义方式是错误的：

```
int array4[3] {1, 2, 3, 4, 5}; // 初始化列表中的数据个数超过长度限制
int array5[5] {1, , , ,1}; // 不能略过中间的数据，定义后面的数据
int array6[] {}; // C++ 标准禁止使用长度为0的数组
```

数组是什么类型呢？看上去好像很神秘，但如果我们试着输出这个数组的名字，就会发现，它输出的东西很像是一个地址值²³。

```
cout << array1; // 输出 0x7fff32b2044c 或者别的，总之很像一个地址
```

事实上，在我们日常使用数组的过程中，大部分情况下数组类型都会隐式类型转换成对应类型指针。刚才的输出语句就是一例，在输出之前，`double[3]` 类型的 `array` 会被隐式类型转换为 `double*` 类型，然后作为一个地址值输出。

在涉及加减法时亦如此。`array2` 原本是 `int[4]` 类型的，而在与整型数据进行加减时，就会先隐式转换成 `int*` 类型，然后作为一个指针来进行加减。

不难发现，数组正好有我们在本节开头中所希望的那种性质：其一，一个数组包含了若干连续数据，它们紧挨着排布；其二，数组名可以视作一个指针，我们可以用 `p+index` 的形式来读取或修改它的值。

那么如果我要定义一个大小为 100 的 `int` 数组，并把每个值都变成 0，我可以如何做呢？

```
int array[100] {}; // {} 的中省略了全部的初始化，这样每个数据都会初始化为0
```

如果我要定义一个大小为 10000 的 `int` 数组，并把每个值都变成 1，我又该如何做呢？这里不太一样，我们无法用简洁的语法直接把所有数据都初始化为 1，所以需要另想方法。这里我们可以用 `for` 循环来批量处理这些数据，这时就能体现出循环语句的强大了。

```
int array[10000]; // 无需初始化，反正待会就要赋值
for (int i = 0; i < 10000; i++) // 注意循环的起止条件
    *(array + i) = 0; // array+i 即是第 i+1 个数据的地址，再取内容，就可以修改了
```

²¹注意，`p+0` 是第一个数据的地址，所以以此类推，`p+index` 是第 `index+1` 个数据的地址。

²²现代编译器大都支持数组定义时使用非常量的长度，此时编译器会用一套比较复杂的机制来创建这个数组。但是我仍建议读者在需要使用动态大小的数组时选择动态内存分配语法。

²³字符型的数组依然是一个例外，我们会在后面讲到它。

注意，`array` 是第一个数据的地址，所以 `array+1` 是第二个数据的地址，……，以此类推，第 10000 个数据的地址应该是 `array+9999`。因此在这里我们需要控制循环的起始和终止条件，让 `i` 从 0 开始，到 9999 终止²⁴。

用 `*(array+i)` 这样的方式来访问显得有点麻烦了。在 C/C++ 中，我们还有一种方式可以访问数组的数据，那就是用下标运算符 `[]` 来实现这个功能。在 C/C++ 中，如果 `arr` 是一个数组类型，那么我们可以用 `arr[i]` 的方式来替代 `*(arr+i)`，效果相同。这个语法还可以扩展到指针层面，如果 `p` 是一个指针，我们也可以用 `p[0]` 的方式来替代 `*p`。²⁵

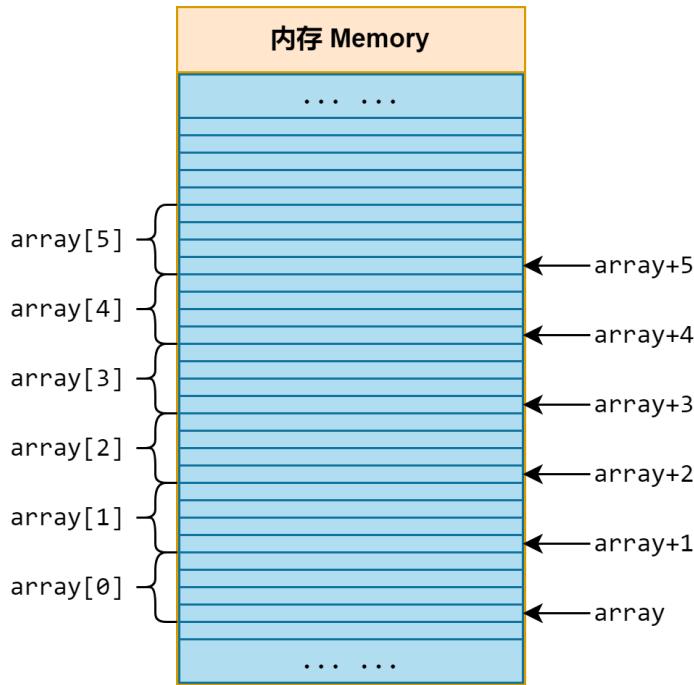


图 5.11: 用 `array[i]` 效果等同于 `*(array+i)`

有了数组之后我们就可以只需要一个名字 `array`，然后通过下标来读取或修改大量数据了。当然，不要忘记数组下标是从 0 开始的，所以 `array` 数组的第一个数是 `array[0]` 而不是 `array[1]`。下面是一个对数组中各数字进行求和的例子，我们需要用户先输入 10 个数，然后求出它们的和。

```
int arr[10], sum {0}; // 定义一个数组arr和int数据sum, sum初始化为0
for (int i = 0; i < 10; i++) // 注意条件
    cin >> arr[i]; // 输入arr[i]的值, arr[i]是arr数组第i+1个数
for (int i = 0; i < 10; i++)
    sum += arr[i]; // 用加赋值运算符, 把arr[i]的值加到sum中
cout << "总计: " << sum;
```

我们可以试一下这段代码的运行效果：

1 2 3 4 5 6 7 8 9 10

总计: 55

它的运行结果也很符合我们的预期。

²⁴虽然我们可以访问 `array+10000`，但我们无法保证这个空间是安全的。换言之，使用 `array+10000` 会带来类似于野指针的问题。

²⁵实际上，对于数组名或指针来说，`p[i]` 形式的表达式都会被编译器当作 `*(p+i)` 来处理，所以这么写只是会让我们自己方便一点而已，对于编译器来说没会么区别。

数组参数传递

我们在前面写了一个 `maximum` 函数模版，它可以求两个数的最大值。现在我们想要求大量数据的最大值，再用 `maximum` 重载的方法就显得太不合适了（即便我们有一个能传递任意数量参数的函数，我们也要衡量一下调用的时候是不是要把一个个参数全都写进去）。为了解决这个问题，我们需要考虑能否用数组来实现这个功能。

在 C++ 中，我们可以传递一个数组的首地址，作为函数的参数。这里“数组的首地址”，指的就是数组在内存空间中的第一个字节对应的地址。从地址值上讲，它就等于 `&array[0]`——我们之后再来谈它们在类型上的区别，目前读者这样理解就足够了。

以下是一个实现此功能的代码，可以接收 5 个浮点数输入，然后给出其中最大的数。读者可以先试着运行它，然后我将分别对语法和语义进行讲解。

```
template<typename T>
T maximum(T arr[], unsigned n) {
    T res {arr[0]}; // 先假设最大值为 arr[0]
    for (int i = 1; i < n; i++)
        if (arr[i] > res) // 如果 arr[i] > res, 说明有更大的数
            res = arr[i]; // 那么目前能找到的最大值就是 arr[i]
    return res; // res 就是返回值
}

int main() {
    double arr[5]; // 定义一个数组 arr 和 int 数据 sum, sum 初始化为 0
    for (int i = 0; i < 5; i++)
        cin >> arr[i];
    cout << maximum(arr, 5); // 传入 arr 数组，并告诉这个函数 arr 有多大
    return 0;
}
```

从语法上，我们可以看到，`maximum` 是一个函数模版，它可以接收一个 `arr` 数组和一个 `n` 无符号整数作为参数。你可能会好奇，为什么我们要把形参写成 `arr[]` 的形状呢？写成 `arr[5]` 不行吗？

可以，但没有意义。在数组参数传递的过程中，我们传递的不是数组本身，而是它的首地址——换句话说，传递的是一个指针。在编译器进行编译的时候，它会把 `T arr[]` 参数视同 `T *arr`，所以即便我们在 `arr[]` 中写了 5，也会被忽略，没有意义。

也正因为数组参数传递过程中只传递了指针，所以函数不能判断这个数组的大小，因此我们必须再加一个参数，来描述这个数组的大小。这就是 `n` 存在的意义。

再来看语义，`maximum` 函数中的这段代码是如何做到我们希望的功能的呢？其实就是用 `for` 循环读取 `arr` 中的每个数，然后逐一比较。如果发现了一个更大的数，那就说明最大值至少应该是这个数，所以 `ref=arr[i]` 赋值一下。如果之后又发现了一个更大的数，那就说明最大值至少应该是这个数，所以 `ref=arr[i]` 再赋值。这样一直找到最后，`res` 就是所有数的最大值了。读者若是还未明白，可以把自己想像成程序，以输入 `2,1,4,5,3` 为例，模拟一下这个过程。

有些时候，我们也不知道输入数据有多少个²⁶，那么怎么办呢？为了不出问题，我们可以设计一个尽可能大的数组（比如，大小为 1000 的数组 `arr`），然后让用户输入尽可能多的数据。如果用户输入了字母 `q` 或者类似的不合理内容，就结束输入循环。这个思路与 [代码 3.3](#) 的判断方式很相似。

我们还需要考虑一种情况，用户的输入可能超过 1000 个，这时如果不加防范，程序会继续将输入存到 `arr[1000], arr[1001]` 这些地方。这会造成野指针问题，不得不防范！所以我们还需要在循环时判断一下，数组下标是否越过了边界。

²⁶这种情况最常见于字符串的输入。

鉴于此，我们可以写一个输入函数。我们可以用 **for** 循环或者 **while** 循环，实现的方式也可以有细微不同，只要能以简单高效的方式达到我们的目的就好。以下是第一种写法：

```
double arr[1000]; //为了能接收任意数量的输入，预先设置一个比较大的数组
unsigned size = 0; //定义一个size变量，用来表示数组中目前的数据量
for (; size < 1000 && cin; size++) { //注意判断条件
    cin >> arr[size]; //输入到arr[size]中，然后size会自增
}
cout << maximum(arr, size); //现在是长度为size的arr数组，传入函数中
```

这里使用 **for** 循环，其中的判断条件是个逻辑与表达式。之所以用 `size<1000` 而不是 `size<=1000` 是因为，条件判断是在输入 `arr[size]` 之前进行的，而迭代是在输入之后进行的。如果某次 `size` 的值为 999，那么本次判断可能为 **true**，输入正常进行，输入了 `arr[999]` 之后，`size` 才迭代为 1000。而如果某次 `size` 的值为 1000 了，这时倘若用 `size<=1000` 来判断，那就会出现 `arr[1000]`，这就越界了！

我们还可以使用 **while** 语句来实现，思路大同小异。

我们也可以把这个输入功能做成函数，就叫 `input_arr`，它接收一个数组参数（其实是指针参数），再接收一个数组容量参数（这个数组最大的容量是多少）。考虑到用户的输入未必能达到最大值（“容量”与“实际储量”当然不一定相同），我们还需要知道这个数组实际装了多少数据。我们可以把这个数据作为 `input_arr` 的返回值。

这个思路比较清晰，我们可以直接写一个这样的函数出来：

```
template<typename T>
unsigned input_arr(T arr[], const unsigned max_size) {
    unsigned real_size {0}; //记录数组中数据的实际个数
    while (real_size < 1000) { //防止数组下标越界
        cin >> arr[real_size]; //输入arr[real_size]
        if (!cin) { //如果输入状态错误
            input_clear(); //先清理输入
            break; //再退出while循环
        }
        ++real_size; //然后real_size自增
    }
    return real_size;
}
```

这个函数略显复杂，注意事项也比较多，我们慢慢道来。

首先，它是一个函数模版，会根据我们的需要生成对应类型的函数实例。这里没什么可说的。

`max_size` 是数组最大容量。它只是一个副本，我们改动它也不会影响原变量，但是我依然建议使用 **const**，以避免在函数中误修改它的值。至于数组传递，它本身就是一种指针传递，所以我们直接在 `input_arr` 函数中修改 `arr` 数组的数据就行了，而不需要什么所谓“对数组的引用”。

在 **while** 语句中我们只判断 `real_size` 是否越界。而对于异常输入的情况，我们选择使用 `if(!cin)` 判断加 **break** 语句来退出循环。

语法正确还不够。你还需要考虑清楚 **while** 循环中各语句的执行顺序，以免出现语义错误。例如 `++real_size` 这一句，必须要在 `if(!cin)` 之后，这两句的顺序是不能调换的。这是因为，只有当 `cin` 正常的时候，`arr[real_size]` 才能得到有效输入，这时 `real_size` 才应该自增；否则，`arr[real_size]` 得不到有效输入，`real_size` 也不该自增，所以应当直接用 `if(!cin)` 中的 **break** 语句退出这个循环，避免执行 `++real_size`。

接下来我们可以使用这个函数，配合 `maximum` 来实现先输入，后求最大值的功能了。

```
int main() {
    int arr[1000];
    unsigned arr_size {input_arr(arr, 1000)};
    //向arr提供输入，并由arr_size接收返回值，记录当前arr数组中的有效数据个数
    cout << maximum(arr, arr_size);
}
```

如果我们发现用户实际输入的需求可能是几万个，而非几个到几百个，那我们就要考虑增加 `arr` 的容量。我们可以把定义句改为 `int arr[100000]`。

这就完了吗？不，还没有，我们还需要改 `input_arr(arr, 1000)` 这里的参数呐！把它也改成 `100000` 才行。

这就体现出单纯用字面量的缺点了，我们没法保证一次修改之后所有相关数据都改变，而人为操作的话，出现遗漏和失误的可能性又太大了。为了保持统一性，我们可以用常量或常量表达式，通过具名的方式把数组的容量描述出来。

```
constexpr int Maxsize {100000}; //用constexpr也可
int arr[Maxsize];
unsigned arr_size {input_arr(arr, Maxsize)}; //这样就好了
```

这样，如果我们要改 `Maxsize` 的值，只要修改一次，就可以把所有需要改的数据一并改完了，犯错的可能性大大降低。

关于输入和求最大值，我们还可以有一些更有技巧性的写法：

```
const int Maxsize {100000}; //用constexpr也可
int arr[Maxsize];
cout << maximum(arr, input_arr(arr, Maxsize)); //?
```

在这里，我们是把输入和求最大值并到同一步来写了。这句可能有点乱，但我们分析一下就会发现它很好懂。

首先，`maximum` 接收两个参数，一个是 `arr`，而另一个是 `input_arr(arr, Maxsize)`。这也就是说，我们需要把 `input_arr` 的返回值求出来，然后才能执行 `maximum` 函数。而在 `input_arr` 执行过程中，程序会先进行输入（这是 `input_arr` 函数的副作用），然后返回实际存储数据的个数。这个个数将作为参数被 `maximum` 函数使用。

下一步，`maximum` 知道了 `arr` 数组的位置和实际数据的个数，然后就会在对应的范围内求出最大的数。这时的 `arr` 也已经保存了用户输入的值（这是 `input_arr` 的副作用），所以整个程序就这样顺理成章地运行下去了。

代码 5.1: 输入数据求最大值.cpp

```
//这是一个输入若干数求最大值的程序，用户可以输入最多100000个数据，输入q结束输入
#include <iostream>
using namespace std;
//声明部分
void input_clear(istream& = {cin}); //在声明中就给出默认参数，注意类型是引用
template<typename T>
T maximum(T[], int); //T[]写成T*也没问题，不过习惯上还是写成数组形式
template<typename T> //注意：每次声明（定义）模板时必须写一个template
unsigned input_arr(T[], const unsigned);
//定义部分
```

```

int main() { //主函数
    const int Maxsize {1000000}; //用constexpr也可
    int arr[Maxsize];
    cout << maximum(arr, input_arr(arr, Maxsize));
    return 0;
}
void input_clear(istream &in) {
    in.clear();
    while (in.get() != '\n')
        continue;
}
template<typename T>
T maximum(T arr[], int n) {
    T res {arr[0]}; //先假设最大值为arr[0]
    for (int i = 1; i < n; i++)
        if (arr[i] > res) //如果arr[i]>res, 说明有更大的数
            res = arr[i]; //那么目前能找到的最大值就是arr[i]
    return res; //res就是返回值
}
template<typename T>
unsigned input_arr(T arr[], const unsigned max_size) {
    unsigned real_size {0}; //记录数组中数据的实际个数
    while (real_size < 1000) { //防止数组下标越界
        cin >> arr[real_size]; //输入arr[real_size]
        ++real_size; //然后real_size自增
        if (!cin) { //如果输入状态错误
            input_clear(); //先清理输入
            break; //再退出while循环
        }
    }
    return real_size;
}

```

这应该是本书迄今为止展示的最长代码了,但是关于它的每个部分,我都已经拆解过(除了 `input_clear`,这部分我们暂且不讲,读者知道怎么用即可)。当我们想要实现较复杂的功能时,长代码总是难以避免的。这也正是我们需要用函数来进行“模块化”的一个重要原因。

范围 `for` 循环

有的时候我们可能需要对一个数据的数据进行批量处理,这时我们一般用 `for` 循环来实现。好处也很明显, `for` 循环内部可以定义一个下标变量 `i` (或者用别的名字),终止条件可以通过比较运算来实现,而迭代操作刚好可以处理下标的变化。这样看来, `for` 循环仿佛是为数组处理量身打造的。

从 C++11 标准起,范围 `for` 循环 (Range-based for loop) 能让我们一次性读取 (或修改) 数组中所有数据的操作变得更简单。比如说,我们定义一个数组,然后输出它的所有数据,可以这样写:

```

int arr[] {1,2,3}; //定义一个长度为3的数组
for (int x : arr) //用范围for循环, 变量x接收arr中的数据
    cout << x << ' ';

```

这样一来，范围 `x` 就会循环接收 `arr` 中的每个数字，然后在循环体内进行操作。

如果我们要修改它的值呢？把 `x` 定义成 `int` 类型的变量是不行的，因为它相当于一个临时变量。因此我们需要使用引用来实现修改的功能。

```
int arr[] {1,2,3,4}; // 定义一个长度为4的数组
for (int &x : arr)
    x *= x; // 将x的值变为原数的平方
```

这个范围 `for` 循环看上去很好用，不过它也存在较多的限制：

- 范围 `for` 循环会对数组中的所有数据进行处理，我们无法人为改变它的处理范围。这也就意味着，如果某个数组中的数据不都是有效数据，那么这种方法可能会把无效数据一并处理。比如说，输出了不该输出的部分，或者是把不该平方的数据也给平方了。即便这样做不会带来任何危险，它也会在实际运行的过程中带来效率问题（因为我们把一些时间浪费在了不该处理的数据上）。
- 范围 `for` 循环不能处理那些“看上去是数组，但实际是指针”的东西。²⁷比如说，函数中接收的“数组参数”，其实它们全都是指针。那也就意味着，代码 5.1 中的 `maximum` 和 `input_arr` 都是无法使用范围 `for` 循环的。我们在后面接触动态内存分配时也会发现这个问题，动态数组不能使用范围 `for` 循环来处理数据。

数组的类型

那么数组和指针之间到底是什么关系呢？为什么数组就可以用范围 `for`，指针就不能？为什么数组名可以隐式类型转换成指针？

如果我们用 `is_same` 来比较一个数组类型和一个指针类型，就会发现它们确实是不相同的。

```
int arr3[3], int *p;
cout << is_same<decltype(arr3), decltype(p)>::value; // 输出为0
```

那么我们试试比较一下两个长度不同的数组类型呢？

```
int arr3[3], arr5[5];
cout << is_same<decltype(arr3), decltype(arr5)>::value; // 输出也为0
```

哎，看起来这两个类型也不相同。

没错，数组类型的区分比指针更细。对于指针来说，指向 `int` 的指针当然和指向 `long long` 的指针是不同类型，但是任何两个指向 `int` 的指针都是同类型的。

数组不然，不光数据类型不同的数组不是同类型，连长度不同的数组也不是同类型了。这里的 `arr3` 的真实类型应该是 `int[3]` 型，而 `arr5` 的真实类型应该是 `int[5]` 型。

可惜 `is_same` 在这里能告诉我们的信息还是太少了，我们只能知道“某两个类型具体是什么”，但还不清楚“某个类型意味着什么”。所以我们还有另一个工具，那就是 `typeid` 运算符。

`typeid` 有点像 `sizeof`，它既可以作用于类型，又可以作用于对象（变量）。`typeid` 的成员函数 `name()` 可以返回一个 `const char*` 对象（这是一个字符串，详见下一节）。我们输出它，就可以看到相关的类型信息了。以下是一个示例：

```
int arr3[3], arr5[5];
cout << typeid(arr3).name() << endl;
cout << typeid(arr5).name() << endl;
cout << typeid(int).name() << ' ' << typeid(double).name() << ' '
```

²⁷这是因为，指针相比于数组，缺少了“数组长度”这条信息，所以范围 `for` 循环根本不能确定数组的实际大小。详见后文。

```
<< typeid(unsigned).name() << ' ' << typeid(float).name() << endl
<< typeid(int*).name() << ' ' << typeid(char*).name();
```

需要提醒读者，`typeid(...).name()` 在不同编译环境下的结果可能不同²⁸，因此本例中的结果取 Coliru 上运行的结果。读者也可以在 Coliru 上自行运行这段代码试试效果。它的输出是

```
A3_i
A5_i
i d j f
Pi Pc
```

其中 `A3_i` 格式的内容表示一个长度为 3 的 `int` 型数组（Array），`A5_i` 表示一个长度为 5 的 `int` 型数组。

而接下来的 `i, d` 等分别是 `int, double` 等类型的名字。

最后输出的 `Pi` 和 `Pc` 分别是两个指针类型的名字，其实就是在原类型名字前面加上了 `P`，代表指针（Pointer）。




图 5.12: 数组到指针的类型转换

也就是说，数组比指针多出了一个“长度”信息。虽然我们一般看不出这个信息来，但是它确实存在。不信的话，你还可以用 `sizeof` 取数组的内存空间大小看一下，它是不是与数组长度挂钩。

```
int arr3[3], arr5[5];
cout << sizeof arr3 << endl << sizeof arr5;
```

而指针不是这样的。指针也是变量，它在内存空间中也有对应的存储位置²⁹。我们可以用 `sizeof` 计算一下。

那么来到数组参数传递这里——我们也可以用 `typeid` 取“数组形参”的类型，或者用 `sizeof` 来取它的内存空间大小，就会发现它的表征和指针是一样的：

```
void fun(int arr[]) {
    cout << typeid(arr).name() << ' ' << sizeof arr;
    // 输出 Pi 8, 说明 arr 是一个指针!
}
int main() {
    int arr[1000];
    fun(arr);
}
```

²⁸实际体验是，在 MSVC 开发环境中给出的结果最为清晰。

²⁹因此我们还可以取一个指针的地址，这是后话。

所以说数组参数传递看似是在传递数组，其实是在传递指针。而在传递的过程中，数组原本所含有的“长度”信息就丧失了，因此我们在传递数组的过程中，最好要另外加上一个参数，说明一下数组的长度，否则函数也不能确定数组的长度，就难免会发生下标越界问题。

5.5 字符串

现在我们来看一种特殊类型的一维数组：字符串。字符串也是一大类，不过它们的道理很相似，所以我们只研究其中一个部分：`char` 数组。

定义一个 `char` 数组的方法和定义一般的一维数组差不多：

```
char str1[5] = {'J', 'a', 'c', 'k', '\0'}; // 正常格式，注意末尾最好用 '\0'
char str2[10] {"A", "m", "y"}; // 省略部分内容，省略的部分使用默认值 ('\0')
char str3[] {65, 66, 67, '\0'}; // 除非末尾用 '\0'，否则不建议这么写！
```

唯一的例外是，我们可以用字符串字面量来初始化字符数组。

```
char str4[5] {"Jack"}; // 效果等同于上述 str1 的定义
```

这是一种语法糖³⁰，实际上编译器会把它解释成和 `str1` 相同的初始化方式。不过呢，这种针对于字符数组的语法糖让我们初始化内容变得更简单了。然而，这种语法糖仅在初始化时有效。到了赋值的时候，我们不能这样写：

```
str1 = "Bob"; // 错误！
```

要想改变字符串的内容，我们只能通过给每个元素赋值的方式来进行：

```
str1[0] = 'B';
str1[1] = 'o';
str1[2] = 'b';
str1[3] = 0; // 不要忘记！
```

但是这种逐个赋值的操作可能出问题，我们很容易漏掉 `str1[3]=0` 这句。所以我们推荐使用 `cstring` 库中的函数 `strcpy` 来实现。我们暂时先不讲这个，留到后面再说。

```
strcpy(str1, "Bob"); // 正确
```

字符串的使用和其它类型的数组很相似，但又有它的特点。所以我们在里先来介绍一下关于字符串的最基本概念。

字符串是什么？

我们最熟悉的字符串就是我们一直在使用，但是尚未讲解过的字符串字面量。很多时候我们都要输出字符串字面量。

```
cout << "HelloWorld!";
```

这里的 `"HelloWorld!"` 就是一个字符串字面量。

字符串字面量不同于基本数据类型的字面量，它是一个数组，我们可以像其它数组名那样去输出它的地址。但是当我们用 `cout` 输出一个字符串字面量的时候，它输出的并不是地址，而是这个字符串的内容啊！

³⁰ 语法糖（Syntactic sugar），是指某种编程语言中的某些语法，它们对语言本身的功能没有影响，但是更方便程序员使用。语法糖可以让程序更简洁，有更高的可读性。

类似的问题，我们在指针中也遇到过。当我们试图输出一个指针的时候，实际输出的可能是任何东西，但是怎么看都不像个地址值。这是因为，`<<` 对于 `ostream` 和 `const char*` 类型有特殊的重载。在遇到 `char*` 及其变体的类型时，会把它按照字符串的方式来输出，而不是输出它的地址。

为了看到它的地址，我们可以通过显式类型转换，把 `char*` 类型转换成 `void*` 类型然后输出，这样就能看到地址值了。

```
cout << (void*)"HelloWorld!"; // 输出 0x4006a4
```

字符串字面量存储在数据段（Data section），这里的内容都是常量，所以字符串是一个常量 `char` 数组。我们可以用 `typeid` 检验。³¹

```
cout << typeid("HelloWorld!").name(); // 输出 A13_c
```

或者是用 `is_same` 检验。但是这里出现了新问题，我们直接写成下面这样是行不通的：

```
cout << is_same<decltype("HelloWorld!"), const char[13]>::value;
// 输出 0, 怎么回事?
```

具体的情况比较复杂，这涉及到 `decltype` 的问题³²，读者不必深究。我们只需改成这样就好：

```
cout << is_same<decltype("HelloWorld!"), const char(&)[13]>::value;
// 输出 1
```

那么既然字符串字面量是一个字符数组，我们岂不是可以用下标运算符来访问它的某一个元素？

```
cout << "HelloWorld!"[0]; // 将输出 H
```

字符串是如何构成的？

细心的读者可能会发现另一个问题：这个 `"HelloWorld!"` 带空格和标点也只有 12 个字符，为什么它的长度是 13？这就不得不提到字符串的构成了。

在 C/C++ 中，所有的字符串都应当以 `'\0'`，也就是 ASCII 码值为 0 的字符结尾。这是我们判断一个字符串有效信息长度的最佳标准。为什么这么说呢？

当我们定义字符串时，因为我们也不确定它的有效信息有多长，所以我们可能要给它比较大的容量。

```
char name[32]; // 难免会有名字很长的人，所以容量要大一点
```

但是这里就会存在一个问题：绝大部分情况下，这个字符串真实存储的信息长度肯定很少，比如说“Amy Smith”，这个名字只有 9 个字符，那么我们就还需要一个类似于 `size` 的变量，来说明 `name` 的有效信息长度。问题在于，这个方法比较浪费空间，我们还需要另外定义变量来存储它的长度；而且也很不方便使用，我们每次传参都要额外加一个变量。

C/C++ 有更好的解决方法，那就是用 `name` 数组内的信息来表示有效长度！具体的方法是，我们在有效信息的末尾，把下一个字符设置成 `'\0'`。这样，无论哪个函数拿到了这个字符串，它只需要从 `name[0]` 开始数一数，看数到哪里 `name[i] == '\0'`，那么自然就知道了这个字符串的长度，而不需要用另外的参数来记录了。

举个例子，现在我记录一个名字 `"Alexander Alexandrovich Stepanov"`。这个名字碰巧有 31 个字符（含空格），加上末尾的结束符共有 32 个。现在我们把它存入 `name` 中。

```
char name[32] {"Alexander Alexandrovich Stepanov"};
```

这时它的 32 个字节全部都是有效信息，如图 5.13 第一行所示。

那么接下来我通过 `strcpy` 把另一个名字复制到 `name` 中，这样做会修改原来字符串的信息。

³¹MSVC 中能看出它是 `char const [13]` 类型，但 GCC 中只有 `A13_c`，看不出常量性，只能知道它是一个 `char` 数组。`is_same` 的检测相对更细致，不过它也有它的问题，见下文。

³²按标准，`decltype("HelloWorld!")` 返回的类型是一个对 `const char[13]` 的左值引用类型。

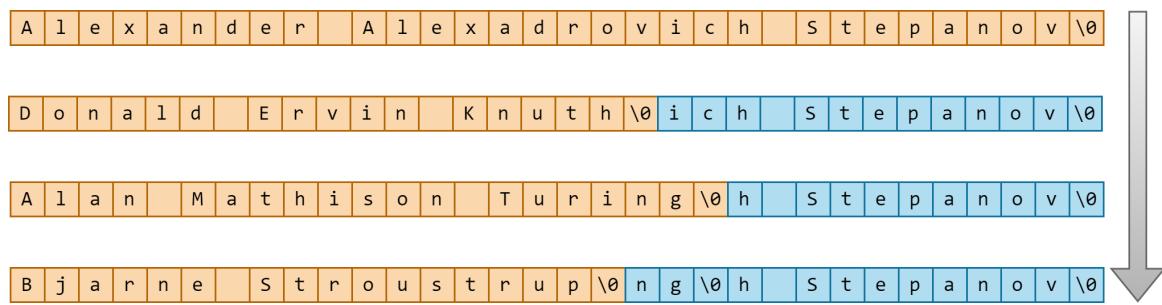


图 5.13: 字符串 name 中信息的变化情况

```
strcpy(name, "Donald\u00d7Ervin\u00d7Knuth");
//strcpy 会把第二个参数中的有效部分复制到第一个参数起的内存空间中
```

现在 name 的内存空间应该如同图 5.13 第二行所示。注意，只有第一个 '\0' 及以前的部分是有效信息（橙色），而后面的部分不是有效信息（蓝色），我们也没有浪费时间去修改它的必要，让它们维持原状就好。

接下来我再次通过 strcpy 把另一个名字复制到 name 中。

```
strcpy(name, "Alan\u00d7Mathison\u00d7Turing");
//strcpy 会把第二个参数中的有效部分复制到第一个参数起的内存空间中
```

现在 name 的内存空间应该如同图 5.13 第三行所示。下一步我再修改 name 的值，就应该得到图 5.14 第四行的情况了。

```
strcpy(name, "Bjarne\u00d7Stroustrup");
```

这就是字符串的基本结构。如果简单点说就是，字符串总是要有一个 '\0' 结束符。那么如果我们要输入一个长度为 n 的字符串，考虑到末尾结束符的存在，我们就至少需要容量有 n+1 的字符串才行。

了解了这些之后，我们就可以自己写一些简单的字符串处理函数了。

字符串的处理

知道了字符串的结构之后，我们就可以写一些简单的函数来进行字符串的处理了。

cstring 库中有一些常见的字符串处理函数——有些我们也可以写，比如 strlen。这个函数可以计算一个字符串有效信息的长度（不包含结束符）。比如说，`sizeof("Amy")` 得到 4，这是它占用内存的大小；而 `strlen("Amy")` 得到 3 这是它外表展现出来的长度。

为了避免名字冲突，我们就写一个 StrLen 函数，它可以接收 `char` 指针³³，并返回一个无符号的整数，作为长度。

来考虑一下这个函数的外在特征。我们只需提供这个字符串就可以了，无需更多信息。不过我们只想求值，不需要改变它，所以干脆设成指向常量的指针，稳妥一些。至于返回值，`strlen` 内部使用的是 `size_t` 类型作为返回值，其实我们用 `unsigned` 或者 `unsigned long long` 也行。

```
unsigned StrLen(const char*); // 声明完毕
```

接下来考虑怎么求出它的长度。其实很简单，我们从 str 指向的第一个字符开始找，直到找到 '\0' 为止，走过了多少个字符，就说明它的长度是多少啦。所以我们可以用一个循环结构来实现这个功能。

³³一般来说，我们在涉及其它类型的数组参数时会使用数组形式的形参，以便告诉用户它接收的是数组（虽然实际情况还是转换成指针了）信息；而在涉及字符串时，我们更习惯于把参数设为指针类型。

```
unsigned StrLen(const char* str) {
    for (unsigned i = 0; ; i++) { // 条件留空将默认为 true
        if (str[i] == '\0') // 如果 str[i]==0, 说明字符串结束了
            return i; // 直接返回 i 的值
    }
}
```

写完了之后一定不要得意忘形，马上在主函数中写一个例子验证一下，看看是否合乎我们的预期。比如 `StrLen("Amy")`，它的值就应该是 3，我们可以输出一下看看对不对。

接下来我们再写一个稍难的函数。`strcpy` 函数可以把一串内容复制到另一个字符串中，效果等同于“字符串间的赋值”，这样可以免于让我们用逐个字符赋值的麻烦方法来改变整个字符串的值。它接收两个参数，第一个参数 `dest` 是目标字符串，第二个参数 `src` 是内容源。这个函数不需要考虑 `dest` 的容量是否足够，只管往里复制就行³⁴。

换句话说，我们只需要把 `src` 串中的有效部分逐个赋值给 `dest` 的对应部分就行。比如说，`dest[0]=src[0]`，然后 `dest[1]=src[1]`，诸如此类。终止条件是 `src[i]=='\0'`，这时我们就可以停止了。但是最后不要忘了人为地在后面补上一个 '`\0`' 结束符，否则这个字符串就没有结束。

所以我们就来模仿赋值语句的方式来写一个 `StrCpy` 函数。它的第一个参数是 `char*` 类型的，第二个参数是 `const char*` 类型的（因为不需要修改，那么就从定义层面防止修改），而返回值是 `char*` 类型的，它的值（地址）应该等于第一个参数的值（地址），这是为了实现类似于赋值运算符的那种连续赋值语法（`StrCpy(str1,StrCpy(str2,str))`）。

```
char* StrCpy(char*, const char*);
```

定义部分看上去好像很难，但我们分析了一通之后会发现，那也只不过是一种逐个赋值的语法而已，所以用 `for` 循环简单写一写就足够了。

```
char* StrCpy(char *dest, const char *src) {
    for (unsigned i = 0; (dest[i] = src[i]) != '\0'; i++) { ; } // 还能这样？
    return dest; // 返回 dest 的值
}

int main() { // 主函数
    char str[10] {"AbCdEfG"}; // 定义 str，并预先用其它内容占据
    cout << StrCpy(str, "Bob"); // 如果输出 Bob，说明代码正确
    return 0;
}
```

读者可以运行一下这段代码。如果不出意外的话，结果会输出 `Bob`。

这里的 `StrCpy` 的逻辑写得比较有技巧性，我们来拆解一下。在 `for` 循环中，我们先初始化了 `i=0`，这是循环的起始条件。接下来，我们进行判断。判断语句 `(dest[i]==src[i])!='\0'` 将会先执行 `dest[i]=src[i]` 这个赋值，其返回值 `dest[i]` 会与 '`\0`' 比较。如果不相等，那就说明没有遇到结束符，循环继续。主体部分只有一个分号（甚至可以什么也没有），它表示什么也不做。既然什么也不做，那就直接运行迭代语句 `i++`，进入下一轮循环判断就好。如此，我们也可以省了单独为 `dest` 数组添加一个结束符的麻烦——因为在判断它是不是 '`\0`' 之前，我们就已经做了赋值操作了。

字符串的输入

现在我们再来讲讲字符串是如何输入的。

最简单的输入方式莫过于用 `cin<<` 来进行输入。

³⁴实际上，它也没办法顾及 `dest` 的容量够不够，因为字符串作为数组类型，在传递参数时就会变成指针类型，在此过程中它的长度信息就已经丧失了，除非我们人为地把长度信息也传入其中。

```
char str[32];
cin >> str; //直接用cin向字符串中输入
```

但是这样就可能会遇到问题。如果我们要向字符串中输入两个英文名，比如 Bjarne Stroustrup 和 Alan Mathison Turing，我们可能就会遭遇这样的困难：

```
char name1[32], name2[32]; //定义两个字符串用于输入人名
cin >> name1 >> name2; //连续输入两个人名
cout << name1 << endl << name2; //输出第一个人名，再换行，再输出第二个人名
```

如果我们真的运行一下，就会发现情况好像不太对劲。

Bjarne Stroustrup

(刚按下回车键，准备输入第二个人名，结果程序就开始输出了)

Bjarne

Stroustrup

这是怎么回事？

这是因为，用 `cin <<` 输入字符串时，它断句的方式是在每个空白字符³⁵处断开。所以在输入 `name1` 时，它只会读取到空格之前的内容，而把 Stroustrup 这个输出留给下一个输入，即 `name2`。这也就解释了为什么当我们按下回车键的时候它就开始输出了，这是因为程序已经把两个字符串读完，接下来当然就是执行输出了。同时这也是输出 `name1` 时得到 Bjarne 而输出 `name2` 时得到 Stroustrup 的原因。

怎么解决呢？我们可以用 `cin` 的成员函数 `get` 或者是 `istream` 类的成员函数 `getline` 来解决。先来讲讲 `getline`。

getline 成员函数

`getline` 成员函数的定义语法有如下两种，它们是重载关系：

```
istream& getline(char_type *s, streamsize count); //重载1
istream& getline(char_type *s, streamsize count, char_type delim); //重载2
```

其中的 `s` 是待输入的字符串，而 `count` 表明这个字符串的容量（不同于 `strcpy`，这里必须提供容量参数）。对于第一个重载来说，它的含义就是：读取一整行输入，直到遇到回车符³⁶，才停止输入；或者是 `count` 长度的字符串容纳不了用户输入的内容量，这时输入也会停止，同时 `cin` 会进入“fail”状态（我们需要用 `input_clear` 来恢复 `cin`，并清理输入流）。

接下来我们可以用 `getline` 来输入一些有空格的名字了。程序不会在空格字符处断句，只会在回车字符处断句。

```
constexpr unsigned NameLen{ 32 }; //把名称字符串容量设为32，便于统一
char name1[NameLen], name2[NameLen]; //定义两个字符串用于输入人名
cin.getline(name1, NameLen).getline(name2, NameLen); //getline可以连续使用
cout << name1 << endl << name2; //输出第一个人名，再换行，再输出第二个人名
```

本程序的运行结果是

Bjarne Stroustrup

³⁵ 空白字符 (Whitespace character)，在 ASCII 字符区内包括 '\t', '\n', '\v', '\f', '\r', '\u'。如果要判断某个字符是否是空白字符，可以用 `cctype` 库中的 `isspace` 函数来处理，如 `isspace('a')`，返回值是 0。

³⁶ 回车符会被提取，但不会存入 `s` 字符串中。

Alan Mathison Turing

Bjarne Stroustrup

Alan Mathison Turing

这就合乎我们的预期了。

至于第二种重载，无非就是把分隔符从换行符换成了自定义的字符而已，没什么特别的，这里就不再赘述。

get 成员函数

istream 类的 get 成员函数的功能比 getline 更丰富。以下是 get 函数的一部分重载：

```
int_type get(); // (1)
istream& get(char_type &ch); // (2)
istream& get(char_type *s, streamsize count); // (3)
istream& get(char_type *s, streamsize count, char_type delim); // (4)
```

重载 (1) 和 (2) 的作用都是读取输入流中的单个字符。我们在 input_clear 中就用过 (1)。

```
void input_clear(istream &in) { // 默认参数 cin, 已在定义中注明
    in.clear();
    while (in.get() != '\n') // get() 的作用读取下一个字符
        continue;
}
```

get() 的返回值是读取的字符所对应的 ASCII 值，我们可以拿它与 '\n' 作比较。如果不相等，就说明还没有读取到回车符，循环继续；一旦读取到回车符，while 循环即终止，函数结束。

重载 (3) 和 (4) 与 getline 十分相似，但它们有着细微的区别，在于如何处理结束符。getline 会把结束符一并提取（形象点说，吞掉）；而 get 不会把结束符一并提取，结束符仍然保留在输入流中，下一个输入还会从这个字符开始。所以这样写就不行：

```
cin.get(name1, NameLen).get(name2, NameLen); // name1 正常，但 name2 为空
```

这是因为，name1 输入完成后，get 函数遇到回车符但没有吞掉它，回车符仍在输入流中，于是输入 name2 的时候，程序第一眼看到 '\n' 就把输入给结束了，name2 当然就会什么也没有了。

为了把输入流中的回车符吞掉，我们可以这样写：

```
cin.get(name1, NameLen).get(name2[0]).get(name2, NameLen);
// 先用 name2[0] 吞一下回车符，再输入 name2，没影响
```

或者干脆点，直接用 getline 就好。

5.6 指针与数组的复合类型

在前面的几节中我们可以看到，指针和数组之间有着千丝万缕的联系，它们虽然类型不同，但都与内存地址密不可分。数组类型还可以转换成指针类型，这种情况在参数传递中普遍存在。

本节我们来研究一些更复杂的结构：二维数组、指针数组、指向数组的指针和指向指针的指针（二阶指针）。它们的分析方法和我们分析一维数组和一级指针的方式大体相同，不过在这里我们要更多地关注类型信息。

二维数组

定义二维数组的基本语法如下：

```
int darr1[2][3] = {{1,2,3},{4,5,6}}; //正常格式，注意是外层2个，内层3个，勿搞反
int darr2[3][3] {{7,8},{10}}; //每个花括号内可分别省略内容，省略的部分初始化为0
int darr3[] [4] {{1,2,3,4},{5,6},{}}; //只能省略第一维长度，不能省略第二维长度
```

初学者很容易在二维数组的下标问题上犯糊涂。比如在定义 `darr1` 的时候，究竟是写成 `{{1,2,3},{4,5,6}}` 还是写成 `{{1,2},{3,4},{5,6}}`？还有，`int[2][3]` 和 `int[3][2]` 到底有什么区别？为什么在定义 `darr3` 的时候只能省略第一维的长度而不能省略第二维的长度？

要解决这些问题，我们就要去探寻二维数组的本质。

二维数组是什么？

我们已经对一维数组十分熟悉了。在我们已有的理解中，一维数组是内存中连续的一串数据，每个元素的类型都是基本数据类型。比如说 `int arr[3]`，它就是一个一维数组，类型为 `int[3]`；而它的某个元素，比如 `arr[0]`，就是一个数据，类型为 `int`。我们可以把它叫做“由数据构成的数组”。

那么我能否定义一个“由数组构成的数组”呢？假设我们想定义一个由 4 个 `arr[3]` 数组构成的数组，那么我们岂不是应该定义成 `int (darr[3])[4]`？

这就错了——其实这也是初学者常常会出现的理解误区。为了便于我们清晰地理解指针/数组复合类型的定义，请读者记住一条重要原则：“**定义的语法**要与**使用的语法**保持一致。

以刚才说到的二维数组为例。我们希望定义一个长度为 4 的二维数组 `darr`，这个数组的每个元素都是一个长度为 3 的数组。那么在我们使用的时候，`darr[0]` 就是一个长度为 3 的数组吧！同样的，`darr[1]`, `darr[2]` 和 `darr[3]` 都是一个长度为 3 的数组。

那么，如果我们还要再读取更内层的信息（这次就是数据了），我们就需要把 `darr[i]` 当作一个整体，再用一次下标运算符，也就是 `(darr[i])[0]`, `(darr[i])[1]` 和 `darr[i][2]`（可以省略括号，不影响结果）。

那么回顾一下 `darr[i][j]` 这个语法，其中 `i` 的合理范围是 0~3，而 `j` 的合理范围是 0~2，所以该定义成什么样，就一目了然了吧？

```
int darr[4][3]; //从darr到darr[4]，再到darr[4][3]
```

接下来我们可以用 `typeid` 或者 `is_same` 来检验它的类型。在 Coliru 中，我们可以运行以下代码：

```
int darr[4][3]; //从darr到darr[4]，再到darr[4][3]
cout << typeid(darr).name() << endl; //输出darr的类型
cout << typeid(darr[3]).name() << endl; //输出darr[3]的类型
cout << typeid(darr[3][2]).name(); //输出darr[3][2]的类型
```

这段代码的运行结果是

```
A4_A3_i
A3_i
i
```

我们从 `typeid` 的结果中也可以看出，`darr` 的输出 `A4_A3_i` 说明它是一个由“`int` 数据构成的 3 长度数组”构成的 4 长度数组。这个话有点绕，读者多琢磨一下，想必就能搞通啦。

所以为什么我们在定义二维数组时只能省略第一维的长度而不能省略第二维的长度呢？这点想必也是一目了然的，因为一个 `int[4][3]` 二维数组本质上是一个由 `int[3]` 一维数组构成的数组！

所以我们在定义数组类型的时候，必须把类型 `int`[3] 告诉编译器，否则编译器就不知道这个数组的类型了。但 4 作为这个数组的长度，是可以省略的。

```
int darr4[3][3]={{} ,{} ,{} ,{} } ; // 四个括号说明它由4个数组构成，所以4可以省略
```

二维数组在内存中是什么样的？

我们说过，一维数组就是在内存中连续存储的一些数据。既然二维数组本质上就是一维数组构成的一维数组，那么我们也不难想见，二维数组也是内存中连续的一段，如图 5.14 所示。

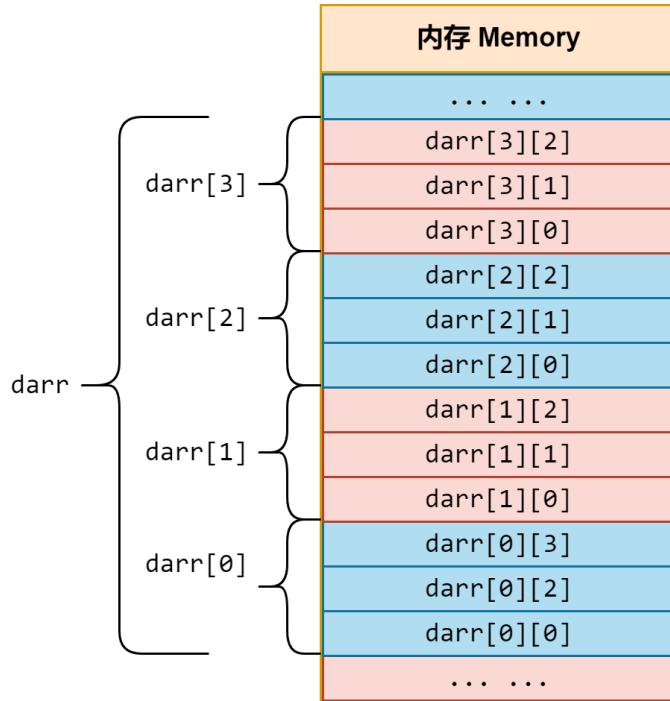


图 5.14: 二维数组在内存中的布局
本图的每个蓝/粉色框代表一个数据，而非一个字节

一些资料会在讲解二维数组时把它画成矩阵的形状，这可能会给读者造成一种误解，即二维数组在内存中是以行列的方式排布的。这是一种偏见。实际情况是，数据在内存中的排布是线性的，比如 `darr[0][3]` 的下一位是 `darr[1][0]`，而不是 `darr[1][3]` 或者别的什么。

敏锐的读者可能会想，既然 `darr[0][3]` 的下一位就是 `darr[1][0]`，那么我们能否通过 `darr[0][4]` 这样的语法来访问 `darr[1][0]` 呢？这当然是可以的；但是如果我们只用 `darr[0][i]` 来访问数组数据的话，为什么我们要定义成二维数组呢？直接用一维的不是更方便吗？

二维数组的常见应用

既然二维数组数据在内存中的排布方式与一维数组一样，那么我们之所以会使用二维数组，肯定是因为二维数组在语法上有过人之处。这里我就来介绍一下它的几个常见应用：

- 矩阵。设想我们需要存储一个 5×5 大小的矩阵。如果用一维数组的话，我们需要用一个大小为 25 的矩阵；在表示“第 n 行，第 m 列”数据的时候，我们需要写成 `arr[(n-1)*5+(m-n)]`（别忘记数组下标从 0 开始）。但是我们可以用一个大小为 5×5 的二维数组直接存储；表示时直接用 `darr[n-1][m-1]` 就行了。这样就很方便吧！
- 多个字符串。字符串本身就是一个 `char[N]` 类型的数组。那么当我们需要批量处理字符串时，当然就要用“数组的数组”啦！

- 数据统计。有些时候我们需要记录两组数据并作统计分析，例如对“售价”-“利润”数据进行存储。我们当然可以使用两个一维数组来实现这个功能，但是用一个二维数组会在传参时更方便一点！我们可以直接传递一个二维数组，而不是传递两个一维数组。³⁷

这里提及到了二维数组参数传递的问题，我们留到待会儿讲指向数组的指针时再讲解。

指针数组

二维数组的表象看上去好像很复杂，其实经过解析之后我们就会发现，那只不过是一种“以数组作为构成元素”的一维数组罢了。指针数组也是这个道理，它是一种“以指针作为构成元素”的一维数组！

指针也是一种数据类型，它一经定义，就在内存中有自己的一席之地。假如说有一个场合，需要我们批量定义指针，那么**指针数组（Array of pointers）**就派上用场了。

定义指针数组的基本语法如下：

```
const char *ap1[3] = {"Alice", "Bob", nullptr}; // 正常格式
int *ap2[10] {}; // 省略的部分将初始化为nullptr
float *ap3[] {nullptr, nullptr, nullptr}; // 可以省略指针数组的长度
```

初学者很容易把指针数组的定义语法与下文要讲的指向数组的指针搞混，我们在这里还是按照刚才说的原则来解释：“定义的语法”要与“使用的语法”保持一致。

指针数组是什么？

这里要提问读者：`*ap1[0]` 是什么？根据 C++ 运算符优先级的知识，我们知道 `[]` 的优先级高于 `*`，所以它应该被理解为 `*(ap1[0])`。那么 `ap1[0]` 是什么？按照我们的理解，它应该是指针数组的第一个元素——一个指针。那么 `*ap1[0]` 就相当于再对这个指针取内容。而 `ap1[0]` 指向的是字符串面量 `"Alice"`，那么我们不难想见，`*ap1[0]`，或者等效于 `(ap1[0])[0]`，就是字符 `'A'`。

我们同样可以用 `typeid` 来检验它们的类型。

```
cout << typeid(ap1).name() << endl; // 输出 ap1 的类型
cout << typeid(ap1[0]).name() << endl; // 输出 ap1[0] 的类型
cout << typeid(*ap1[0]).name() << endl; // 输出 *ap1[0] 的类型
```

这段代码的运行结果是

```
A3_PKc
PKc
C
```

其中的 `PKc` 意为“指向常量 `char` 的指针”，总之是一个指针就对了；而 `A3_PKc` 当然就是一个指针数组³⁸。

指针数组在内存中是什么样的？

指针数组在内存中的结构非常简单，它就是一个普通的一维数组而已，只是元素类型换成了指针。指针类型的数据在内存中也有其存储空间，我们之后就会来研究相关问题。

³⁷需要注意一点，用二维数组的前提是这个二维数组中的所有数据都是同一类型。如果涉及到“名字”-“性别”-“年龄”这样不同数据类型同时存在的情况，我们就需要用结构体，详见第六章。

³⁸其实我们可以分得更细，它是一个“指向常量的指针数组”（`Array of pointer to constant`），不过初学阶段的读者就不必深究了。

指针数组的常见应用

我们在前面已经看到了指针数组的一个常见应用，那就是存储字符串字面量。我们此前已经提过，字符串字面量不同于其它类型的字面量，它是有地址的！既然它有自己的地址，那么我们没必要用一个二维数组去存储（既浪费存储空间，又浪费存储所用的时间），直接用一堆 `const char*` 来指向这些内容就行，什么时候需要就拿出来用。当然这样做的前提是不需要修改这些字符串字面量的值。如果修改这些值，就可能发生未知错误（这也就是我们使用 `const` 的原因）。

指针数组还可以用于动态内存管理。在涉及动态内存分配时，我们可以把一个二级指针通过动态内存分配变为指针数组，然后对其中的每个指针再进行动态内存分配，诸如此类。我们等到下一节再谈此话题。

在传递参数时，我们也可能用到指针数组。这和我们用数组类传递参数有着异曲同工之处——如果参数太多，那么用一个数组来传参就要经济得多；如果要传递的指针太多，那么用一个指针数组来存储这些指针，把它作为实参传递给函数，也要经济得多。我们留到待会儿讲二阶指针的时候再讲解。

指向数组的指针

指向数组的指针 (**Pointer to array**, 简称**数组指针**)，对初学者来说更是一个难题。很多初学者搞不清楚什么是指向数组的指针，什么是指针数组，并且经常在定义的时候搞混。这里我们不仅要讲清楚指向数组的指针是什么，还要理清它和指针数组之间是什么关系。

定义一个指向数组的指针的基本语法如下：

```
int (*pta1)[5] = {nullptr}; // 正常格式，等号可省略
double arr[3] {};
double (*pta2)[3] {&arr}; // 3不可省略，并且需要和arr的长度保持一致！
```

不要小看定义语句中的 `()`，它是指向数组的指针区别于指针数组的关键。

指向数组的指针是什么？

顾名思义，这个指针是指向数组的。我们之前遇到的那些指针，它们都是指向数据的。现在我们遇到了指向数组的指针，不用怕，我们把数组也当成一种数据类型就好。（还记得吗，如果我们把一维数组当成一个数据类型的话，二维数组其实就是“一维数组构成的一维数组”）

如图 5.15 所示，现在有一个二维数组 `int darr[4][3]`。它的每个元素都是一个长度为 3 的 `int` 数组 (`int[3]`)，那么我们可以定义一个指向 `darr[0]` 的指针，如下所示：

```
int (*pta)[3] {darr[0]+0};
```

在这里我们要解决两个问题。第一，怎么理解它的定义语法？第二，二维数组和指向数组的指针究竟有什么关系？为什么我们可以用 `pta` 指向 `darr[0]+0`？

首先，让我们来考虑一下使用的语法。`(*pta)[0]` 是什么？这里 `(*pta)` 套了括号，所以应该先算它。鉴于 `pta` 是一个指向数组的指针，那么 `(*pta)` 就是一个数组了。所以 `(*pta)[0]` 就是这个数组的第一个元素，就这么简单。现在读者可以再回看一下指针数组的定义，并比较它们“使用的语法”，大概就可以分清它们的定义语法了吧！

然后再来看看二维数组和指向数组的指针间的关系。我们之前说过，`T` 类型数据构成的数组 `T[N]` 也可隐式转换成指向 `T` 类型的指针，即 `T*`。对于二维数组也是如此！既然一个二维数组就是一维数组构成的一维数组，那么它就可以转换成指向一维数组的指针！

那么读者也可以猜一下，`pta+1` 会指向什么呢？既然指针的加减法讲究的是数据的偏移量而非地址的偏移量，那么我们就应该想到，`pta+1` 应该指向下一个数组，也就是 `darr[1]`。同理，`pta+2` 应该指向下一个数组，即 `darr[2]`，以此类推。图 5.15 给出了这种关系，读者可以作为参考。




图 5.15: 指向数组的指针 pta 指向了数组 darr[0]

指向数组的指针在内存中是什么样的？

指向数组的指针只是一个指针。如果你用 `sizeof` 取它的内存占用，会发现它的大小和指向 `int` 的指针相等。实际上，无论指针指向什么，它永远都只是负责存储那个事物的地址而已，所以寥寥几个字节的空间足够！

这也就是我们喜欢用指针或引用³⁹传递参数的原因——无论要传递的信息有多大，一个指针那么大的数据就可以说明一切了！

指向数组的指针的常见应用

要说数组指针最常见的应用，那当属二维数组参数传递了。

我们说过，所有的数组参数传递在本质上都是指针传递。对于二维数组也是这样。所有的二维数组在进行参数传递时都会被隐式类型转换成指向一维数组的指针，然后传递参数。

```
double MatrixSum(double matrix[][n], int rows);
```

这个函数就可以用来求一个矩阵中所有数字的和。

一个数组也有它的内存地址。比如说有一个一维数组 `arr`，我们可以输出它的地址，也可以直接把它当作指针来输出。

```
int arr[3];
cout << arr; //arr会转换成int*型然后输出
cout << &arr; //直接输出一个int(*)[3]，这就是指向数组的指针类型
```

它的输出将会是这样的：

0x7ffd12a60744

³⁹C++ 中的引用是通过指针实现的，只是它在代码上隐藏起来了。我们进行引用传递的过程其实都是在进行指针传递。所以你可以认为引用是一种语法糖。

0x7ffd12a60744

读者可能会感到奇怪：这两个地址一样啊！

没错，这两个地址的值是一样的，但它们的类型完全不同。对于 `arr` 来说，它是 `int[3]` 类型，而在输出的时候会转换成 `*` 类型。而对数组取地址将会得到 `int(*)[3]`，这是一个“指向 3 长度 `int` 数组的指针”类型。我们可以用 `typeid` 或者 `is_same` 来验证它。

```
cout << is_same<decltype(arr), int[3]>::value << endl; // 输出 1
cout << is_same<decltype(&arr), int(*)[3]>::value << endl; // 输出 1
```

还记得我曾经说过吗？对于一个需要用多个字节来存储的类型来说，它的地址就是存储区域中第一个字节的地址。`arr` 的第一个字节也正是 `arr[0]` 的第一个字节，地址为 `0x7ffd12a60744`，所以自然会输出相同的值，读者不必感到奇怪。如果输出了不一样的值，我们才要感到不对劲呢。

那么我们是不是还能想到一种输出字符串字面量地址的新思路？

```
cout << &"HelloWorld!"; // 将输出地址值
```

这里的 `&"HelloWorld!"` 也是一个指向数组的指针类型，具体地说，是 `const char(*)[13]`。

```
cout << is_same<decltype(&"HelloWorld!"), const char(*)[13]>::value;
// 输出为 1
```

二阶指针

我们在前文中说过，一个指针也有它的内存地址。那么我们可以通过取地址运算符来取出它的地址吧。

```
int num {3};
int *p {&num};
cout << &p << endl << &num;
```

这个程序的运行结果是

0x7ffd7e034998
0x7ffd7e034994

不同于我们在前面看到的例子，这里的 `&p` 和 `&num` 是不同的。

它们当然不同啦，又不是同一个数据，也没有包含关系，当然应该存储在不同的单元中。

那么我们能否用另一个指针来指向 `p` 呢？这是可以的。我们可以定义一个二阶指针，或者说，指向指针的指针，来实现这个功能。

定义一个二阶指针的基本语法如下：

```
int **pp1 = {&p}; // 正常格式，等号可省略
char **pp2 {}; // 省略将默认初始化为 nullptr
```

这个语句的定义就很容易理解了，不会涉及什么误解。

二阶指针是什么？

初学者容易在自己尝试的时候写出 `&&num` 这样的语法，试图一步到位，得到一个二阶指针。这样写是错误的，而且也是没有意义的。这是因为，二阶指针描述的是一个指针的地址。但是 `&num` 只是一个临时的返回值⁴⁰，不是内存中我们可以获取到的实体，所以对它取地址是没有意义的！

⁴⁰更确切地说，右值。我们会在精讲篇中探讨这个问题。

但是我们可以对二阶指针两次取内容，这是因为，只要它是一个地址，它就可以取内容。二阶指针存储了某个一阶指针的地址值，而一阶指针又存储了某个数据的地址值，所以我们可以对二阶指针连续取地址。

```
cout << typeid(pp1).name() << endl;
cout << typeid(*pp1).name() << endl;
cout << typeid(**pp1).name() << endl;
```

这段代码的运行结果是

```
PPi
Pi
i
```

很好理解，我就不多说了。

二阶指针在内存中是什么样的？

同上文，它是一个单独的变量，在内存中有它自己的一席之地。我们甚至还可以取二阶指针的地址，并把它存入三阶指针当中！

```
int ***ppp {&pp1}; //这是一个三阶指针，存储了一个二阶指针的地址
```

还有更高阶的指针，不过我们在这里就不多说了。

二阶指针的常见应用

我们知道，一个二维数组可以隐式转换成指向数组的指针。而一个指针数组也可以转换成一个二阶指针。其实这点也符合我们的规律，因为它是一个“由指针构成的数组”向“指向指针的指针”的转换。所以如果我们要向某函数传递一个指针数组，我们就需要用二级指针形参来接收了。

这四种类型的转换关系可以用图 5.16 来描述。注意，二维数组是不能直接转换成二级指针类型的，数组指针也是不能直接转换成指向数组的指针类型的。这方面更详细的讨论，我们放在精讲篇。

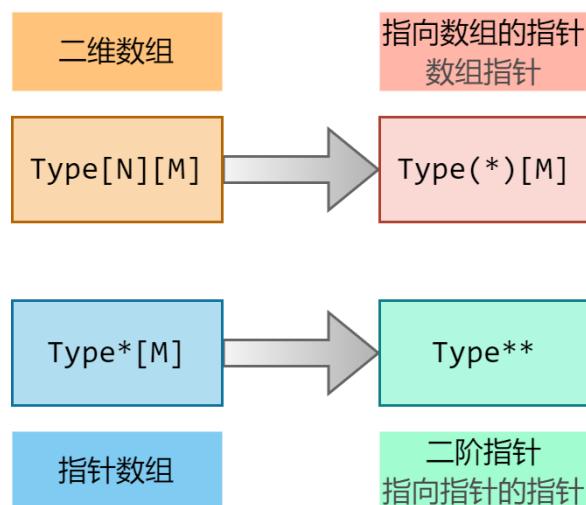


图 5.16: 四种指针/数组复合类型的类型转换关系

5.7 动态内存分配

在本章前几节的例子中，我们每次使用一个数组时，都会把它定义成一个长度为常数的类型。但在实际使用的时候，我们可能不知道用户需要多大规模的数组。如果预先定义一个十分大的数组，就免不了会浪费大量的内存空间，这在实际使用时是很不经济的。

我们能否定义一个“在运行时确定长度”的数组呢？早期的编译器不允许这种语法，不过许多较现代的编译器支持这种语法。

```
unsigned n; // 长度变量
cin >> n; // 由用户输入想要的长度
char str1[n]; // 这就是一个n长度的数组，n是刚才用户输入的值
cin >> n; // 由用户再次输入一个长度变量
char str2[n]; // 这就是一个n长度的数组，这里n的值可以不同于上次
```

但是我不推荐这样定义数组，有以下几个原因：

- C++ 标准从未对变长度数组⁴¹的使用作出明确规定规定。C++ 标准中只允许了使用常量表达式⁴²来作为数组长度。因此它本身就是一种未定义行为。
- 这种语法只是部分编译器对 C++ 标准的扩充，但并不是所有编译器都能做到！比如说，这段代码可以在 GCC 或 Clang 中通过编译，但在 MSVC 中就不行。
- 变长度数组的类型是模糊的。我们提过，不同长度的数组属于不同的类型，它们之间不能等同。那么这里的 str1 和 str2 到底是什么类型呢？这就造成了类型上的困惑。

正因如此，我非常不推荐使用这种方法来定义“在运行时确定长度”的数组。我们权当这种语法不存在就好。

那么我们还有什么别的办法吗？这就要谈到动态内存分配（Dynamic memory allocation）技术了。

动态内存分配是什么？

我们此前所接触的数组定义方式被称为“静态分配”，简单说就是，一个数组的大小在编译期就决定好了。具体的内存分配肯定是在运行时进行，但是它也只能遵照代码中的规则，代码中要求它分配多少内存，它就分配多少内存。

这种方式很简单，也容易实现。但它的问题在于太不灵活。为了使数组有足够的容量，我们不得不用饱和式的方法来分配内存，把数组设计得越大越好。

动态内存分配则不同，它可以根据运行时的实际需要来分配内存空间。如果运行时需要存储 100 个 **double** 数据，那我们就使用一个大小为 800 字节 ($100 * \text{sizeof}(\text{double})$) 的内存块来存着就好。如果运行时需要存储 10000 个呢？那我们就使用一个大小为 80000 字节的内存块来存着就好。这就是“动态分配”，我们可以在运行时再决定使用多少内存，而无需提前在代码中决定。这是一种按需分配。

动态内存分配需要使用关键字 **new**，它会在内存的堆段找到一段未被使用的空间。我们需要用一个指针来存储这段空间（第一个字节）的地址，否则我们就不知道它在哪里了（这也是指针的重要之处）。

⁴¹变长度数组（Variable-length array），是指大小在运行时确定的数组。这里特指如 **char** str1[n] 这样用变量长度来定义数组的情况。

⁴²或者是在编译时可确定的常量。总之，需要是一种能够在编译时确定的信息。

```
int *pobj = new int {3}; //new在动态内存中创建一个对象（数据）并初始化为3
double *arr = new double[4] {.1, .2};
//new[]在动态内存中创建一个长度为4的数组，初始化列表中留空的部分为0
```

`new` 和 `new[]` 是两个运算符，前一个用来动态分配单个对象（数据），而后一个用来动态分配数组。

在实际编程中，这两个运算符的作用差不多，而且一般也不会同时出现，所以我们通常把它当成是一样的东西。但是在回收的时候我们要注意它们的对应关系，否则就会出错。我们待会儿再谈。

`new/new[]` 的返回值是一个 `void*`，它会隐式类型转换成我们需要的指针类型。比如说 `new int` 的返回类型就是 `int*`，而 `new double[4]` 的返回类型就是 `double*`。这个返回值可以被指针存储，此时这个指针就指向了此段动态内存。

对于 `new` 分配的内存空间，我们可以把它当成一个“指向对象的指针”来用，比如说 `*pobj`（当然，也可以是 `pobj[0]`），这就相当于一个对象（变量），它的用法如同对象名（变量名）那样。

对于 `new[]` 分配的内存空间，我们可以把它当成一个“数组”来用，比如说 `arr[i]`（也可以是 `*(arr+i)`）。总之，只要你会用静态的变量/数组，那你自然就会用动态的。

内存泄漏问题及动态内存的回收

动态内存与静态内存的另一个区别在于它们的生存期。我们讲过静态数据的生存期，它们在定义完毕时生存期开始，而在作用域结束时生存期结束。

```
{ //某个作用域
    int x {3}; //x的生存期开始
    { //内层作用域
        int y {x}; //y的生存期开始；x对本作用域可见
    } //y的生存期结束，此后y这个名字没有意义
    { //另一个内层作用域
        int y[5]; //y的生存期开始，虽然它和前面的y重名，但它们没有任何必然联系
    } //y的生存期结束
} //x的生存期结束
```

这些局部静态变量存储于栈段（见图 5.1）。

而经过 `new/new[]` 分配的内存空间存储于堆段（见图 5.1），它们的特征与静态变量不同。它们在 `new/new[]` 之后生存期开始，此后就会长期存在，无论作用域怎么变化，都不会影响它们的生存期。

```
{ //某个作用域
    int *p; //p的生存期开始，p仍是静态生存期的
    { //内层作用域
        p = new int[3]; //p指向的位置处，有一个动态数组的生存期开始
    } //作用域结束，但动态数组的生存期并未结束
    p[0] = 3; //动态数组仍然可用
} //p的生存期结束，但动态数组的生存期依旧没有结束
```

现在我们遇到了一个棘手的问题：`p` 的生存期结束了，但用 `new[]` 分配的动态数组的生存期还没结束。结果就是，这个内存空间已经不能用了（因为 `p` 已经不能用了，我们就不可能知道这段动态内存的地址的），但是它仍然存在，变成了占据着内存空间但起不到任何作用的僵尸！这就是一个典型的内存泄漏（Memory leak）问题。

在个人电脑上，内存泄漏问题是很容易解决的。比如这段代码

```
int main() {
```

```

while (true)
    new long double;
return 0;
}

```

这是一个内存泄漏器，只要跑起来就会不停地吃内存，直到内存空间没有一点余量，程序才会以 `bad_alloc` 异常结束。读者可以打开自己的任务管理器，看一下内存占用的情况。

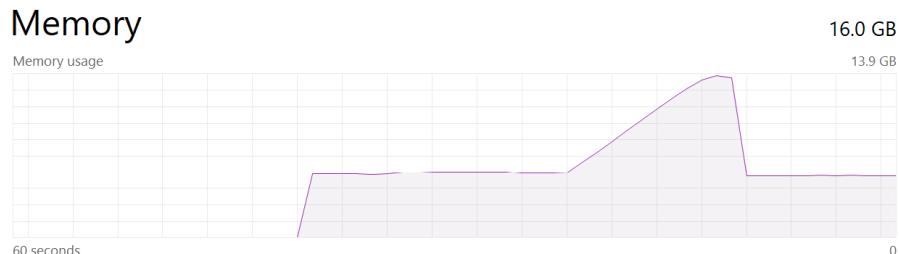


图 5.17: 开始运行内存泄漏器和结束运行时，内存占用的变化

图中可以看到，在我们开始运行这个程序的那一刻，内存占用就迅速增加，直到接近最大值。而在我们结束这个程序的时候，内存占用马上又回到了原来的水平。所以对于个人电脑来说，内存泄漏是无关紧要的小问题，结束一下进程，它就解决了。

但是不是任何时候都可以靠结束进程来解决问题的。对于需长期运行的服务器来说，贸然结束进程可以意味着很大的损失。所以在我们日常写代码的时候就要养成良好的习惯，不要写出会导致内存泄漏的代码来。

那么怎么预防内存泄漏呢？唯一的方法就是及时回收（或者叫释放）那些我们不需要的内存空间。

回收内存空间需要用到 `delete` 或 `delete[]` 运算符。其中 `delete` 运算符用于回收 `new` 分配的内存空间，而 `delete[]` 运算符用于回收 `new[]` 分配的内存空间。它们两个是不同的，一定不要混用！

```

int *pobj = new int;
delete pobj; // 使用 new 分配的动态内存要用 delete 回收
pobj = nullptr;
double *arr = new double[4];
delete[] arr; // 使用 new[] 分配的动态数组要用 delete[] 回收，[] 内无需加数字
arr = nullptr;

```

读者需要注意的是，`delete/delete[]` 只是回收了这个指针所指向的动态内存，它不会影响指针的值。那么在动态内存回收之后，这个指针指向的就是无效区域——换句话说，它是野指针！那么为了防范野指针的出现，我们最好在回收内存空间之后，让这个指针指向 `nullptr` (`nullptr` 是对所有指针都绝对安全的避风港)。

真实情况下的内存泄漏往往不是由这么低级的“忘记回收”导致的，而是一些“我们自己都没想到需要回收”的情况，比如

```

int* alloc(int value) { // 注意返回类型是 int*, 它意味着返回一个地址值
    return new int {value}; // 直接返回由 new 分配好的动态空间，已经用 value 初始化
}
int main() {
    const int N {10};
    int *p[N]{};
    int*p[N]{}; // 定义由 N 个指针构成的指针数组
}

```

```

p[0] = alloc(5); //让将 p[0] 指向 alloc 分配好的动态内存空间
//在经历了很多操作之后
delete p[0]; //最后记得回收！
return 0;
}

```

我们很容易在复杂的代码中忘记了回收动态内存空间，尤其是在这种“`new` 出现在一个函数中，而使用这个动态内存却是在另一个函数中”的情形下（类似的例子，我们会在面向对象编程时见得很多）。所以动态内存分配的灵活性与危险性是并存的，我们稍有不慎，就可能会造成内存泄漏的问题。

二维数组的动态内存分配

现在你已经学会了如何动态分配一个一维数组，那么如何动态分配一个二维数组呢？我们想，二维数组也只不过是一个“一维数组类型的一维数组”，所以我们用一维数组的动态内存分配语法就足以分配一个二维数组了。

```

int n;
cin >> n;
int (*pta)[10] = new int[n][10];

```

在这里，`new[]` 的返回值是一个 `(int*)[10]`，也就是指向数组的指针，我们可以定义一个 `pta` 来存储这个返回值。这样，我们就用一个指向 `10` 长度 `int` 数组的指针，指向了一个 `n` 长度的 `10` 长度 `int` 动态数组。这话可能有点绕，读者多琢磨一下想必就可以理解。

回收这个数组的方式很简单，直接 `delete[]` 就行。

```

delete[] pta; //回收 pta 指向的动态内存
pta = nullptr; //最好这样

```

但是这样也有一个限制——我们在这里定义的是一个 `n*10` 大小的数组，还是有一个维度需要静态分配的。我们能不能让两个维度都是变量，比如定义一个 `n*m` 动态数组？其实是可以的。

我们的思路是，先用一个二阶指针，分配一个动态指针数组：

```

int **pp = new int*[n] {}; //全部初始化为nullptr

```

在这里，`new` 的返回值是一个 `int*[n]`，也就是长度为 `n` 的指针数组。那么其中随便一个 `pp[i]` 都是一个 `int*` 指针，工我们岂不是可以直接为每个这样的指针分配一个长度为 `m` 的动态数组？

```

for(int i=0; i<n; i++) { //别忘了 pp 下标的范围是 0~n-1，而不是 1~n
    pp[i] = new int[m] {}; //对其中的每个指针 pp[i] 都分配一个长度为 m 的数组
}

```

至于这种二维数组的回收，那就有讲究了。我们首先为 `pp` 分配了一个 `int*` 指针数组，然后又为其中的每个 `int*` 指针分配了一个 `int` 数组，所以这些内容都要回收（仅回收 `pp` 指向的空间不代表回收了每个 `pp[i]` 指向的空间）。但是怎么回收就是个问题了——

```

delete[] pp; //回收 pp 指向的空间
for(int i=0; i<n; i++) {
    delete[] pp[i]; //错误！
}

```

我们仔细想一遍过程就知道为什么了：当 `pp` 的空间被回收之后，`pp` 就变成了一个野指针。这时候再访问它的内容就不合理了，所以 `pp[i]` 这个用法也就有问题了！

所以我们回收动态内存的时候也要讲求一个顺序。应该先回收各个 `pp[i]` 的空间，然后再回收 `pp` 的空间才对。

```
for(int i=0; i<n; i++) {  
    delete[] pp[i]; //先回收各个pp[i]的空间  
}  
delete[] pp; //再回收pp的空间
```

第六章 自定义类型及其使用

迄今为止，我们遇到的各种类型都是 C++ 提供给我们的。要么是基本类型，要么是指针、数组、引用这样的复合类型。类型（Type）与数据（Data）之间是类与对象的关系。一个数据只不过是内存中若干 0 和 1 的排列组合，倘若没有类型，程序就不知道如何把这些信息解释成有效内容。而对于同一串 0/1 来说，如果类型不同，那么解释出来的信息也是不一样的。以下是一个例子：

```
int n {0x63794b37}; // 这是一个 16 进制字面量，其 10 进制为 1668893495  
cout << (char*)&n; // 以字符串形式输出
```

在某台电脑上，它的输出是

7KycT¤\$¤¤

为什么把 `int*` 类型转换成 `char*` 类型之后再输出就会得到这么奇怪的内容呢？原因就出在类型上。




图 6.1: 对同一段比特串，不同类型会解读出不同内容

内存中的 32 个比特如图所示。如果用 `int` 类型去解读它，就会得到 1668893495；而如果用 `char` 类型去解读它，就会分别得到四个字符 '7', 'K', 'y', 'c'。而当我们以 `char*` 类型输出时，因为这里没有结束符 '\0'，所以它还会继续输出后面内存中的无意义内容，直到碰到结束符为止。

所以我们可以认为，类型就是信息与二进制编码之间的一套转换方案。同样一串二进制编码，在不同类型下会解释出不同的信息——这也就是为什么我从第一章起就在强调“类型”。

那么言归正传（刚才的内容看不懂也没关系）。在本章，我将讲解如何利用基本数据类型和上一章中讲到的复合数据类型，来自创类型。我们不需要研究到比特这个层次，更不需要讲什么编码，我们拿 C++ 现成的类型来组合就可以了。

6.1 枚举常量

定义一个枚举常量的基本格式如下：¹

```
enum <枚举名> {<枚举项>=<整型常量表达式>, <枚举项>=<整型常量表达式>, ...};
```

¹本节只介绍无作用域枚举，关于有作用域枚举，请见精讲篇。

枚举名不是必须的。如果不使用枚举名，那么这些枚举项的类型就是匿名枚举，这样做相当于定义了一些整型常量。如果我们规定了名字，那它们就是具名枚举，有丰富的作用。

枚举常量都是基于整型的，它的枚举项可以隐式类型转换为整型来输出。

```
enum {A=1, B=3, C=5}; //不具名枚举
cout << B; //输出3
```

我们可以省略其中的部分枚举项的值，这时枚举项的值是基于前一个值递增的。

```
enum {A=-2, B=4, C, D}; //C为递增为5, D递增为6
enum {E, F, G}; //第一项E不设值则为0, 后面F,G分别为1和2
```

如果我们需要一次性定义大量整型常量，那么除了 `const` 及 `constexpr` 语法之外，我们还可以选择 `enum`。

如果这个枚举有枚举名，那么我们还可以把它作为一个类型来用！具名枚举类型的优点是：

- 它的值可以用标识符来表示，而不是用单纯的字面量——我们提过，常量表达式比字面量的一大好处在于方便在源代码层面做统一修改。
- 具名枚举类型可以隐式转换为整型常量，所以我们使用起来很方便。
- 整型常量不能隐式转换为具名枚举类型，而且具名枚举类型数据的取值范围有很大限制，我们可以很防止这类数据取一些不允许的值。

举个例子，想必读者就可以理解了。关于服装的尺码，不同国家/地区都有各自的规定。以男士西装为例，欧洲/俄罗斯、英国/美国、日本、韩国都有自己的尺寸对照表。我们可以用枚举常量来表示各个尺寸。

```
enum SuitsSize {
    XXS=40, XS=42, S_1=44, S_2=46, M_1=48, M_2=50,
    L_1=52, L_2=54, XL=56, XXL=58, XXXL=60
}; //这是欧洲/俄罗斯标准
```

接下来我们可以定义一些 `SuitsSize` 类型的变量，比如说就定义成对应的人名吧。

```
SuitsSize Erik {XXL}; //Erik的值就是XXL, 不是58, 只是它可以隐式转换成58
SuitsSize Jacques {XS}; //Jacques的值就是XS
SuitsSize Carlos {M_1}; //M尺码有两个, 为了区分而分别写成M_1和M_2
```

当我们想要知道枚举项的具体值时，我们可以直接以 `int` 类型输出。

```
cout << static_cast<int>(XL); //或者直接cout<<XL, 会隐式类型转换
```

如果某个人的尺码发生了改变，我们可以直接赋值来改变，非常方便。

```
Erik = XXXXL; //胖了
```

但是我们赋值也不能乱来；我们只能赋那些已经规定好了的项。

```
Eirk = XXXXXXXL; //错误!
```

既然 `SuitsSize` 也是一个类型，那么我们当然还可以定义这个类型的常量数据。

```
const SuitsSize Giovanni {XXXL}; //Giovanni的值一经定义, 就不可改变
```

总而言之，我们可以把具名枚举的各项看作是整型数据，但是我们应该先把它当成一种特殊的自定义类型，它的值就是标识符本身，只不过可以转换为整型而已。作为类比，我们可以想一下 `bool` 类型，它的值就是标识符 `true` 或 `false` 本身，只是它可以隐式转换成整型而已。

精讲篇

附录 A C++ 运算符基本属性

表 A.1 列出了截至 C++17 的所有运算符的优先级、结合性和重载要求。¹

表 A.1: 截至 C++17 的所有运算符

优先级	运算符	运算符含义	结合性	重载要求
1	scope::a	作用域解析	从左到右	不可重载
2	var++ var--	后缀自增/自减		特殊参数要求 ²
	type() type{}	函数风格类型转换 ³		可重载
	fun()	函数调用		只能是成员函数
	arr[index]	下标运算 ⁴		只能是成员函数
	obj.member	成员访问		不可重载
	p_obj->member	指针的成员访问		返回类型受限 ⁵ 只能是成员函数 不能是静态函数
3	++var --var	前缀自增/自减	从右到左	可重载
	+var -var	一元加/减(正/负号)		可重载
	!var ~var	逻辑非/按位取反		可重载
	(type)var	C 风格类型转换		可重载
	*pointer	取内容(解引用)		可重载
	&var	取地址		可重载
	new / new[]	动态内存分配		可重载
	delete / delete[]	动态内存回收		可重载
	sizeof a ⁶	求内存空间大小		不可重载
4	obj.*p	成员指针访问	从左到右	不可重载
	p_obj->*p	指针的成员指针访问		可重载
5	lhs*rhs lhs/rhs lhs%rhs	乘法/除法/模运算		可重载 ⁷
6	lhs+rhs lhs-rhs	加法/减法		可重载

¹值得注意的是，虽然双引号"" 不被视为运算符，但它可以用在重载自定义字面量的语法中。本书不予以介绍，对此感兴趣的读者可以阅读 [用户自定义字面量-cppreference](#)。

²重载后缀自增/自减运算符需带 `int` 型参数。参数可以不具名，事实上也无需使用。这样的语法是为了与前缀形式相区别。

³函数风格类型转换、C 风格类型转换和 `static_cast` 在静态类型转换时是等价的。换言之，只需定义一个转换函数，就可以使用这三种类型转换语法。

⁴对于内置类型数组 `arr` 的下标运算，`arr[index]` (和 `index[arr]`) 都会解析为 `*(arr+index)` (和 `*(index+arr)`)，而自定义类型的下标重载版本不会如此。

⁵返回类型必须是裸指针或对象。返回对象时，可以按值或按引用传递参数。

⁶不使用括号的 `sizeof a` 只适用于数据或对象；如果要对类型求内存空间大小，必须用 `sizeof(type)` 形式。

⁷注意，一些重载运算符对参数有特殊要求：必须接收至少一个自定义类型的参数，可以是类或枚举类。比如说，`double operator%(double, double)` 就是不允许的。并非所有重载都有这个限制，比如下标运算可以接收 `int` 类型的参数。

优先级	运算符	运算符含义	结合性	重载要求	
7	<code>lhs<<rhs</code> <code>lhs>>rhs</code>	左移位/右移位	从左到右	可重载	
8	<code>lhs<rhs</code> <code>lhs<=rhs</code>	小于/小于或等于		可重载	
	<code>lhs>rhs</code> <code>lhs>=rhs</code>	大于/大于或等于		可重载	
9	<code>lhs==rhs</code> <code>lhs!=rhs</code>	相等运算符/不等运算符		可重载	
10	<code>lhs&rhs</code>	按位与		可重载	
11	<code>lhs^rhs</code>	按位异或(互斥或)		可重载	
12	<code>lhs rhs</code>	按位或(可兼或)		可重载	
13	<code>lhs&&rhs</code>	逻辑与		可重载 ⁸	
14	<code>lhs rhs</code>	逻辑或(可兼或)		可重载	
15	<code>condition?exp1:exp2</code>	条件运算符	从右到左	不可重载	
	<code>throw exception</code>	抛出异常		不可重载	
	<code>lhs=rhs</code>	直接赋值		只能是成员函数	
	<code>lhs+=rhs</code> <code>lhs-=rhs</code>	复合赋值		只能是成员函数	
	<code>lhs*=rhs</code> <code>lhs/=rhs</code>				
	<code>lhs%=rhs</code> <code>lhs =rhs</code>				
16	<code>exp1,exp2</code>	逗号	从左到右	可重载	

另有这些运算符：`static_cast`, `dynamic_cast`, `const_cast`, `reinterpret_cast`, `typeid`, `noexcept`。它们在使用时必须对操作数加括号(相比之下, `sizeof` 是可以不对操作数加括号的), 因而不受优先级、结合性问题困扰, 不列入表 A.1。以上这些运算符均不可重载, 但你可以通过自定义转换函数的方式来使 `static_cast` 变得可用。

⁸逻辑与/逻辑或函数有短路求值特点, 如对于 `false&&f()`, 在左操作数为 `false` 时已经能确定整个表达式为 `false`, 故不需要再求 `f()`, 于是右操作数及其副作用都不会发生。但这两个运算符经过重载后并不保留短路求值特性, 左右操作数都会被计算。

附录 B ASCII 码表（0 到 127）

ASCII 字符分为控制字符和可显示字符两部分。

表 B.1 是 33 个 ASCII 控制字符，其中 DEC 代表十进制形式，HEX 代表十六进制形式，CN 代表脱出字符¹，ES 代表转义字符²，CH 代表字符含义。

表 B.1: 33 个 ASCII 控制字符

DEC	HEX	CN	ES	CH	DEC	HEX	CN	ES	CH
0	00	[^] @	\@	NUL 空	16	10	[^] P		DLE 退出数据链
1	01	[^] A		SOH 标题开始	17	11	[^] Q		DC1 设备控制 1
2	02	[^] B		STX 正文开始	18	12	[^] R		DC2 设备控制 2
3	03	[^] C		ETX 正文结束	19	13	[^] S		DC3 设备控制 3
4	04	[^] D		EOT 传送结束	20	14	[^] T		DC4 设备控制 4
5	05	[^] E		ENQ 询问	21	15	[^] U		MAK 反确认
6	06	[^] F		ACK 确认	22	16	[^] V		SYN 同步空闲
7	07	[^] G	\a	BEL 响铃	23	17	[^] W		ETB 传输块结束
8	08	[^] H	\b	BS 退格	24	18	[^] X		CAN 取消
9	09	[^] I	\t	HT 横向制表	25	19	[^] Y		EM 媒介结束
10	0A	[^] J	\n	LF 换行	26	1A	[^] Z		SUB 替换
11	0B	[^] K	\v	VT 纵向制表	27	1B	[^] [\e ³	ESC 退出
12	0C	[^] L	\f	FF 换页	28	1C	[^] \		FS 文件分隔符
13	0D	[^] M	\r	CR 回车	29	1D	[^]]		GS 组分隔符
14	0E	[^] N		SO 移出	30	1E	[^] ^		RS 记录分隔符
15	0F	[^] O		SI 移入	31	1F	[^] _		US 单无分隔符
127	7F	[^] ?		DEL 删除					

表 B.2 是 95 个 ASCII 可打印字符，其中 DEC 表示十进制形式，HEX 表示十六进制形式，CH 代表字符。

¹ 脱出字符 (Caret notation)，是 ASCII 控制字符的一种记号，常用于在终端当中输入控制字符。多数情况下，脱出字符由 Ctrl+ 某键输入，而不是敲下^加一个字符。在显示时，脱出字符被视为单个字符，而非两个。

² 转义字符 (Escape sequence)，是一个字符序列，它以反斜线开头，用特定的字母组合来表达一些特殊含义。在输出转义字符时，它们不会按照原形式输出，而是被译为另一类字符（比如控制字符）。

³ C++ 和许多语言标准都没有明确规定将\e作为转义字符，但是有些编译器，如 GCC，允许使用这种语法。

表 B.2: 95 个 ASCII 可打印字符

DEC	HEX	CH	DEC	HEX	CH	DEC	HEX	CH	DEC	HEX	CH
32	20	⁴	48	30	Ø	64	40	@	80	50	P
33	21	!	49	31	1	65	41	A	81	51	Q
34	22	" ⁵	50	32	2	66	42	B	82	52	R
35	23	#	51	33	3	67	43	C	83	53	S
36	24	\$	52	34	4	68	44	D	84	54	T
37	25	%	53	35	5	69	45	E	85	55	U
38	26	&	54	36	6	70	46	F	86	56	V
39	27	' ⁶	55	37	7	71	47	G	87	57	W
40	28	(56	38	8	72	48	H	88	58	X
41	29)	57	39	9	73	49	I	89	59	Y
42	2A	*	58	3A	:	74	4A	J	90	5A	Z
43	2B	+	59	3B	;	75	4B	K	91	5B	[
44	2C	,	60	3C	<	76	4C	L	92	5C	\ ⁷
45	2D	-	61	3D	=	77	4D	M	93	5D]
46	2E	.	62	4E	>	78	4E	N	94	5E	^
47	2F	/	63	4F	?	79	4F	O	95	5F	_
96	60	`	104	68	h	112	70	p	120	78	x
97	61	a	105	69	i	113	71	q	121	79	y
98	62	b	106	6A	j	114	72	r	122	7A	z
99	63	c	107	6B	k	115	73	s	123	7B	{
100	64	d	108	6C	l	116	74	t	124	7C	
101	65	e	109	6D	m	117	75	u	125	7D	}
102	66	f	110	6E	n	118	76	v	126	7E	~
103	67	g	111	6F	o	119	77	w			

⁴此处为空格符。⁵字符 " 在 C++ 代码中需用转义字符 '\\"' 表达。⁶字符 ' 在 C++ 代码中需用转义字符 '\'' 表达。⁷字符 \ 在 C++ 代码中需用转义字符 '\\\' 表达。

附录 C 相关数学知识

本附录列出了部分有关的数学知识。这些知识并非必要的内容，但掌握它们可以让你对 C++ 语言有更深入的理解。

C.1 进制与进制转换

跋

編程技巧馬行空，語法知識也錯綜。

偶遇疑難求上下，遭逢困惑問西東。

鑽研練就超群技，實踐能成鬼斧工。

道遠路長君莫嘆，錦囊盡在此書中。

